


## INVERSÃO LINEAR:

### ESTIMADOR DE MÍNIMOS QUADRADOS PONDERADOS

Muitas vezes as observações geofísicas não são obtidas com o mesmo grau de precisão, sendo umas observações mais precisas que outras. Neste caso não é razoável exigir que a função ajustante produza a mesma proximidade a todas as observações. É mais razoável exigir um ajuste “melhor” nas observações geofísicas mais precisas e um ajuste “pior” nas observações geofísicas menos precisas (Figura 1).



Matematicamente, ao invés de minimizarmos a soma dos quadrados dos resíduos, i.e.,

$$\min_{\bar{\mathbf{p}} \in F} \{Q\} \equiv \min_{\bar{\mathbf{p}} \in F} \{\|\boldsymbol{\epsilon}\|_2^2\} \equiv \min_{\bar{\mathbf{p}} \in F} \left\| \bar{\mathbf{y}}^o - \bar{\mathbf{A}} \bar{\mathbf{p}} \right\|_2^2 \equiv \min_{\bar{\mathbf{p}} \in F} \left( \bar{\mathbf{y}}^o - \bar{\mathbf{A}} \bar{\mathbf{p}} \right)^T \left( \bar{\mathbf{y}}^o - \bar{\mathbf{A}} \bar{\mathbf{p}} \right)$$

minimizaremos a soma dos quadrados ponderados dos resíduos

$$\min_{\bar{\mathbf{p}} \in F} \{Q\} \equiv \min_{\bar{\mathbf{p}} \in F} \left\{ \sum_{i=1}^N \epsilon_i^2 w_i \right\} \equiv \min_{\bar{\mathbf{p}} \in F} \sum_{i=1}^N \left[ y_i^o - y_i^c \right]^2 w_i$$

Em notação matricial temos:

$$\min_{\bar{\mathbf{p}} \in F} \{ Q \} \equiv \min_{\bar{\mathbf{p}} \in F} \left\{ \bar{\boldsymbol{\varepsilon}}^T \overline{\overline{\mathbf{W}}} \bar{\boldsymbol{\varepsilon}} \right\} \equiv \min_{\bar{\mathbf{p}} \in F} \left\{ \left\| \overline{\overline{\mathbf{W}}}^{1/2} \bar{\boldsymbol{\varepsilon}} \right\|_2^2 \right\}$$

em que  $\overline{\overline{\mathbf{W}}} \in R^{N \times N}$  é uma matriz diagonal de pesos, de modo que o i-ésimo elemento do resíduo ( $\varepsilon_i$ ) será ponderado pelo i-ésimo elemento da diagonal de  $\overline{\overline{\mathbf{W}}}$

$$Q = \varepsilon_1^2 w_1 + \varepsilon_2^2 w_2 + \varepsilon_3^2 w_3 + \dots + \varepsilon_N^2 w_N$$

O método dos Mínimos Quadrados Ponderados (MQP) impõe que cada elemento do vetor das observações calculadas ou ajustadas ( $\bar{\mathbf{y}}^c$ ) deve estar o próximo ao correspondente elemento do vetor observado ( $\bar{\mathbf{y}}^o$ ), sendo que o grau desta proximidade é controlado pela escolha dos pesos  $w_i$ .

Se todos os elementos que compõe o vetor  $\bar{\mathbf{y}}^c$  (anomalia ajustada) devem estar igualmente próximos aos elementos que compõe  $\bar{\mathbf{y}}^o$  (dados observados) então, neste caso, a matriz de peso será a matriz identidade  $\overline{\overline{\mathbf{W}}} = \overline{\overline{\mathbf{I}}}$  e o método se reduz aos Mínimos Quadrados (MQ) já estudado anteriormente.

$$\min_{\bar{\mathbf{p}} \in F} Q = \bar{\boldsymbol{\varepsilon}}^T \overline{\overline{\mathbf{W}}} \bar{\boldsymbol{\varepsilon}}$$

$$\min_{\bar{\mathbf{p}} \in F} Q = (\bar{\mathbf{y}}^o - \bar{\mathbf{y}}^c)^T \overline{\overline{\mathbf{W}}} (\bar{\mathbf{y}}^o - \bar{\mathbf{y}}^c)$$

como

$$\bar{\mathbf{y}}^c = \overline{\overline{\mathbf{A}}} \bar{\mathbf{p}}$$

então temos

$$\min_{\bar{\mathbf{p}} \in F} Q = \left( \bar{\mathbf{y}}^o - \overline{\overline{\mathbf{A}}} \bar{\mathbf{p}} \right)^T \overline{\overline{\mathbf{W}}} \left( \bar{\mathbf{y}}^o - \overline{\overline{\mathbf{A}}} \bar{\mathbf{p}} \right)$$

A condição necessária para que  $Q$  tenha mínimo é

$$\begin{aligned}\overline{\nabla}_{\overline{\mathbf{p}}} \{Q\} &= \overline{\mathbf{0}} \\ \overline{\nabla}_{\overline{\mathbf{p}}} \{Q\} &= \overline{\nabla}_{\overline{\mathbf{p}}} \left\{ \left( \overline{\mathbf{y}}^o - \overline{\mathbf{A}} \overline{\mathbf{p}} \right)^T \overline{\mathbf{W}} \left( \overline{\mathbf{y}}^o - \overline{\mathbf{A}} \overline{\mathbf{p}} \right) \right\} = \overline{\mathbf{0}}\end{aligned}$$

Para o cálculo do vetor gradiente acima, veja na revisão de álgebra linear o item

gradiente de uma forma quadrática do tipo  $Q = \overline{\mathbf{x}}^T \overline{\mathbf{A}} \overline{\mathbf{x}}$ .

$$\begin{aligned}\overline{\nabla}_{\overline{\mathbf{p}}} \{Q\} &= 2 \overline{\nabla}_{\overline{\mathbf{p}}} \left\{ \left( \overline{\mathbf{y}}^o - \overline{\mathbf{A}} \overline{\mathbf{p}} \right)^T \right\} \overline{\mathbf{W}} \left( \overline{\mathbf{y}}^o - \overline{\mathbf{A}} \overline{\mathbf{p}} \right) = \overline{\mathbf{0}} \\ \overline{\nabla}_{\overline{\mathbf{p}}} \{Q\} &= 2 \left( \overline{\nabla}_{\overline{\mathbf{p}}} (\overline{\mathbf{y}}^{oT}) - \overline{\nabla}_{\overline{\mathbf{p}}} (\overline{\mathbf{p}}^T \overline{\mathbf{A}}^T) \right) \overline{\mathbf{W}} \left( \overline{\mathbf{y}}^o - \overline{\mathbf{A}} \overline{\mathbf{p}} \right) = \overline{\mathbf{0}}\end{aligned}$$

como  $\overline{\nabla}_{\overline{\mathbf{p}}} (\overline{\mathbf{y}}^{oT}) = \overline{\mathbf{0}}$ , então temos

$$\overline{\nabla}_{\overline{\mathbf{p}}} \{Q\} = -2 \left( \overline{\nabla}_{\overline{\mathbf{p}}} (\overline{\mathbf{p}}^T \overline{\mathbf{A}}^T) \right) \overline{\mathbf{W}} \left( \overline{\mathbf{y}}^o - \overline{\mathbf{A}} \overline{\mathbf{p}} \right) = \overline{\mathbf{0}}$$

como  $\overline{\nabla}_{\overline{\mathbf{p}}} (\overline{\mathbf{p}}^T) = \overline{\mathbf{I}}$ , então temos

$$\begin{aligned}\overline{\nabla}_{\overline{\mathbf{p}}} \{Q\} &= -2 \overline{\mathbf{A}}^T \overline{\mathbf{W}} \left( \overline{\mathbf{y}}^o - \overline{\mathbf{A}} \overline{\mathbf{p}} \right) = \overline{\mathbf{0}} \\ -2 \overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{y}}^o + 2 \overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}} \overline{\mathbf{p}} &= \overline{\mathbf{0}} \\ \overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}} \overline{\mathbf{p}} &= \overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{y}}^o\end{aligned}$$

Resultando no estimador dos Mínimos Quadrados Ponderados (MQP)

$$\hat{\overline{\mathbf{p}}} = \left( \overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}} \right)^{-1} \overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{y}}^o$$

### **Análise da unicidade da solução estimada via MQP:**

A solução  $\hat{\mathbf{p}}$  só será única se a matriz a ser invertida ( $\overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}}$ ) for NÃO SINGULAR. Um meio de avaliarmos se a matriz é não singular é através do seu determinante. Se o determinante a matriz  $\overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}}$  é diferente de zero ( $\text{Det}(\overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}}) \neq 0$ ) esta matriz é não singular. Um segundo meio de avaliarmos se uma matriz é não singular é através do seu posto<sup>1</sup>. Como a matriz de sensibilidade  $\overline{\mathbf{A}}$  é  $N \times M$ , o produto  $\overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}}$  é  $M \times M$  então, a matriz  $\overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}}$  deve ter posto  $M$  (número de parâmetros) para ser uma matriz não singular ( $r(\overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}}) = M$ ). Tal como no estimador MQ, para usarmos o estimador de mínimos quadrados ponderados é necessário, embora não suficiente que  $N \geq M$ , isto é que o número de observações ( $N$ ) seja pelo menos igual ao número de parâmetros ( $M$ ). Para garantirmos a unicidade da solução estimada via estimador MQP é necessário e suficiente que  $N \geq M$  e o posto da matriz  $\overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}}$  seja igual a  $M$  ( $r(\overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}}) = M$ ).

Caso contrário, se ( $\overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}}$ ) for singular então,  $\hat{\mathbf{p}} \equiv \mathbf{0}$  não é a única solução da equação normal  $\overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}} \mathbf{p} = \overline{\mathbf{A}}^T \overline{\mathbf{W}} \mathbf{y}^o$  e a condição mencionada anteriormente para a unicidade da solução não é satisfeita. Neste caso em que não há unicidade da solução a matriz  $\overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}}$  é singular, então o seu determinante é igual a zero ( $\text{Det}(\overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}}) = 0$ ) e o seu posto é menor que o número de parâmetros a serem estimados ( $r(\overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}}) < M$ ).

Vamos supor que a matriz  $\overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}}$  é não singular, portanto garantimos a unicidade da solução. Já falamos anteriormente, que a unicidade da solução é uma condição necessária, mas não é suficiente para afirmarmos que estamos resolvendo um problema bem-posto. Falta analisar a estabilidade da solução estimada que estudaremos aqui através de uma análise estatística.

---

<sup>1</sup> posto de uma matriz é o número de vetores colunas (ou vetores linhas) que formam um conjunto LI de vetores

### **Análise da Estabilidade da solução MQP via análise estatística:**

Como já abordamos anteriormente, o estudo da estabilidade da solução pode ser realizado através da variância dos parâmetros, uma vez que o estimador  $\hat{\mathbf{p}}$  é uma variável aleatória. Vamos analisar se o estimador  $\hat{\mathbf{p}}$  apresenta variância mínima. Lembramos que, à luz da estatística um bom estimador  $\hat{\mathbf{p}}$  deve ser não tendencioso e de variância mínima. Então vamos calcular a esperança e variância do estimador de mínimos quadrados  $\hat{\mathbf{p}}$ . Para tanto precisamos estabelecer alguma premissas estatísticas sobre o ruído que contamina os dados (veja Anexo 1 do tópico 3) e também sobre as demais variáveis do modelo matemático.

#### **(1) Esperança do estimador MQP ( $\hat{\mathbf{p}}$ ) :**

Considerando as premissas estatísticas estabelecidas na Figura 2 e as propriedades da esperança, temos que

$$E \left\{ \hat{\mathbf{p}} \right\} = E \left\{ \left( \overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{A}} \right)^{-1} \overline{\mathbf{A}}^T \overline{\mathbf{W}} \overline{\mathbf{y}}^o \right\}$$

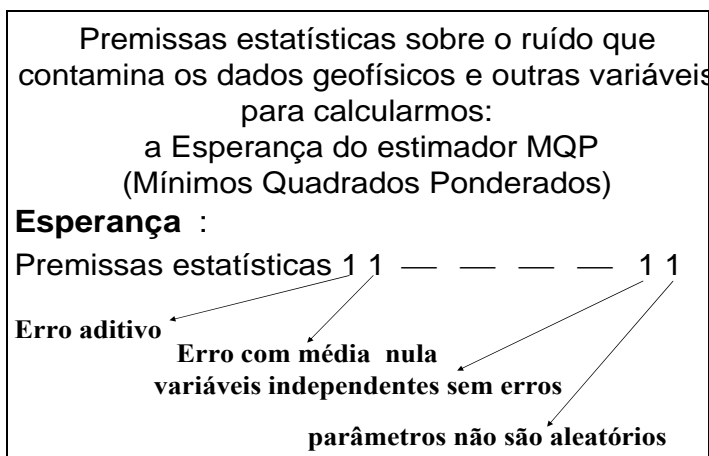


Figura 2

Usando a premissa 1 que os erros são aditivos ( $\overline{\mathbf{y}}^o = \overline{\mathbf{y}}^c + \overline{\mathbf{\varepsilon}}$ ) e usando a informação que em um problema linear a componente determinística (vetor dos dados ajustados ou calculados) é  $\overline{\mathbf{y}}^c = \overline{\mathbf{A}} \overline{\mathbf{p}}$  temos que

$$E \left\{ \hat{\bar{\mathbf{p}}} \right\} = E \left\{ \left( \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} (\bar{\mathbf{A}} \bar{\mathbf{p}} + \bar{\boldsymbol{\varepsilon}}) \right\}$$

$$E \left\{ \hat{\bar{\mathbf{p}}} \right\} = E \left\{ \left( \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} \bar{\mathbf{p}} + \left( \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\boldsymbol{\varepsilon}} \right\}$$

$$\text{como } \left( \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} = \bar{\mathbf{I}}$$

$$E \left\{ \hat{\bar{\mathbf{p}}} \right\} = E \left\{ \bar{\mathbf{p}} \right\} + E \left\{ \left( \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\boldsymbol{\varepsilon}} \right\}$$

Usando a premissa 7 que as variáveis independentes não são v.a. temos,

$$E \left\{ \hat{\bar{\mathbf{p}}} \right\} = E \left\{ \bar{\mathbf{p}} \right\} + \left( \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} E \left\{ \bar{\boldsymbol{\varepsilon}} \right\}$$

Pela premissa 2 os erros tem média nula o que implica  $E[\bar{\boldsymbol{\varepsilon}}] = \bar{\mathbf{0}}$  então

$$E \left\{ \hat{\bar{\mathbf{p}}} \right\} = E \left\{ \bar{\mathbf{p}} \right\}$$

Usando a premissa 7 que os parâmetros não são aleatórios temos

$$E \left\{ \hat{\bar{\mathbf{p}}} \right\} = \bar{\mathbf{p}}$$

Vemos então que o estimador MQP ( $\hat{\bar{\mathbf{p}}}$ ) é NÃO TENDENCIOSO. De fato, o estimador MQP não introduz nenhum tipo de informação a priori sobre os parâmetros a serem estimados. A informação introduzida é no espaço das observações.

## 2) Matriz de covariância do estimador MQP ( $\hat{\bar{\mathbf{p}}}$ ):

Considerando as premissas estatísticas estabelecidas na Figura 3, as propriedades da variância e partindo-se da equação da matriz de covariância de um vetor (Anexo 1) temos que

$$\text{cov} \left\{ \hat{\bar{\mathbf{p}}} \right\} = E \left\{ \left[ \hat{\bar{\mathbf{p}}} - E(\hat{\bar{\mathbf{p}}}) \right] \left[ \hat{\bar{\mathbf{p}}} - E(\hat{\bar{\mathbf{p}}}) \right]^T \right\}$$

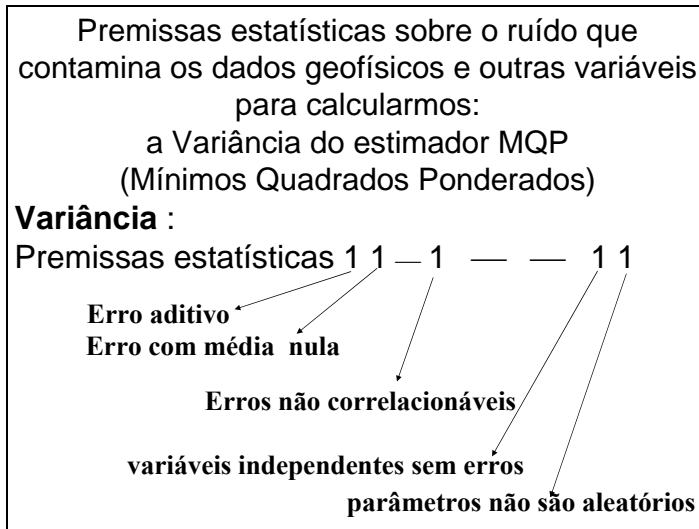


Figura 3

Usando o resultado anterior e  $E \{ \hat{\mathbf{p}} \} = \bar{\mathbf{p}}$

$$\text{cov} \left\{ \hat{\mathbf{p}} \right\} = E \left\{ \left[ \hat{\mathbf{p}} - \bar{\mathbf{p}} \right] \left[ \hat{\mathbf{p}} - \bar{\mathbf{p}} \right]^T \right\}$$

Usando a premissa 1 que os erros são aditivos ( $\bar{\mathbf{y}}^o = \bar{\mathbf{y}}^c + \bar{\boldsymbol{\varepsilon}}$ ) e a informação que o problema é linear i.e.,  $\bar{\mathbf{y}}^c = \bar{\mathbf{A}} \bar{\mathbf{p}}$  então temos que

$$\hat{\mathbf{p}} = \left( \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{y}}^o$$

$$\hat{\mathbf{p}} = \left( \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} (\bar{\mathbf{A}} \bar{\mathbf{p}} + \bar{\boldsymbol{\varepsilon}})$$

$$\hat{\mathbf{p}} = \left( \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} \bar{\mathbf{p}} + \left( \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\boldsymbol{\varepsilon}}$$

como  $\left( \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} = \bar{\mathbf{I}}$

$$\hat{\mathbf{p}} = \bar{\mathbf{p}} + \left( \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\boldsymbol{\varepsilon}}$$

substituindo o estimador acima na equação da covariância temos que

$$\text{cov}\left\{\hat{\mathbf{p}}\right\} = E\left\{\left[\bar{\mathbf{p}} + \left(\bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}}\right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\boldsymbol{\varepsilon}} - \bar{\mathbf{p}}\right] \left[\bar{\mathbf{p}} + \left(\bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}}\right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\boldsymbol{\varepsilon}} - \bar{\mathbf{p}}\right]^T\right\}$$

$$\text{COV}\left\{\hat{\mathbf{p}}\right\} = E\left\{\left[\left(\bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}}\right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\boldsymbol{\varepsilon}}\right] \left[\left(\bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}}\right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\boldsymbol{\varepsilon}}\right]^T\right\}$$

Usando propriedades da transposta temos

$$\text{COV}\left\{\hat{\mathbf{p}}\right\} = E\left\{\left(\bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}}\right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\boldsymbol{\varepsilon}} \bar{\boldsymbol{\varepsilon}}^T \bar{\mathbf{W}}^T \bar{\mathbf{A}} \left(\bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}}\right)^{-1}\right\}$$

Usando a premissa 7 que as variáveis independentes não são v.a. temos,

$$\text{COV}\left\{\hat{\mathbf{p}}\right\} = \left(\bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}}\right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} E\left\{\bar{\boldsymbol{\varepsilon}} \bar{\boldsymbol{\varepsilon}}^T\right\} \bar{\mathbf{W}}^T \bar{\mathbf{A}} \left(\bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}}\right)^{-1}$$

Temos que calcular a esperança de  $E\left\{\bar{\boldsymbol{\varepsilon}} \bar{\boldsymbol{\varepsilon}}^T\right\}$  que nada mais é que a esperança de uma forma quadrática (veja Apêndice - Matriz de Covariância dos Erros) que é expressa como

$$E\left\{\bar{\boldsymbol{\varepsilon}} \bar{\boldsymbol{\varepsilon}}^T\right\} = \text{cov}(\bar{\boldsymbol{\varepsilon}}) + E(\bar{\boldsymbol{\varepsilon}}) E(\bar{\boldsymbol{\varepsilon}}^T)$$

Pela premissa 2 os erros tem média nula o que implica  $E[\bar{\boldsymbol{\varepsilon}}] = \bar{\mathbf{0}}$  então

$$E\left\{\bar{\boldsymbol{\varepsilon}} \bar{\boldsymbol{\varepsilon}}^T\right\} = \text{cov}(\bar{\boldsymbol{\varepsilon}})$$

Substituindo o resultado acima na expressão obtemos a expressão da matriz de covariância do estimador MQP, i.e,

$$\text{COV}\left\{\hat{\mathbf{p}}\right\} = \left(\bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}}\right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}} \text{cov}\left\{\bar{\boldsymbol{\varepsilon}}\right\} \bar{\mathbf{W}}^T \bar{\mathbf{A}} \left(\bar{\mathbf{A}}^T \bar{\mathbf{W}} \bar{\mathbf{A}}\right)^{-1}$$

Usando a premissa 4 que os erros não são correlacionáveis ( $\text{cov}(\varepsilon_i, \varepsilon_j) = 0$ ,  $\forall i \neq j$ ), isto significa dizer que a matriz de covariância dos erros



$[\text{cov}(\bar{\boldsymbol{\varepsilon}})]$  é uma matriz diagonal cujo i-ésimo elemento da diagonal é a variância  $\sigma_i^2$  do i-ésimo elemento do vetor dos resíduos ( $\bar{\boldsymbol{\varepsilon}}$ ) então temos

$$\text{COV}\{\bar{\boldsymbol{\varepsilon}}\} = \begin{bmatrix} \sigma_1^2 & & & \\ & \sigma_2^2 & & \\ & & \ddots & \\ & & & \sigma_N^2 \end{bmatrix}_{N \times N}$$

### 2.1) Matriz de covariância do estimador MQP ( $\hat{\mathbf{p}}$ ) para um caso particular:

Vamos considerar o caso particular em que o i-ésimo elemento da matriz de peso  $\overline{\overline{\mathbf{W}}}$  é definido como:

$$w_i = \frac{1}{\sigma_i^2}$$

Em outras palavras, a matriz de peso  $\overline{\overline{\mathbf{W}}}$  foi definida como a inversa da matriz de covariância dos erros  $[\text{cov}(\bar{\boldsymbol{\varepsilon}})]$ . Então podemos dizer que

$$\overline{\overline{\mathbf{W}}} = (\text{COV}\{\bar{\boldsymbol{\varepsilon}}\})^{-1}$$

Veja que podemos dizer que

$$\text{COV}\{\bar{\boldsymbol{\varepsilon}}\} = \overline{\overline{\mathbf{W}}}^{-1}$$

Portanto, neste caso particular a matriz de covariância dos parâmetros do estimador  $\hat{\mathbf{p}}$  dos MQP

$$\text{COV}\left\{\hat{\mathbf{p}}\right\} = \left(\overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}}} \overline{\overline{\mathbf{A}}}\right)^{-1} \overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}}} \text{cov}\{\bar{\boldsymbol{\varepsilon}}\} \overline{\overline{\mathbf{W}}}^T \overline{\overline{\mathbf{A}}} \left(\overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}}} \overline{\overline{\mathbf{A}}}\right)^{-1}$$

será simplificada:

$$\text{COV}\left\{\hat{\mathbf{p}}\right\} = \left(\overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}}} \overline{\overline{\mathbf{A}}}\right)^{-1} \overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}}} \left(\overline{\overline{\mathbf{W}}}^{-1}\right) \overline{\overline{\mathbf{W}}}^T \overline{\overline{\mathbf{A}}} \left(\overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}}} \overline{\overline{\mathbf{A}}}\right)^{-1}$$

como  $\overline{\overline{\mathbf{W}}}(\overline{\overline{\mathbf{W}}})^{-1} = \overline{\overline{\mathbf{I}}}$

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = \left( \overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}}} \overline{\overline{\mathbf{A}}} \right)^{-1} \overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}}}^T \overline{\overline{\mathbf{A}}} \left( \overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}}} \overline{\overline{\mathbf{A}}} \right)^{-1}$$

como  $\left( \overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}}} \overline{\overline{\mathbf{A}}} \right)^{-1} \overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}}} \overline{\overline{\mathbf{A}}} = \overline{\overline{\mathbf{I}}}$  temos

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = \left( \overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}}} \overline{\overline{\mathbf{A}}} \right)^{-1}$$

Como estamos no caso particular que  $\overline{\overline{\mathbf{W}}} = (\text{COV}\{\overline{\overline{\boldsymbol{\varepsilon}}}\})^{-1}$  temos

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = \left( \overline{\overline{\mathbf{A}}}^T [\text{COV}\{\overline{\overline{\boldsymbol{\varepsilon}}}\}]^{-1} \overline{\overline{\mathbf{A}}} \right)^{-1}$$

Veja que se considerarmos que a variância dos erros contidos nas observações geofísicas (incerteza dos dados) é a mesma em todas as observações, i.e.,

$\sigma_i^2 = \sigma^2, \forall i = 1, \dots, N$  então temos que

$$\text{COV}\{\overline{\overline{\boldsymbol{\varepsilon}}}\} = \begin{bmatrix} \sigma^2 & & & \\ & \sigma^2 & & \\ & & \ddots & \\ & & & \sigma^2 \end{bmatrix} = \sigma^2 \overline{\overline{\mathbf{I}}}$$

Substituindo  $\text{COV}\{\overline{\overline{\boldsymbol{\varepsilon}}}\} = \sigma^2 \overline{\overline{\mathbf{I}}}$  temos

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = \left( \overline{\overline{\mathbf{A}}}^T \left[ \sigma^2 \overline{\overline{\mathbf{I}}} \right]^{-1} \overline{\overline{\mathbf{A}}} \right)^{-1}$$

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = \left( \overline{\overline{\mathbf{A}}}^T \left( \frac{1}{\sigma^2} \overline{\overline{\mathbf{I}}} \right) \overline{\overline{\mathbf{A}}} \right)^{-1}$$

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = \sigma^2 \left( \overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{A}}} \right)^{-1}$$

Veja que a matriz de covariância dos parâmetros do estimador  $\hat{\mathbf{p}}$  dos MQP no caso particular em que  $\text{COV}\{\bar{\varepsilon}\} = \overline{\mathbf{W}}^{-1} = \sigma^2 \overline{\mathbf{I}}$  é exatamente igual a matriz de covariância dos parâmetros do estimador  $\hat{\mathbf{p}}$  dos MQ, portanto não há melhoria significativa com a introdução da matriz peso da variância dos ruídos com relação a estabilidade da solução estimada. A pequena melhoria que poderá ocorrer NÃO é devido a estabilização da solução, mas devido a um processo semelhante a escolha das observações com maior razão sinal/ruído.

### **Papel dos Pesos nos Mínimos Quadrados Ponderados:**

No método dos Mínimos Quadrados Ponderados (MQP) a matriz diagonal  $\overline{\mathbf{W}} \in R^{N \times N}$  define a contribuição relativa de cada erro individual ao erro total estimado. Para observações mais precisas desejamos um ajuste melhor, ou seja, desejamos que os erros  $\varepsilon_i$  sejam menores. Como minimizaremos a soma dos quadrados dos erros ponderados, i.e.,  $\min\{\varepsilon_1^2 w_1 + \dots + \varepsilon_N^2 w_N\}$ , se atribuirmos para a i-ésima observação um peso  $w_i$  grande para minimizar  $Q = \sum_{i=1}^N \varepsilon_i^2 w_i$  o erro  $\varepsilon_i$  deverá ser pequeno implicando um melhor ajuste. Por outro lado, se atribuirmos para a i-ésima observação um peso  $w_i$  pequeno para minimizar  $Q = \sum_{i=1}^N \varepsilon_i^2 w_i$  o erro  $\varepsilon_i$  poderá ser grande implicando um pior ajuste.

Em resumo, desejamos que o erro  $\varepsilon_i$  das observações mais precisas e menos precisas tenham um peso grande e um peso pequeno, respectivamente, na quantificação do erro total.