

## SVD: Decomposição em Valores Singulares


### Autovalores (eigenvalues) e Autovetores (eigenvectors):

Considere um sistema linear do tipo:

$$\bar{\mathbf{y}} = \bar{\mathbf{A}} \bar{\mathbf{b}}, \quad (1)$$

em que  $\bar{\mathbf{A}}$  é uma matriz arbitrária  $N \times N$  que transforma o vetor  $\bar{\mathbf{b}}$  de dimensão  $N$  no vetor  $\bar{\mathbf{y}}$  também de dimensão  $N$ . Vamos considerar que o nosso objetivo seja resolver este sistema linear sendo que o vetor  $\bar{\mathbf{y}}$  é o vetor contendo os dados conhecidos e o nosso problema consiste em achar o vetor  $\bar{\mathbf{b}}$ . No entanto, nesta seção nós não iremos nos preocupar com nenhum método para a solução deste sistema, ao contrário iremos nos concentrar no estudo das propriedades básicas deste sistema.

Considerando que  $\bar{\mathbf{A}}$  é uma matriz arbitrária  $N \times N$  e  $\bar{\mathbf{x}}$  um vetor em  $\mathbb{R}^n$ , então geralmente não há uma relação geométrica comum entre o vetor  $\bar{\mathbf{x}}$  e o vetor  $\bar{\mathbf{A}}\bar{\mathbf{x}}$  (Figura 1a). No entanto, há geralmente certos vetores  $\bar{\mathbf{x}}$  tal que  $\bar{\mathbf{x}}$  e  $\bar{\mathbf{A}}\bar{\mathbf{x}}$  são múltiplos escalares de um no outro (Figura 1b).




**DEFINIÇÃO:** se  $\overline{\overline{\mathbf{A}}}$  é uma matriz arbitrária  $N \times N$ , então um vetor não nulo  $\overline{\mathbf{x}}$  em  $\mathbb{R}^n$  é chamado **autovetor (eigenvector)** de  $\overline{\overline{\mathbf{A}}}$  se o vetor  $\overline{\overline{\mathbf{A}}}\overline{\mathbf{x}}$  é um escalar múltiplo do vetor  $\overline{\mathbf{x}}$ , ou seja,

$$\overline{\overline{\mathbf{A}}}\overline{\mathbf{x}} = \lambda \overline{\mathbf{x}} \quad (2)$$

para algum escalar  $\lambda$ . O escalar  $\lambda$  é chamado de **autovalor (eigenvalue)** de  $\overline{\overline{\mathbf{A}}}$ , e  $\overline{\mathbf{x}}$  é o autovetor de  $\overline{\overline{\mathbf{A}}}$  correspondente (associado) ao autovalor  $\lambda$ .

Autovalores e autovetores têm uma interpretação geométrica em  $\mathbb{R}^2$ . Se o escalar  $\lambda$  é o autovalor de  $\overline{\overline{\mathbf{A}}}$  correspondente ao autovetor  $\overline{\mathbf{x}}$ , então dependendo do valor do autovalor  $\lambda$ , a multiplicação por  $\overline{\overline{\mathbf{A}}}$  levará a uma dilatação, contração ou mudança de direção de  $\overline{\mathbf{x}}$  (Figura 2).



Para acharmos os autovalores da matriz  $\overline{\overline{\mathbf{A}}}$  ( $N \times N$ ) temos que escrever a equação

$$\overline{\overline{\mathbf{A}}}\overline{\mathbf{x}} = \lambda \overline{\mathbf{x}} \text{ como :}$$

$$\overline{\overline{\mathbf{A}}}\overline{\mathbf{x}} = \lambda \overline{\mathbf{I}} \overline{\mathbf{x}} \quad (3)$$

ou seja:

$$\left( \overline{\overline{\mathbf{A}}} - \lambda \overline{\mathbf{I}} \right) \overline{\mathbf{x}} = \overline{\mathbf{0}} \quad (4)$$

Para  $\lambda$  ser um autovalor deve existir uma solução não nula para esta equação, ou seja, deve existir uma solução não trivial  $\bar{\mathbf{x}} \neq \bar{\mathbf{0}}$  que satisfaça esta equação homogênea. Uma solução não trivial ( $\bar{\mathbf{x}} \neq \bar{\mathbf{0}}$ ) para esta equação homogênea ocorre se a matriz  $\left( \bar{\bar{\mathbf{A}}} - \lambda \bar{\bar{\mathbf{I}}} \right)$  for singular e isto ocorre se e somente se

$$\text{DET} \left( \bar{\bar{\mathbf{A}}} - \lambda \bar{\bar{\mathbf{I}}} \right) = 0 \quad (5)$$

Esta equação acima é chamada de **equação característica** de  $\bar{\bar{\mathbf{A}}}$ ; os escalares que satisfazem a esta equação são os autovalores de  $\bar{\bar{\mathbf{A}}}$ . Os autovalores de  $\bar{\bar{\mathbf{A}}}$  devem satisfazer ao polinômio de ordem N chamado de **polinômio característico** em que o coeficiente de  $\lambda^N$  é 1 e tem a seguinte forma:

$$\text{DET}(\lambda \bar{\bar{\mathbf{I}}} - \bar{\bar{\mathbf{A}}}) = \lambda^N + c_1 \lambda^{N-1} + \dots + c_N = 0 \quad (6)$$

**Teorema:** Se a matriz  $\bar{\bar{\mathbf{A}}} \in R^{N \times N}$  tem N autovalores distintos ( $\lambda_1, \dots, \lambda_N$ ) então existe um conjunto LI (linearmente independente) de N autovetores ( $x_1, \dots, x_N$ ).

### Auto-Sistemas

Se a matriz  $\bar{\bar{\mathbf{A}}} \in R^{N \times N}$  tem N autovalores distintos ( $\lambda_1, \dots, \lambda_N$ ) então existe um conjunto LI (linearmente independente) de N autovetores ( $\bar{\mathbf{x}}_1, \dots, \bar{\mathbf{x}}_N$ ), sendo que cada autovetor está associado a um autovalor, levando as seguintes equações;

$$\bar{\bar{\mathbf{A}}} \bar{\mathbf{x}}_1 = \lambda_1 \bar{\mathbf{x}}_1, \quad \bar{\bar{\mathbf{A}}} \bar{\mathbf{x}}_2 = \lambda_2 \bar{\mathbf{x}}_2, \quad \dots, \quad \bar{\bar{\mathbf{A}}} \bar{\mathbf{x}}_N = \lambda_N \bar{\mathbf{x}}_N.$$

Das equações acima  $\bar{\bar{\mathbf{A}}} \bar{\mathbf{x}}_i = \lambda_i \bar{\mathbf{x}}_i$ , para  $1 \leq i \leq N$  obtemos a seguinte forma compacta:

$$\left[ \bar{\bar{\mathbf{A}}} \bar{\mathbf{x}}_1, \bar{\bar{\mathbf{A}}} \bar{\mathbf{x}}_2, \dots, \bar{\bar{\mathbf{A}}} \bar{\mathbf{x}}_N \right] = \left[ \lambda_1 \bar{\mathbf{x}}_1, \lambda_2 \bar{\mathbf{x}}_2, \dots, \lambda_N \bar{\mathbf{x}}_N \right]$$

$$\overline{\overline{\mathbf{A}}} \begin{bmatrix} \overline{\mathbf{x}}_1 & \overline{\mathbf{x}}_2 & \dots & \overline{\mathbf{x}}_N \end{bmatrix} = \begin{bmatrix} \overline{\mathbf{x}}_1 & \overline{\mathbf{x}}_2 & \dots & \overline{\mathbf{x}}_N \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 & 0 & 0 \\ 0 & \lambda_2 & 0 & 0 \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & 0 & \lambda_N \end{bmatrix}$$

Para escrever de uma forma mais compacta, façamos

$$\overline{\overline{\mathbf{P}}} = \begin{bmatrix} \overline{\mathbf{x}}_1 & \overline{\mathbf{x}}_2 & \dots & \overline{\mathbf{x}}_N \end{bmatrix} \text{ e } \overline{\overline{\mathbf{\Lambda}}} = \begin{bmatrix} \lambda_1 & 0 & 0 & 0 \\ 0 & \lambda_2 & 0 & 0 \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & 0 & \lambda_N \end{bmatrix}$$

Desta forma a equação  $\begin{bmatrix} \overline{\overline{\mathbf{A}}} \overline{\mathbf{x}}_1, \overline{\overline{\mathbf{A}}} \overline{\mathbf{x}}_2, \dots, \overline{\overline{\mathbf{A}}} \overline{\mathbf{x}}_N \end{bmatrix} = \begin{bmatrix} \lambda_1 \overline{\mathbf{x}}_1, \lambda_2 \overline{\mathbf{x}}_2, \dots, \lambda_N \overline{\mathbf{x}}_N \end{bmatrix}$  pode ser escrita como:

$$\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{P}}} = \overline{\overline{\mathbf{P}}} \overline{\overline{\mathbf{\Lambda}}}$$

Note que é  $\overline{\overline{\mathbf{P}}}$  uma matriz  $N \times N$  cujas colunas são os autovetores da matriz  $\overline{\overline{\mathbf{A}}}$  como consideramos que há  $N$  autovalores distintos  $(\lambda_1, \dots, \lambda_N)$  então existe um conjunto LI de  $N$  autovetores de  $\overline{\overline{\mathbf{A}}}$ . Como o conjunto de colunas de  $\overline{\overline{\mathbf{P}}}$  é LI, então ela é Não-Singular (i.e., inversível); portanto pós-multiplicando os dois lados da equação acima por  $\overline{\overline{\mathbf{P}}}^{-1}$  temos:

$$\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{P}}} \overline{\overline{\mathbf{P}}}^{-1} = \overline{\overline{\mathbf{P}}} \overline{\overline{\mathbf{\Lambda}}} \overline{\overline{\mathbf{P}}}^{-1}$$

$$\overline{\overline{\mathbf{A}}} = \overline{\overline{\mathbf{P}}} \overline{\overline{\mathbf{\Lambda}}} \overline{\overline{\mathbf{P}}}^{-1}$$

Assim, a existência de  $N$  autovalores distintos  $(\lambda_1, \dots, \lambda_N)$  da matriz  $\overline{\overline{\mathbf{A}}} \in R^{N \times N}$  leva a existência de um conjunto LI de  $N$  autovetores  $(\overline{\mathbf{x}}_1, \dots, \overline{\mathbf{x}}_N)$  que formam os vetores colunas de uma matriz  $\overline{\overline{\mathbf{P}}} \in R^{N \times N}$ , permitindo decompor a matriz por um tipo especial de produto  $\overline{\overline{\mathbf{A}}} = \overline{\overline{\mathbf{P}}} \overline{\overline{\mathbf{\Lambda}}} \overline{\overline{\mathbf{P}}}^{-1}$

**Teorema:** Uma matriz  $\overline{\overline{\mathbf{A}}} \in R^{N \times N}$  tem conjunto LI de N autovalores se somente existe uma matriz não singular  $\overline{\overline{\mathbf{P}}} \in R^{N \times N}$  e uma matriz diagonal  $\overline{\overline{\mathbf{\Lambda}}}$  para a qual

$$\overline{\overline{\mathbf{A}}} = \overline{\overline{\mathbf{P}}} \overline{\overline{\mathbf{\Lambda}}} \overline{\overline{\mathbf{P}}}^{-1}.$$

As colunas da matriz  $\overline{\overline{\mathbf{P}}} = [\overline{\overline{\mathbf{x}}}_1 \ \overline{\overline{\mathbf{x}}}_2 \ \dots \ \overline{\overline{\mathbf{x}}}_N]$  são os autovetores de  $\overline{\overline{\mathbf{A}}}$  associados respectivamente com os autovalores  $\lambda_i$ , onde  $\lambda_i$  é o (i,i)-ésimo elemento da matriz diagonal  $\overline{\overline{\mathbf{\Lambda}}}$ .

**Teorema:** Se a matriz  $\overline{\overline{\mathbf{A}}} \in R^{N \times N}$  é real e simétrica<sup>1</sup>, então  $\overline{\overline{\mathbf{A}}}$  pode ser decomposta como

$$\overline{\overline{\mathbf{A}}} = \overline{\overline{\mathbf{Q}}} \overline{\overline{\mathbf{\Lambda}}} \overline{\overline{\mathbf{Q}}}^T$$

em que  $\overline{\overline{\mathbf{Q}}}$  é uma matriz real orthogonal<sup>2</sup> cujas colunas são os autovetores de  $\overline{\overline{\mathbf{A}}}$  e  $\overline{\overline{\mathbf{\Lambda}}}$  é uma matriz real diagonal dos autovalores de  $\overline{\overline{\mathbf{A}}}$ .

**Uma Informação:**

No MATLAB há um commando “ eig ” que pode fornecer os autovalores e autovetores de uma matriz quadrada qualquer. Digite no matlab “help eig” para obter informações sobre este comando. Veja um exemplo

```
» a=[4 0 ; 0 4]
```

```
a = 4    0
```

```
    0    4
```

```
» [P,S]=eig(a)
```

```
P = 1    0
```

```
    0    1
```

```
S = 4    0
```

```
    0    4
```

Neste exemplo acima a matriz é a variável “a” os autovetores são as colunas da matriz P e os valores singulares estão na diagonal da matriz S

---


<sup>1</sup> Matriz simétrica é uma matriz quadrada tal que  $\overline{\overline{\mathbf{A}}}^T = \overline{\overline{\mathbf{A}}}$ .

## **Interpretação Geométrica de autovalor e autovetor:**

Considere a matriz simétrica

$$\overline{\overline{\mathbf{A}}} = \begin{bmatrix} 4 & 8 \\ 8 & 4 \end{bmatrix}$$

Esta matriz simétrica pode ser interpretada como uma matriz de dados em estatística, em que as colunas representam variáveis e as linhas representam observações. Assim o conteúdo de informação desta matriz pode ser visualizado geometricamente em  $\mathbb{R}^2$  (e também em  $\mathbb{R}^3$  matriz 3 x 3), representando-se as observações num espaço definido por eixos de variáveis (ou vice-versa):



Assim os pontos A (vermelho) e B (azul) representam as duas observações (linhas da matriz) num espaço de duas variáveis (colunas da matriz)

Os autovalores da matriz  $\overline{\overline{\mathbf{A}}}$  são dados resolvendo-se a equação característica. Assim temos que

$$\text{DET} \begin{bmatrix} 4 - \lambda & 8 \\ 8 & 4 - \lambda \end{bmatrix} = (4 - \lambda)^2 - 64 = 0$$

Portanto a equação característica de  $\overline{\overline{\mathbf{A}}}$  é:

---

<sup>2</sup> Uma matriz quadrada  $\overline{\overline{\mathbf{Q}}} \in \mathbb{R}^{N \times N}$  é ortogonal se  $\overline{\overline{\mathbf{Q}}}^T \overline{\overline{\mathbf{Q}}} = \overline{\overline{\mathbf{Q}}} \overline{\overline{\mathbf{Q}}}^T = \overline{\overline{\mathbf{I}}}_N$ , logo  $\overline{\overline{\mathbf{Q}}}^{-1} = \overline{\overline{\mathbf{Q}}}^T$

*Curso de Inversão de Dados Geofísicos*  
*Programa de Pós-graduação em Geofísica do ON*

$$\lambda^2 - 8\lambda - 48 = 0$$

A solução desta equação são  $\lambda_1 = 12$  e  $\lambda_2 = -4$ ; estes são os autovalores da matriz  $\bar{\bar{A}}$ .

Por definição temos que  $(\lambda \bar{\bar{I}} - \bar{\bar{A}})\bar{x} = \bar{0}$  portanto os autovetores respectivos são:


$$\begin{bmatrix} 4 - \lambda_1 & 8 \\ 8 & 4 - \lambda_1 \end{bmatrix} \begin{bmatrix} x_{11} \\ x_{12} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Tomando-se  $\lambda_1 = 12$ , assim temos o vetor normalizado  $\bar{x}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$  e

$$\begin{bmatrix} 4 - \lambda_2 & 8 \\ 8 & 4 - \lambda_2 \end{bmatrix} \begin{bmatrix} x_{21} \\ x_{22} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Tomando-se  $\lambda_2 = -4$ , assim temos o vetor normalizado  $\bar{x}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$ .

Introduzindo-se os autovetores e autovalores no gráfico acima temos:



Vemos que os autovetores tomados com módulos iguais ao valores absolutos dos respectivos autovalores caracterizam uma elipse com centro na origem e que passa

pelos pontos A e B. A forma elíptica indica a existência de um autovalor próximo a zero. Mas o que significa um autovalor próximo de zero ? Ou ainda. O que significa um autovalor igual a zero ? Veremos, a seguir, que na direção do autovetor associado a este autovalor próximo a zero há um mal-condicionamento do sistema, ou seja, há uma dependência linear.


Vamos considerar agora dois casos extremos:

CASO (a) - Neste primeiro caso temos

$$\overline{\overline{\mathbf{A}}} = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}$$

Neste primeiro caso os autovalores são  $\lambda_1 = 4$  e  $\lambda_2 = 4$  ; e os autovetores da matriz  $\overline{\overline{\mathbf{A}}}$  associada a estes autovalores são indeterminados: quaisquer dos vetores satisfazem a equação  $(\lambda \overline{\overline{\mathbf{I}}} - \overline{\overline{\mathbf{A}}}) \overline{\mathbf{x}} = \overline{\mathbf{0}}$ .

Graficamente podemos constatar que este caso representa uma situação ideal em que as observações A e B são o mais diferentes possível (são informações não redundantes) e os autovalores são idênticos.





A forma circular indica uma independência linear do sistema.


CASO (b) - O segundo caso extremo temos:

$$\overline{\mathbf{A}} = \begin{bmatrix} 4 & 4 \\ 4 & 4 \end{bmatrix}$$

Neste segundo caso os autovalores são  $\lambda_1 = 8$  e  $\lambda_2 = 0$ ; e os autovetores da matriz

$\overline{\mathbf{A}}$  associada a estes autovalores são  $\bar{\mathbf{x}}1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$  e  $\bar{\mathbf{x}}2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$ .

Graficamente podemos constatar que as observações são idênticas (redundantes), ou seja a observação A é idêntica a observação B = (4,4).



Concluimos que o caso (a) representa uma situação ideal: as observações A e B são o mais diferente possível e os autovalores são valores idênticos. Note que neste número de condição (razão entre o maior e menor valor singular) é igual a 1. No caso (b), ao contrário, as observações A e B são idênticas (redundantes), neste caso o número de condição tende para o infinito (razão extrema).

Os três casos que estudados podem ser sintetizados de acordo com o número de condição <sup>3</sup>:

	$COND =  \lambda_1  /  \lambda_2 ,  \lambda_1  >  \lambda_2 $
Observações completamente independentes	$COND = 4 / 4 = 1$
Observações parcialmente independentes	$COND = 12 / 4 = 3$
Observações redundantes	$COND = 8 / 0 = \infty$

Note que a presença de um autovalor NULO ou muito próximo a zero aumenta a razão (em valor absoluto) entre os módulos dos autovalores extremos e indica observações redundantes.

Podemos constatar que um autovalor nulo ou muito próximo de zero é um medidor da não unicidade e da instabilidade, respectivamente, já que a redundância de observações leva a problema subdeterminado, contendo mais incógnitas do que observações (equações), e caracterizando portanto uma demanda de informação maior que aquela contida nos dados observados **problema mal-posto**.

**Então, para caracterizarmos se um problema é mal-posto, basta então analisarmos os autovalores da matriz associada com o sistema linear correspondente.**

Vale lembrar que para determinarmos os autovalores e autovetores a matriz arbitrária  $\bar{\bar{A}}$  é obrigatoriamente quadrada de dimensão  $N \times N$ . Infelizmente, a análise acima não pode ser aplicada diretamente porque em geral o número de observações difere do número de parâmetros (incógnitas), de modo que os autovalores e os autovetores de matriz não quadrada ( $N \times M$ ) não são definidos. Veremos abaixo como este problema é contornado.

---

<sup>3</sup> Numero de condição de uma matriz  $\bar{\bar{A}} (N \times N)$  é dado pela razão entre o módulo do maior autovalor ( $|\lambda_{\max}|$ ) e o módulo do menor autovalor ( $|\lambda_{\min}|$ ) da matriz  $\bar{\bar{A}}$ , i.e., o numero de condição da matriz  $\bar{\bar{A}}$  é  $cond = \frac{|\lambda_{\max}|}{|\lambda_{\min}|}$

## Decomposição em Valores Singulares

### Sistema linear Arbitrário:

Agora iremos investigar um sistema linear arbitrário  $N \times M$

$$\bar{\mathbf{y}} = \bar{\bar{\mathbf{A}}} \bar{\mathbf{p}}, \quad (7)$$

em  $\bar{\bar{\mathbf{A}}}$  é uma matriz arbitrária  $N \times M$ , o vetor  $\bar{\mathbf{p}}$  de dimensão  $M$  e o vetor  $\bar{\mathbf{y}}$  de dimensão  $N$ . Portanto a matriz  $\bar{\bar{\mathbf{A}}}$  transforma o vetor  $\bar{\mathbf{p}}$  de dimensão  $M$  no vetor  $\bar{\mathbf{y}}$  de dimensão  $N$ . É evidente que a matriz  $\bar{\bar{\mathbf{A}}}$  está associada com dois espaços em que um é de  $N$  dimensão e o outro de  $M$  dimensão. Se o vetor  $\bar{\mathbf{p}}$  do espaço  $M$ -dimensional é dado, o operador  $\bar{\bar{\mathbf{A}}}$  opera e o transplanta dentro do espaço  $N$ -dimensional. Por outro lado, se o nosso objetivo é resolver este sistema linear, em que foi nos dado o vetor  $\bar{\mathbf{y}}$  do espaço  $N$ -dimensional (vetor contendo os dados geofísicos), então o nosso problema consiste em achar o vetor  $\bar{\mathbf{p}}$  do espaço  $M$ -dimensional que o produza por meio do operador  $\bar{\bar{\mathbf{A}}}$ . No entanto, nesta seção nós também não iremos nos preocupar com nenhum método para a solução deste sistema, ao contrário iremos nos concentrar no estudo das propriedades básicas deste sistema

A idéia central que será a base para toda as nossas discussões do comportamento do operador linear é a seguinte. Nós não consideraremos o sistema linear  $\bar{\mathbf{y}} = \bar{\bar{\mathbf{A}}} \bar{\mathbf{p}}$  isoladamente mas expandido pelo sistema adjunto ( $M \times N$ )

$$\bar{\bar{\mathbf{A}}}^T \bar{\mathbf{q}} = \bar{\mathbf{x}} \quad (8)$$

A matriz  $\bar{\bar{\mathbf{A}}}^T$  tem  $M$  linhas e  $N$  colunas ( $M \times N$ ) e adequadamente os vetores  $\bar{\mathbf{q}}$  e  $\bar{\mathbf{x}}$  estão em uma relação de reciprocidade (intercâmbio) com os vetores  $\bar{\mathbf{p}}$  e  $\bar{\mathbf{y}}$ . Concretamente,  $\bar{\mathbf{y}}$  e  $\bar{\mathbf{q}}$  são vetores que pertencem ao espaço  $N$ -dimensional, enquanto  $\bar{\mathbf{p}}$  e  $\bar{\mathbf{x}}$  são vetores que pertencem ao espaço  $M$ -dimensional.

Tomaremos o sistema adjunto  $\overline{\overline{\mathbf{A}}}^T \overline{\mathbf{q}} = \overline{\mathbf{x}}$  como um sistema auxiliar para formarmos um sistema aumentado. Assim combinaremos o sistema

$\overline{\overline{\mathbf{A}}}^T \overline{\mathbf{q}} = \overline{\mathbf{x}}$  com o sistema  $\overline{\overline{\mathbf{A}}} \overline{\mathbf{p}} = \overline{\mathbf{y}}$  dentro do esquema aumentado:

$$\overline{\overline{\mathbf{T}}} \overline{\mathbf{z}} = \overline{\mathbf{a}} \quad (9)$$

em que introduzimos uma nova matriz quadrada  $\overline{\overline{\mathbf{T}}}$  de dimensões ( N+M X N+M ) e definida como segue:

$$\overline{\overline{\mathbf{T}}} = \frac{N}{M} \begin{bmatrix} \overline{\overline{\mathbf{0}}} & \overline{\overline{\mathbf{A}}} \\ \overline{\overline{\mathbf{A}}}^T & \overline{\overline{\mathbf{0}}} \end{bmatrix} \quad (10)$$

N          M

$$\overline{\mathbf{z}} = \frac{N}{M} \begin{bmatrix} \overline{\mathbf{q}} \\ \overline{\mathbf{p}} \end{bmatrix} \quad (11)$$

e

$$\overline{\mathbf{a}} = \frac{N}{M} \begin{bmatrix} \overline{\mathbf{y}} \\ \overline{\mathbf{x}} \end{bmatrix} \quad (12)$$

O sistema linear pode ser então definido como

$$\begin{array}{c} \text{N} \\ \text{M} \end{array} \left\{ \begin{array}{c} \overbrace{\left[ \begin{array}{cc} \overline{\overline{\mathbf{0}}} & \overline{\overline{\mathbf{A}}} \end{array} \right]}^{\text{N}} \\ \underbrace{\left[ \begin{array}{cc} \overline{\overline{\mathbf{A}}}^T & \overline{\overline{\mathbf{0}}} \end{array} \right]}_{\text{M}} \end{array} \right\} \begin{array}{c} \text{N} \\ \text{M} \end{array} \left\{ \begin{array}{c} \overline{\mathbf{q}} \\ \overline{\mathbf{p}} \end{array} \right\} = \begin{array}{c} \text{N} \\ \text{M} \end{array} \left\{ \begin{array}{c} \overline{\mathbf{y}} \\ \overline{\mathbf{x}} \end{array} \right\}$$

isto é no sistema:

$$\begin{bmatrix} \overline{\mathbf{0}} & \overline{\mathbf{A}} \\ \overline{\mathbf{A}}^T & \overline{\mathbf{0}} \end{bmatrix} \begin{bmatrix} \overline{\mathbf{q}} \\ \overline{\mathbf{p}} \end{bmatrix} = \begin{bmatrix} \overline{\mathbf{y}} \\ \overline{\mathbf{x}} \end{bmatrix}$$

Vale ressaltar que o sistema adjunto  $\overline{\mathbf{A}}^T \overline{\mathbf{q}} = \overline{\mathbf{x}}$  não exerce nenhum efeito no sistema linear principal  $\overline{\mathbf{A}} \overline{\mathbf{p}} = \overline{\mathbf{y}}$ . Assim os vetores  $\overline{\mathbf{q}}$  e  $\overline{\mathbf{x}}$  são completamente independente dos vetores  $\overline{\mathbf{p}}$  e  $\overline{\mathbf{y}}$ , e vice-versa. Porém a adição do sistema adjunto ao sistema linear principal amplia o nosso conhecimento sobre as propriedades do sistema linear arbitrário  $N \times M$ .

Como a matriz  $\overline{\mathbf{T}}$  é quadrada podemos definir agora seus autovalores e autovetores. Para tanto vamos tomar a equação fundamental dos autovalores

$$\overline{\mathbf{T}} \overline{\mathbf{w}} = s \overline{\mathbf{w}} \quad (13)$$

ou seja,

$$(\overline{\mathbf{T}} - s \overline{\mathbf{I}}) \overline{\mathbf{w}} = \overline{\mathbf{0}} \quad (14)$$

Em vista das características da nossa matriz  $\overline{\mathbf{T}}$  de dimensões  $(N+M \times N+M)$  o vetor  $\overline{\mathbf{w}}$  é um vetor de dimensão  $N+M$ . Vamos considerar então que o vetor  $\overline{\mathbf{w}}$  seja particionado nos vetores  $\overline{\mathbf{u}}$  e  $\overline{\mathbf{v}}$  de dimensões  $N$  e  $M$ , respectivamente

$$\overline{\mathbf{w}}_{(N+M \times 1)} = \frac{N}{M} \left\{ \begin{array}{c} \overline{\mathbf{u}} \\ \overline{\mathbf{v}} \end{array} \right\}$$

$$\overline{\mathbf{w}} = \frac{N}{M} \begin{bmatrix} \overline{\mathbf{u}} \\ \overline{\mathbf{v}} \end{bmatrix}$$

Então o sistema  $\overline{\mathbf{T}} \overline{\mathbf{w}} = s \overline{\mathbf{w}}$  pode ser desdobrado na seguinte forma:

$$\begin{cases} \overline{\mathbf{A}} \overline{\mathbf{v}} = s \overline{\mathbf{u}} \\ \overline{\mathbf{A}}^T \overline{\mathbf{u}} = s \overline{\mathbf{v}} \end{cases} \quad (15)$$

Este par de equações chamaremos de “problema de autovalor deslocado” uma vez que os vetores do lado direito  $\overline{\mathbf{u}}$  e  $\overline{\mathbf{v}}$  estão deslocados quando comparando com o problema de autovalor já estudado em que temos  $\overline{\mathbf{A}} \overline{\mathbf{x}} = \lambda \overline{\mathbf{x}}$ .

Vamos então pré multiplicar a primeira equação do sistema acima por  $\overline{\mathbf{A}}^T$  e a segunda equação por  $\overline{\mathbf{A}}$ . Temos então o seguinte sistema

$$\begin{cases} \overline{\mathbf{A}}^T \overline{\mathbf{A}} \overline{\mathbf{v}} = s \overline{\mathbf{A}}^T \overline{\mathbf{u}} \\ \overline{\mathbf{A}} \overline{\mathbf{A}}^T \overline{\mathbf{u}} = s \overline{\mathbf{A}} \overline{\mathbf{v}} \end{cases} \quad (16)$$

Da primeira equação do sistema (15) temos que  $\overline{\mathbf{A}} \overline{\mathbf{v}} = s \overline{\mathbf{u}}$ . Substituindo na segunda equação do sistema (16) temos que

$$\overline{\mathbf{A}} \overline{\mathbf{A}}^T \overline{\mathbf{u}} = s^2 \overline{\mathbf{u}} \quad (17)$$

Da segunda equação do sistema (15) temos que  $\overline{\mathbf{A}}^T \overline{\mathbf{u}} = s \overline{\mathbf{v}}$ . Substituindo na primeira equação do sistema (16) temos que

$$\overline{\mathbf{A}}^T \overline{\mathbf{A}} \overline{\mathbf{v}} = s^2 \overline{\mathbf{v}} \quad (18)$$

As equações (17) e (18) definem dois problemas de autovalores-autovetores. O

primeiro problema é associado a matriz simétrica  $N \times N$   $\overline{\mathbf{A}} \overline{\mathbf{A}}^T$  e o segundo problema está associado a matriz  $M \times M$   $\overline{\mathbf{A}}^T \overline{\mathbf{A}}$ , ambos problemas com os mesmos

autovalores não nulos  $s^2$ . Os vetores  $\bar{\mathbf{u}}$  e  $\bar{\mathbf{v}}$  são, respectivamente, os autovetores de  $\bar{\mathbf{A}}\bar{\mathbf{A}}^T$  e  $\bar{\mathbf{A}}^T\bar{\mathbf{A}}$ , portanto são vetores ortogonais que geram, respectivamente espaços de N e M dimensões.

Existirão, no máximo, min (M,N) autovalores diferentes de zero, todos os outros autovalores serão nulos. Assim se  $N > M$  a equação (18) comportará M autovalores que poderão ser diferentes de zero. Por outro lado, a equação (17) comportará os mesmos M autovalores que poderão ser diferentes de zero e também comportará  $N - M$  autovalores nulos. As mesmas observações se aplicam, mutatis mutandis, para o caso  $M > N$ .

Presumindo, sem perda da generalidade, que  $N > M$  a primeira equação do sistema (15) aplicado a cada par de autovalor-autovetor leva ao sistema:

$$\left\{ \begin{array}{l} \bar{\mathbf{A}} \bar{\mathbf{v}}_1 = s_1 \bar{\mathbf{u}}_1 \\ \bar{\mathbf{A}} \bar{\mathbf{v}}_2 = s_2 \bar{\mathbf{u}}_2 \\ \bullet \\ \bullet \\ \bullet \\ \bar{\mathbf{A}} \bar{\mathbf{v}}_M = s_M \bar{\mathbf{u}}_M \end{array} \right. \quad (19)$$

Em notação matricial podemos escrever o sistema acima como:

$$\bar{\mathbf{A}} \begin{bmatrix} \bar{\mathbf{v}}_1 & \bar{\mathbf{v}}_2 & \dots & \bar{\mathbf{v}}_M \end{bmatrix} = \begin{bmatrix} s_1 \bar{\mathbf{u}}_1 & s_2 \bar{\mathbf{u}}_2 & \dots & s_M \bar{\mathbf{u}}_M \end{bmatrix} \quad (20)$$

ou ainda

$$\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{V}}} = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1M} & u_{1M+1} & \cdots & u_{1N} \\ u_{21} & u_{22} & \cdots & u_{2M} & u_{2M+1} & \cdots & u_{2N} \\ \vdots & \vdots & & & \vdots & & \\ u_{N1} & u_{N2} & \cdots & u_{NM} & u_{NM+1} & \cdots & u_{NN} \end{bmatrix} \begin{bmatrix} s_1 \\ s_2 \\ \ddots \\ s_M \\ \overline{0} \end{bmatrix}$$

Veja na Figura abaixo o mesmo sistema linear de equações (19) em sua forma matricial dado pela equação (20). Nesta Figura destacamos a relação dos M autovalores diferentes de zero  $[s_1, s_2, \dots, s_M]$  e os M autovetores  $[\overline{u}_1, \overline{u}_2, \dots, \overline{u}_M]$ . Note neste caso particular, em que  $N > M$  que há  $N-M$  autovetores que  $[\overline{u}_{M+1}, \overline{u}_{M+2}, \dots, \overline{u}_N]$  associados com  $N-M$  autovalores iguais a de zero

**Sem perda de generalidade, considere  $N > M$ . Então existirão no máximo M autovalores diferentes de zero**

$$\overline{\overline{\mathbf{A}}} \begin{bmatrix} \overline{\mathbf{v}}_1 & \overline{\mathbf{v}}_2 & \cdots & \overline{\mathbf{v}}_M \end{bmatrix} = \begin{bmatrix} s_1 \overline{\mathbf{u}}_1 & s_2 \overline{\mathbf{u}}_2 & \cdots & s_M \overline{\mathbf{u}}_M \end{bmatrix}$$

The diagram illustrates the matrix equation and the relationship between dimensions  $M$ ,  $N-M$ , and  $N$ . The matrix  $\overline{\overline{\mathbf{A}}}$  is partitioned into two blocks: a top block of size  $M \times M$  (yellow) and a bottom block of size  $(N-M) \times M$  (grey). The top block contains the singular values  $s_1, s_2, \dots, s_M$ . The bottom block contains zeros. The vector  $\overline{\mathbf{v}}$  is partitioned into two blocks: a top block of size  $M$  (yellow) and a bottom block of size  $N-M$  (grey). The vector  $\overline{\mathbf{u}}$  is partitioned into two blocks: a top block of size  $M$  (yellow) and a bottom block of size  $N-M$  (grey). The total dimension of the vector  $\overline{\mathbf{v}}$  is  $N$ , and the total dimension of the vector  $\overline{\mathbf{u}}$  is  $N$ . The diagram shows that the first  $M$  components of  $\overline{\mathbf{v}}$  are non-zero, and the remaining  $N-M$  components are zero. The first  $M$  components of  $\overline{\mathbf{u}}$  are non-zero, and the remaining  $N-M$  components are zero.



Finalmente podemos escrever:

$$\overline{\overline{\mathbf{A}}} \quad (N \times M) \quad \overline{\overline{\mathbf{V}}} \quad (M \times M) = \overline{\overline{\mathbf{U}}} \quad (N \times N) \quad \overline{\overline{\mathbf{S}}} \quad (N \times M) \quad (21)$$

as matrizes  $\overline{\overline{\mathbf{U}}}$  e  $\overline{\overline{\mathbf{V}}}$  são definidas como

$$\overline{\overline{\mathbf{V}}} = \begin{bmatrix} \overline{\mathbf{v}_1} & \overline{\mathbf{v}_2} & \dots & \overline{\mathbf{v}_M} \end{bmatrix}$$

e

$$\overline{\overline{\mathbf{U}}} = \begin{bmatrix} \overline{\mathbf{u}_1} & \overline{\mathbf{u}_2} & \dots & \overline{\mathbf{u}_N} \end{bmatrix}$$

Isto é  $\overline{\overline{\mathbf{U}}}$  e  $\overline{\overline{\mathbf{V}}}$  são matrizes cujas colunas são os autovalores de  $\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{A}}}^T$  e  $\overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{A}}}$ , respectivamente. Como os autovetores são ortogonais, concluímos que os conjuntos

$$\begin{bmatrix} \overline{\mathbf{u}_1} & \overline{\mathbf{u}_2} & \dots & \overline{\mathbf{u}_N} \end{bmatrix} \text{ e } \begin{bmatrix} \overline{\mathbf{v}_1} & \overline{\mathbf{v}_2} & \dots & \overline{\mathbf{v}_M} \end{bmatrix} \text{ formam bases ortogonais}$$

que geram os espaços de observações e parâmetros, respectivamente. Assim as

matrizes  $\overline{\overline{\mathbf{U}}}$  e  $\overline{\overline{\mathbf{V}}}$  tendo colunas que são vetores ortogonais, são matrizes ortogonais.

As matrizes  $\overline{\overline{\mathbf{U}}}$  e  $\overline{\overline{\mathbf{V}}}$  são normalizadas de modo que  $\overline{\overline{\mathbf{U}}}$  e  $\overline{\overline{\mathbf{V}}}$  sejam ortonormais, isto é:

$$\overline{\overline{\mathbf{V}}}^T \overline{\overline{\mathbf{V}}} = \overline{\overline{\mathbf{V}}} \overline{\overline{\mathbf{V}}}^T = \overline{\overline{\mathbf{I}}} \quad (M \times M) \quad \text{e}$$

$$\overline{\overline{\mathbf{U}}}^T \overline{\overline{\mathbf{U}}} = \overline{\overline{\mathbf{U}}} \overline{\overline{\mathbf{U}}}^T = \overline{\overline{\mathbf{I}}} \quad (N \times N)$$

Pós multiplicando a equação (21) por  $\overline{\overline{\mathbf{V}}}^T$ :

$$\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{V}}} \overline{\overline{\mathbf{V}}}^T = \overline{\overline{\mathbf{U}}} \overline{\overline{\mathbf{S}}} \overline{\overline{\mathbf{V}}}^T$$

portanto;

$$\overline{\overline{\mathbf{A}}} \quad (N \times M) = \overline{\overline{\mathbf{U}}} \quad (N \times N) \quad \overline{\overline{\mathbf{S}}} \quad (N \times M) \quad \overline{\overline{\mathbf{V}}}^T \quad (M \times M) \quad (22)$$

A equação 22 representa a **DECOMPOSIÇÃO EM VALORES SINGULARES** da matriz  $\overline{\overline{\mathbf{A}}}$ , assim chamada porque os valores  $S_i$  que compõe a diagonal da matriz  $\overline{\overline{\mathbf{S}}}$ , são a raiz quadrada positiva dos autovalores das matrizes  $\overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{A}}}$  ou  $\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{A}}}^T$  e são denominados de **valores singulares** de  $\overline{\overline{\mathbf{A}}}$ .

A importância da decomposição de uma matriz em valores singulares está na obtenção dos valores singulares, cuja análise, como já vimos, permite detectar se um problema é mal-posto quando pelo menos um valor singular for NULO ou PRÓXIMO DE ZERO. Veremos a seguir uma análise detalhada da relação entre a não unicidade e da instabilidade com os valores singulares nulo ou próximo do valor zero.

## SVD da matriz $\overline{\overline{\mathbf{A}}}$ e os r valores singulares não-nulos

Um sistema linear arbitrário N X M

$$\overline{\overline{\mathbf{y}}} = \overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{p}}},$$

sendo  $\overline{\overline{\mathbf{A}}}$  uma matriz arbitrária N x M,  $\overline{\overline{\mathbf{p}}}$  um vetor de dimensão M e  $\overline{\overline{\mathbf{y}}}$  um vetor de dimensão N. A matriz  $\overline{\overline{\mathbf{A}}}$  (matriz de sensibilidade) transforma o vetor  $\overline{\overline{\mathbf{p}}}$  de dimensão M no vetor  $\overline{\overline{\mathbf{y}}}$  de dimensão N e portanto esta matriz está associada com dois espaços diferentes: um espaço N dimensional e o outro M dimensional. Nesta seção iremos nos concentrar em examinar as propriedades da matriz  $\overline{\overline{\mathbf{A}}}$  deste sistema linear e a ferramenta para fazermos esta análise é a decomposição em valores singulares (SVD) da matriz  $\overline{\overline{\mathbf{A}}}$ .

Se  $\overline{\overline{\mathbf{A}}} (M \times N)$  é real a decomposta em:

$$\overline{\overline{\mathbf{A}}} = \overline{\overline{\mathbf{U}}} \overline{\overline{\mathbf{S}}} \overline{\overline{\mathbf{V}}}^T$$

$(N \times M) \quad (N \times N) \quad (N \times M) \quad (M \times M)$

em que  $\bar{\bar{S}}$  é uma matriz diagonal de dimensão  $N \times M$ ,  $\bar{\bar{U}}$  e  $\bar{\bar{V}}$  são matrizes ortogonais<sup>4</sup> de dimensões  $N \times N$  e  $M \times M$ , respectivamente. Esta equação representa a **DECOMPOSIÇÃO EM VALORES SINGULARES (SVD)** da matriz  $\bar{\bar{A}}$ , sendo assim chamada porque os valores  $S_i$  que compõe a diagonal da matriz  $\bar{\bar{S}}$ , são a raiz quadrada positiva dos autovalores das matrizes  $\bar{\bar{A}}^T \bar{\bar{A}}$  ou  $\bar{\bar{A}} \bar{\bar{A}}^T$  e são denominados de **valores singulares** de  $\bar{\bar{A}}$ . As matrizes  $\bar{\bar{U}}$  e  $\bar{\bar{V}}$  são matrizes ortogonais cujas colunas são os autovetores de  $\bar{\bar{A}} \bar{\bar{A}}^T$  e  $\bar{\bar{A}}^T \bar{\bar{A}}$ , respectivamente. Como os autovetores são ortogonais, concluímos que os conjuntos  $\begin{bmatrix} \bar{u}_1 & \bar{u}_2 & \dots & \bar{u}_N \end{bmatrix}$  e  $\begin{bmatrix} \bar{v}_1 & \bar{v}_2 & \dots & \bar{v}_M \end{bmatrix}$  formam bases<sup>5</sup> ortogonais<sup>6</sup> que geram os espaços de observações e parâmetros, respectivamente. Assim,  $\bar{\bar{U}}$  é uma matriz ortogonal ( $N \times N$ ) cujas colunas são bases do espaço  $R^N$  (espaço das observações) e  $\bar{\bar{V}}$  é uma matriz ortogonal ( $M \times M$ ) cujas colunas são bases do espaço  $R^M$  (espaço dos parâmetros). As matrizes  $\bar{\bar{U}}$  e  $\bar{\bar{V}}$  são normalizadas de modo que  $\bar{\bar{U}}$  e  $\bar{\bar{V}}$  sejam ortonormais, isto é:

---

<sup>4</sup> Uma matriz  $\bar{\bar{U}}$  real  $N \times N$  é chamada de matriz ortogonal se  $\bar{\bar{U}}^T \bar{\bar{U}} = \bar{\bar{U}} \bar{\bar{U}}^T = \bar{\bar{I}}$  ( $N \times N$ ). Cada coluna e cada linha de uma matriz ortogonal é um vetor ortonormal, ou seja,  $\bar{u}_i^T \bar{u}_i = 1$  em que  $\bar{u}_i$  é a  $i$ -ésima coluna da matriz ortogonal  $\bar{\bar{U}}$

<sup>5</sup> Base de um espaço vetorial é um conjunto LI de vetores que geram o espaço vetorial

<sup>6</sup> Base ortogonal é uma base contendo vetores ortogonais, ou seja,  $\bar{u}_i^T \bar{u}_k = 0$  em que  $\bar{u}_i$  e  $\bar{u}_k$  são respectivamente a  $i$ -ésima e  $k$ -ésima colunas da matriz ortogonal  $\bar{\bar{U}}$

$$\overline{\overline{\mathbf{V}}}^T \overline{\overline{\mathbf{V}}} = \overline{\overline{\mathbf{V}}} \overline{\overline{\mathbf{V}}}^T = \overline{\overline{\mathbf{I}}}_{(M \times M)} \text{ e}$$

$$\overline{\overline{\mathbf{U}}}^T \overline{\overline{\mathbf{U}}} = \overline{\overline{\mathbf{U}}} \overline{\overline{\mathbf{U}}}^T = \overline{\overline{\mathbf{I}}}_{(N \times N)}$$

A matriz  $\overline{\overline{\mathbf{S}}}$  (N x M) de valores singulares é uma matriz diagonal com valores positivos. Em geral, as rotinas que realizam a SVD de uma matriz N x M, usualmente ordenam de forma decrescente os valores singulares ao longo da diagonal da matriz  $\overline{\overline{\mathbf{S}}}$ , tal que

$$S_1 \geq S_2 \geq \dots \geq S_{\text{Min}(M, N)} \geq 0.$$

Veja que alguns dos valores singulares podem ser ZERO. Vamos supor que temos  $r$  valores singulares não-nulos. Neste caso a matriz  $\overline{\overline{\mathbf{S}}}$  pode ser particionada da seguinte forma:

$$\overline{\overline{\mathbf{S}}}_{(N \times M)} = \begin{bmatrix} \overline{\overline{\mathbf{S}}}_r & \overline{\overline{\mathbf{0}}} \\ \overline{\overline{\mathbf{0}}} & \overline{\overline{\mathbf{0}}} \end{bmatrix}$$

Em que  $\overline{\overline{\mathbf{S}}}_r$  é uma matriz diagonal de dimensão  $r \times r$  composta dos  $r$  valores singulares positivos. Fazendo a decomposição da matriz temos:

$$\overline{\overline{\mathbf{A}}} = \overline{\overline{\mathbf{U}}} \overline{\overline{\mathbf{S}}} \overline{\overline{\mathbf{V}}}^T$$

$$\overline{\overline{\mathbf{A}}} = \overline{\overline{\mathbf{U}}} \begin{bmatrix} \overline{\overline{\mathbf{S}}}_r & \overline{\overline{\mathbf{0}}} \\ \overline{\overline{\mathbf{0}}} & \overline{\overline{\mathbf{0}}} \end{bmatrix} \overline{\overline{\mathbf{V}}}^T$$

$$\bar{\bar{\mathbf{A}}} = \begin{bmatrix} \bar{\mathbf{u}}_1 & \bar{\mathbf{u}}_2 & \cdots & \bar{\mathbf{u}}_r & \cdots & \bar{\mathbf{u}}_N \end{bmatrix} \begin{bmatrix} \bar{\bar{\mathbf{S}}}_r & \bar{\bar{\mathbf{0}}} \\ \bar{\bar{\mathbf{0}}} & \bar{\bar{\mathbf{0}}} \end{bmatrix} \begin{bmatrix} \bar{\mathbf{v}}_1 & \bar{\mathbf{v}}_2 & \cdots & \bar{\mathbf{v}}_r & \cdots & \bar{\mathbf{v}}_M \end{bmatrix}^T$$

Considerando as matrizes particionadas:

$$\bar{\bar{\mathbf{V}}} = \begin{bmatrix} \bar{\bar{\mathbf{V}}}_r & \bar{\bar{\mathbf{V}}}_{M-r} \end{bmatrix}$$

$$\bar{\bar{\mathbf{U}}} = \begin{bmatrix} \bar{\bar{\mathbf{U}}}_r & \bar{\bar{\mathbf{U}}}_{N-r} \end{bmatrix}$$

em que a matriz  $\bar{\bar{\mathbf{U}}}_r = \begin{bmatrix} \bar{\mathbf{u}}_1 & \bar{\mathbf{u}}_2 & \cdots & \bar{\mathbf{u}}_r \end{bmatrix}$  é uma matriz (N x r), a matriz

$\bar{\bar{\mathbf{U}}}_{N-r} = \begin{bmatrix} \bar{\mathbf{u}}_{r+1} & \bar{\mathbf{u}}_{r+2} & \cdots & \bar{\mathbf{u}}_N \end{bmatrix}$  é uma matriz (N x N-r), a matriz

$\bar{\bar{\mathbf{V}}}_r = \begin{bmatrix} \bar{\mathbf{v}}_1 & \bar{\mathbf{v}}_2 & \cdots & \bar{\mathbf{v}}_r \end{bmatrix}$  é uma matriz (M x r) e a matriz

$\bar{\bar{\mathbf{V}}}_{M-r} = \begin{bmatrix} \bar{\mathbf{v}}_{r+1} & \bar{\mathbf{v}}_{r+2} & \cdots & \bar{\mathbf{v}}_M \end{bmatrix}$  é uma matriz (M x M-r), decomposição da

matriz de sensibilidade  $\bar{\bar{\mathbf{A}}} = \bar{\bar{\mathbf{U}}} \bar{\bar{\mathbf{S}}} \bar{\bar{\mathbf{V}}}^T$  pode ser escrita como:

$$\bar{\bar{\mathbf{A}}} = \begin{bmatrix} \bar{\bar{\mathbf{U}}}_r & \bar{\bar{\mathbf{U}}}_{N-r} \end{bmatrix} \begin{bmatrix} \bar{\bar{\mathbf{S}}}_r & \bar{\bar{\mathbf{0}}} \\ \bar{\bar{\mathbf{0}}} & \bar{\bar{\mathbf{0}}} \end{bmatrix} \begin{bmatrix} \bar{\bar{\mathbf{V}}}_r^T \\ \bar{\bar{\mathbf{V}}}_{M-r}^T \end{bmatrix}$$

Neste caso a matriz é escrita como

$$\bar{\bar{\mathbf{A}}} = \bar{\bar{\mathbf{U}}}_r \bar{\bar{\mathbf{S}}}_r \bar{\bar{\mathbf{V}}}_r^T$$

### Exemplo numérico simples:

#### Uma Informação:

No MATLAB há um commando “svd” que calcula a decomposição em valores singulares de uma matriz retangular  $N \times M$  fornecendo a matriz de valores singulares e as matrizes ortogonais ( $N \times N$ ) e ( $M \times M$ ) cujas os vetores colunas são bases do espaço  $R^N$  (espaço das observações) e  $R^M$  respectivamente.

Veja um exemplo

»  $a = [1 \ 1 \ 0; \ 1 \ 1 \ 0]$

$a =$

$$\begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \end{bmatrix}$$

»  $[U, S, V] = \text{svd}(a)$

$U =$

$$\begin{bmatrix} 0.7071 & -0.7071 \\ 0.7071 & 0.7071 \end{bmatrix}$$

$S =$

$$\begin{bmatrix} 2 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

$V =$

$$\begin{bmatrix} 0.7071 & -0.7071 & 0 \\ 0.7071 & 0.7071 & 0 \\ 0 & 0 & 1.0 \end{bmatrix}$$

Neste exemplo acima  $\overline{\overline{\mathbf{A}}} \in R^{N \times M}$  é uma matriz expressa como

$$\overline{\overline{\mathbf{A}}} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \end{bmatrix} \quad (N=2 \text{ e } M=3). \text{ Note que o posto desta matriz é igual a 1 (há}$$

apenas uma vetor LI). A decomposição em valores singulares de  $\overline{\overline{\mathbf{A}}}$  mostra exatamente que o posto é igual a 1 uma vez que a matriz dos valores singulares  $\overline{\overline{\mathbf{S}}}$ , é uma matriz diagonal contendo apenas um valor não nulo ( $r=1$ )  $\overline{\overline{\mathbf{S}}} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$ .

Logo  $\overline{\overline{\mathbf{S}}}_r = [2]$  tem dimensão (1 x 1). Como neste caso as matrizes ortogonais

$\overline{\overline{\mathbf{U}}}$  e  $\overline{\overline{\mathbf{V}}}$  que expressas respectivamente como:

$$\overline{\overline{\mathbf{U}}} = \begin{bmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix} \text{ e } \overline{\overline{\mathbf{V}}} = \begin{bmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} & 0 \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

as suas formas particionadas são

$$\overline{\overline{\mathbf{U}}} = \begin{bmatrix} \overline{\overline{\mathbf{U}}}_r & \overline{\overline{\mathbf{U}}}_{N-r} \end{bmatrix} \text{ e } \overline{\overline{\mathbf{V}}} = \begin{bmatrix} \overline{\overline{\mathbf{V}}}_r & \overline{\overline{\mathbf{V}}}_{M-r} \end{bmatrix} .$$

Como temos apenas um valor singular diferente de zero ( $r = 1$ ) então temos que:

$$\overline{\overline{\mathbf{U}}}_{(N \times r)} = \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{2}{\sqrt{2}} \\ \frac{\sqrt{2}}{2} \\ 2 \end{bmatrix} \text{ e } \overline{\overline{\mathbf{V}}}_{(M \times r)} = \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{2}{\sqrt{2}} \\ \frac{\sqrt{2}}{2} \\ 0 \end{bmatrix}$$

Veja que a matriz  $\overline{\overline{\mathbf{A}}}$  pode ser escrita como

$$\overline{\overline{\mathbf{A}}} = \overline{\overline{\mathbf{U}}}_r \overline{\overline{\mathbf{S}}}_r \overline{\overline{\mathbf{V}}}_r^T$$

*Veja o resultado no Matlab*

»  $Ur=U(:,1)$  (comando para extrair a primeira coluna da matriz U )

$Ur =$

0.7071  
0.7071

»  $Vr=V(:,1)$  (comando para extrair a primeira coluna da matriz V)

$Vr =$

0.7071  
0.7071  
0

»  $Sr=S(1,1)$  (comando para extrair o único valor singular diferente se zero)

$Sr =$   
2

»  $Ur*Sr*Vr'$  (comando que faz o calculo da matriz  $\overline{\overline{\mathbf{A}}} = \overline{\overline{\mathbf{U}}}_r \overline{\overline{\mathbf{S}}}_r \overline{\overline{\mathbf{V}}}_r^T$ )

$ans =$

1.0000 1.0000 0  
1.0000 1.0000 0