

OS VALORES SINGULARES NA ANÁLISE DE NÃO UNICIDADE E INSTABILIDADE:

Vamos considerar agora o funcional ajustante \bar{y} dado por $\bar{y} = \bar{\bar{A}} \bar{p}$. Queremos estimar um vetor de parâmetros \bar{p}' que produza um funcional ajustante avaliado nos N pontos de observações que esteja perto das observações medidas \bar{y}^0 sob algum critério. Se a medida de proximidade \bar{y} e \bar{y}^0 for a distância Euclideana entre 2 vetores, o problema se torna:

$$\min_{\bar{p}} \left\| \bar{y}^0 - \bar{\bar{A}} \bar{p} \right\|_2^2 = \min_{\bar{p}} Q$$

Introduzindo a decomposição em valores singulares de $\bar{\bar{A}}$:

$$Q = \left\| \bar{\varepsilon} \right\|_2^2 = \left\| \bar{y}^0 - \bar{\bar{U}} \bar{\bar{S}} \bar{\bar{V}}^T \bar{p} \right\|_2^2 \quad (6)$$

Propriedade: Numa transformação ortogonal a norma Euclideana é preservada. Assim por exemplo dado uma matriz ortogonal $\bar{\bar{U}}$ então $\left\| \bar{x} \right\|_2 = \left\| \bar{\bar{U}} \bar{x} \right\|_2$.

Vamos então aplicar esta propriedade na equação (6). Assim pré-multiplicando o vetor de resíduos pela matriz ortogonal $\bar{\bar{U}}^T$ teremos a preservação da norma Euclideana do vetor de resíduos.

$$Q = \left\| \bar{\bar{U}}^T \bar{\varepsilon} \right\|_2^2 = \left\| \bar{\bar{U}}^T \bar{y}^0 - \bar{\bar{U}}^T \bar{\bar{U}} \bar{\bar{S}} \bar{\bar{V}}^T \bar{p} \right\|_2^2 \quad (7)$$

resultando em :

$$Q = \left\| \bar{\bar{U}}^T \bar{y}^0 - \bar{\bar{S}} \bar{\bar{V}}^T \bar{p} \right\|_2^2 \quad (8)$$

Vamos chamar:

$$\overline{\overline{\mathbf{U}}}^T \overline{\mathbf{y}}^o = \overline{\boldsymbol{\beta}} \quad (9)$$

e

$$\overline{\overline{\mathbf{V}}}^T \overline{\mathbf{p}} = \overline{\boldsymbol{\alpha}} \quad (10)$$

Substituindo as equações (9) e (10) na equação (8) obtemos que o nosso funcional Q a ser minimizado é expresso como:

$$Q = \left\| \overline{\boldsymbol{\beta}} - \overline{\overline{\mathbf{S}}} \overline{\boldsymbol{\alpha}} \right\|_2^2 \quad (11)$$

Matematicamente introduzimos um novo sistema de referência rotacionando os eixos originais para novos eixos de referência. Este novo sistema de referência tem como eixos os autovetores das matrizes ortogonais $\overline{\overline{\mathbf{U}}}$ e $\overline{\overline{\mathbf{V}}}$.

Considere que um vetor de parâmetros de dimensão 2, logo temos, p_1 e p_2 . Então inicialmente temos o espaço de parâmetros formado pelos eixos p_1 e p_2 . O ponto p na Figura (1) é o vetor $\overline{\mathbf{p}}$ que apresenta coordenadas ou elementos p_1 e p_2 . Agora queremos representar o mesmo ponto p no novo sistema de referências, ou seja, em relação aos novos eixos formados pelos autovetores da matriz $\overline{\overline{\mathbf{V}}} = \begin{bmatrix} \overline{\mathbf{v}}_1 & \overline{\mathbf{v}}_2 \end{bmatrix}$. Então o nosso objetivo é determinar as coordenadas do ponto p (elementos do vetor $\overline{\mathbf{p}}$) neste novo sistema de referência, ou seja, determinar α_1 e α_2 que são elementos do vetor $\overline{\boldsymbol{\alpha}}$. Geometricamente, temos:




Figura 1

Matematicamente a representação das coordenadas antigas em relação aos eixos novos é expressa por

$$\overline{\overline{\mathbf{V}}}^T \overline{\mathbf{p}} = \overline{\mathbf{a}} \quad (12)$$

Considerando que o posto é igual a M então pré-multiplicando a equação acima pela matriz dos autovetores $\overline{\overline{\mathbf{V}}}$ temos que:

$$\overline{\mathbf{p}} = \overline{\overline{\mathbf{V}}} \overline{\mathbf{a}} \quad (13)$$

Analogamente se considerarmos que um vetor de observações de dimensão 2, logo temos, y_1° e y_2° . Então inicialmente temos o espaço de observações formado pelos eixos y_1° e y_2° . O ponto y° na Figura (2) é o vetor $\overline{\mathbf{y}}^\circ$ que apresenta coordenadas ou elementos y_1° e y_2° . Agora queremos representar o mesmo ponto y° no novo sistema de referências, ou seja, em relação aos novos eixos formados pelos autovetores da matriz $\overline{\overline{\mathbf{U}}} = \begin{bmatrix} \overline{u}_1 & \overline{u}_2 \end{bmatrix}$. Então o nosso objetivo é determinar as coordenadas do ponto y° (elementos do vetor $\overline{\mathbf{y}}^\circ$) neste novo sistema de referência, ou seja, determinar β_1 e β_2 que são elementos do vetor $\overline{\boldsymbol{\beta}}$. Geometricamente, temos:




Figura 2

Matematicamente a representação das coordenadas antigas em relação aos eixos novos é expressa por

$$\overline{\overline{\mathbf{U}}}^T \overline{\mathbf{y}}^o = \overline{\boldsymbol{\beta}} \quad (14)$$

Considerando que o posto é igual a N então pré-multiplicando a equação acima pela matriz dos autovetores $\overline{\overline{\mathbf{U}}}$ temos que:

$$\overline{\mathbf{y}}^o = \overline{\overline{\mathbf{U}}} \overline{\boldsymbol{\beta}} \quad (15)$$




Figura 3

Dada uma matriz $M \times M$ $\overline{\overline{\mathbf{V}}} = \begin{bmatrix} \overline{\mathbf{v}}_1 & \overline{\mathbf{v}}_2 & \dots & \overline{\mathbf{v}}_M \end{bmatrix}$ e um vetor $M \times 1$ $\overline{\mathbf{a}}$, temos que:

$$\overline{\overline{\mathbf{V}}} \overline{\mathbf{a}} = \sum_{i=1}^M \alpha_i \overline{\mathbf{v}}_i \quad (16)$$

então

$$\overline{\overline{\mathbf{V}}} \overline{\mathbf{a}} = \alpha_1 \overline{\mathbf{v}}_1 + \alpha_2 \overline{\mathbf{v}}_2 + \alpha_3 \overline{\mathbf{v}}_3 + \dots + \alpha_M \overline{\mathbf{v}}_M \quad (17)$$

Como os autovetores $\overline{\mathbf{v}}_i$, colunas da matriz $\overline{\overline{\mathbf{V}}}$ formam uma base no espaço de parâmetros, qualquer vetor de parâmetros $\overline{\mathbf{p}}'$ deste espaço que explica os dados geofísicos observados, ou seja satisfaz ao sistema $\overline{\mathbf{y}}^o = \overline{\overline{\mathbf{A}}} \overline{\mathbf{p}}'$, pode ser expandido como:

$$\bar{\mathbf{p}}' = \bar{\bar{\mathbf{V}}} \bar{\mathbf{a}} = \sum_{i=1}^M \alpha_i \bar{\mathbf{v}}_i \quad (18)$$

Considerando agora a partição da matriz $\bar{\bar{\mathbf{V}}} = \begin{bmatrix} \bar{\bar{\mathbf{V}}}_r & \bar{\bar{\mathbf{V}}}_{M-r} \end{bmatrix}$ temos:

$$\bar{\mathbf{p}}' = \begin{bmatrix} \bar{\bar{\mathbf{V}}}_r & \bar{\bar{\mathbf{V}}}_{M-r} \end{bmatrix} \begin{bmatrix} \bar{\mathbf{a}}_r \\ \bar{\mathbf{a}}_{M-r} \end{bmatrix} \quad (19)$$

sendo que $\bar{\bar{\mathbf{V}}}_r$ ($\mathbf{M} \times \mathbf{r}$) , $\bar{\bar{\mathbf{V}}}_{M-r}$ ($\mathbf{M} \times \mathbf{M} - \mathbf{r}$) , $\bar{\mathbf{a}}_r$ ($\mathbf{r} \times \mathbf{1}$) e $\bar{\mathbf{a}}_{M-r}$ ($\mathbf{M} - \mathbf{r} \times \mathbf{1}$) .

Analogamente, os autovetores $\bar{\mathbf{u}}_i$, $i = 1, \dots, N$, colunas da matriz $\bar{\bar{\mathbf{U}}}$ formam uma base no espaço das observações geofísicas. Então qualquer elemento deste espaço pode ser expandido como:

$$\bar{\mathbf{y}}^0 = \bar{\bar{\mathbf{U}}} \bar{\mathbf{\beta}} = \sum_{i=1}^N \beta_i \bar{\mathbf{u}}_i \quad (20)$$

Considerando $N > M > r$, logo o posto r é menor que M e N , e portanto teremos uma partição da matriz $\bar{\bar{\mathbf{U}}} = \begin{bmatrix} \bar{\bar{\mathbf{U}}}_r & \bar{\bar{\mathbf{U}}}_{M-r} & \bar{\bar{\mathbf{U}}}_{N-M} \end{bmatrix}$ e conseqüentemente temos

$$\bar{\mathbf{y}}^0 = \begin{bmatrix} \bar{\bar{\mathbf{U}}}_r & \bar{\bar{\mathbf{U}}}_{M-r} & \bar{\bar{\mathbf{U}}}_{N-M} \end{bmatrix} \begin{bmatrix} \bar{\mathbf{\beta}}_r \\ \bar{\mathbf{\beta}}_{M-r} \\ \bar{\mathbf{\beta}}_{N-M} \end{bmatrix} \quad (21)$$

sendo que

$$\bar{\bar{\mathbf{U}}}_r \text{ (N x r)}$$

$$\bar{\bar{\mathbf{U}}}_{M-r} \text{ (N x M - r)}$$

$$\bar{\bar{\mathbf{U}}}_{N-M} \text{ (N x N-M)}$$

$$\bar{\mathbf{\beta}}_r \text{ (r x 1)}$$

$$\bar{\mathbf{\beta}}_{M-r} \text{ (M-r x 1) .}$$

$$\bar{\mathbf{\beta}}_{N-M} \text{ (N - M x 1)}$$

Vamos agora introduzir na equação (11) as partições da matriz $\bar{\bar{\mathbf{S}}}$ e dos vetores

$\bar{\mathbf{a}}$ e $\bar{\mathbf{\beta}}$ considerando $N > M > r$:

$$\mathbf{Q} = \left\| \bar{\mathbf{\beta}} - \bar{\bar{\mathbf{S}}} \bar{\mathbf{a}} \right\|_2^2 = \left\| \begin{bmatrix} \bar{\mathbf{\beta}}_r \\ \bar{\mathbf{\beta}}_{M-r} \\ \bar{\mathbf{\beta}}_{N-M} \end{bmatrix} - \begin{bmatrix} \bar{\bar{\mathbf{S}}}_r & \bar{\mathbf{0}} \\ \bar{\mathbf{0}} & \bar{\bar{\mathbf{S}}}_{M-r} \\ \bar{\mathbf{0}} & \bar{\mathbf{0}} \end{bmatrix} \begin{bmatrix} \bar{\mathbf{a}}_r \\ \bar{\mathbf{a}}_{M-r} \end{bmatrix} \right\|_2^2 \quad (22)$$

$$\mathbf{Q} = \left\| \begin{bmatrix} \bar{\mathbf{\beta}}_r \\ \bar{\mathbf{\beta}}_{M-r} \\ \bar{\mathbf{\beta}}_{N-M} \end{bmatrix} - \begin{bmatrix} \bar{\bar{\mathbf{S}}}_r & \bar{\mathbf{a}}_r \\ \bar{\bar{\mathbf{S}}}_{M-r} & \bar{\mathbf{a}}_{M-r} \\ \bar{\mathbf{0}} \end{bmatrix} \right\|_2^2$$

$$Q = \left\| \begin{array}{c} \bar{\beta}_r - \bar{\bar{S}}_r \bar{\alpha}_r \\ \bar{\beta}_{M-r} - \bar{\bar{S}}_{M-r} \bar{\alpha}_{M-r} \\ \bar{\beta}_{N-M} \end{array} \right\|_2^2$$

Finalmente obtemos:

$$Q = \left\| \bar{\beta}_r - \bar{\bar{S}}_r \bar{\alpha}_r \right\|_2^2 + \left\| \bar{\beta}_{M-r} - \bar{\bar{S}}_{M-r} \bar{\alpha}_{M-r} \right\|_2^2 + \left\| \bar{\beta}_{N-M} \right\|_2^2 \quad (23)$$

A equação (23) é de extrema importância na análise da relação entre valores singulares, não unicidade e instabilidade.

Queremos encontrar uma solução $\bar{\mathbf{p}}'$ tal que a distância entre $\bar{\bar{\mathbf{A}}} \bar{\mathbf{p}}'$ e $\bar{\mathbf{y}}^0$ seja a menor possível na Norma Euclideana. Esta distância como vimos é dada pelo funcional Q. Para então obtermos a estimativa $\bar{\mathbf{p}}'$, basta, segundo a equação (18), determinarmos o vetor $\bar{\alpha}$, uma vez que a matriz dos autovetores $\bar{\bar{\mathbf{V}}}$ é conhecida da decomposição em valores singulares da matriz $\bar{\bar{\mathbf{A}}}$.

Vejamos agora as possíveis hipóteses:

Hipótese 1: $M - r$ valores singulares são nulos:

Neste caso a matriz $\bar{\bar{\mathbf{S}}}_{M-r} = \bar{\mathbf{0}}$ então o funcional Q é dado por:

$$Q = \left\| \bar{\beta}_r - \bar{\bar{S}}_r \bar{\alpha}_r \right\|_2^2 + \left\| \bar{\beta}_{M-r} \right\|_2^2 + \left\| \bar{\beta}_{N-M} \right\|_2^2 \quad (24)$$

ou ainda

$$Q = \left(\bar{\beta}_r - \bar{\bar{S}}_r \bar{\alpha}_r \right)^T \left(\bar{\beta}_r - \bar{\bar{S}}_r \bar{\alpha}_r \right) + \left(\bar{\beta}_{M-r} \right)^T \left(\bar{\beta}_{M-r} \right) + \left(\bar{\beta}_{N-M} \right)^T \left(\bar{\beta}_{N-M} \right) \quad (25)$$

Então queremos encontrar a estimativa $\bar{\alpha}'$ tal que o funcional Q seja mínimo.

A condição necessária para Q ter um mínimo é

$$\bar{\nabla}_{\alpha} \mathbf{Q} = 0$$

A solução que minimiza Q nesta condição em que $\bar{\mathbf{S}}_{M-r} = \bar{\mathbf{0}}$ é dado por

$$\bar{\mathbf{a}}_r' = \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{p}}_r \quad (26)$$

Então a estimativa $\bar{\mathbf{a}}'$ tal que o funcional Q seja mínimo é dada pela equação (26).

Note que esta estimativa envolve apenas a parte do vetor $\bar{\mathbf{a}}$ correspondente a $\bar{\mathbf{a}}_r$, portanto a parte do vetor $\bar{\mathbf{a}}$ correspondente a $\bar{\mathbf{a}}_{M-r}$ não é usada para minimizar o funcional Q. Vimos na equação (18) que

$$\bar{\mathbf{p}}' = \bar{\mathbf{V}} \bar{\mathbf{a}}' = \bar{\mathbf{V}}_r \bar{\mathbf{a}}_r' + \bar{\mathbf{V}}_{M-r} \bar{\mathbf{a}}_{M-r}'$$

Desta forma, qualquer vetor $\bar{\mathbf{a}}_{M-r}'$ quando usado junto com o vetor $\bar{\mathbf{a}}_r'$ dado pela equação (26) levará a vetores soluções:

$$\bar{\mathbf{p}}' = \bar{\mathbf{V}}_r \bar{\mathbf{a}}_r' + \bar{\mathbf{V}}_{M-r} \bar{\mathbf{a}}_{M-r}'$$

que produzirão mínimos da função objeto Q.

Substituindo a estimativa do vetor $\bar{\mathbf{a}}$ dada pela equação (26) na equação (23) temos:

$$\mathbf{Q}_{\text{MIN}} = \|\bar{\mathbf{p}}_{M-r}\|_2^2 + \|\bar{\mathbf{p}}_{N-M}\|_2^2 = \|\bar{\mathbf{p}}_{N-r}\|_2^2 \quad (27)$$

Como, neste caso de M - r valores singulares nulos, podemos atribuir ao vetor

$\bar{\mathbf{a}}_{M-r}'$ qualquer valor, então teremos por consequência infinitas soluções

$\bar{\mathbf{p}}' = \bar{\mathbf{V}}_r \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{p}}_r + \bar{\mathbf{V}}_{M-r} \bar{\mathbf{a}}_{M-r}'$ produzindo o mesmo mínimo da função Q dado pela equação (27).

Note que o vetor $\bar{\mathbf{a}}'_{M-r}$ é a projeção da solução nula na base do espaço nulo do espaço dos parâmetros. Então podemos dizer que

$$\bar{\mathbf{p}}^{null} = \bar{\mathbf{V}}_{M-r} \bar{\mathbf{a}}'_{M-r}$$

isto porque como consideramos que a matriz $\bar{\mathbf{A}}$ tem M-r valores singulares iguais a ZERO, então sua SVD é dada por

$$\bar{\mathbf{A}} = \begin{bmatrix} \bar{\mathbf{U}}_r & \bar{\mathbf{U}}_{M-r} & \bar{\mathbf{U}}_{N-M} \end{bmatrix} \begin{bmatrix} \bar{\mathbf{S}}_r & \bar{\mathbf{0}} \\ \bar{\mathbf{0}} & \bar{\mathbf{S}}_{M-r} \\ \bar{\mathbf{0}} & \bar{\mathbf{0}} \end{bmatrix} \begin{bmatrix} \bar{\mathbf{V}}_r^T \\ \bar{\mathbf{V}}_{M-r}^T \end{bmatrix}$$

Sob a condição de $\bar{\mathbf{S}}_{M-r} = \bar{\mathbf{0}}$ pode-se escrever que

$$\bar{\mathbf{A}} = \bar{\mathbf{U}}_r \bar{\mathbf{S}}_r \bar{\mathbf{V}}_r^T$$

Então fazendo-se a multiplicação da matriz $\bar{\mathbf{A}}$ por $\bar{\mathbf{p}}^{null} = \bar{\mathbf{V}}_{M-r} \bar{\mathbf{a}}'_{M-r}$ temos

$$\bar{\mathbf{A}} \bar{\mathbf{p}}^{null} = \bar{\mathbf{U}}_r \bar{\mathbf{S}}_r \bar{\mathbf{V}}_r^T \bar{\mathbf{V}}_{M-r} \bar{\mathbf{a}}'_{M-r}$$

Como $\bar{\mathbf{V}}_r$ e $\bar{\mathbf{V}}_{M-r}$ são matrizes ortogonais então $\bar{\mathbf{V}}_r^T \bar{\mathbf{V}}_{M-r} = \bar{\mathbf{0}}_{(r \times r)}$

Conseqüentemente temos que

$$\bar{\mathbf{A}} \bar{\mathbf{p}}^{null} = \bar{\mathbf{0}}$$

Provando que $\bar{\mathbf{V}}_{M-r} \bar{\mathbf{a}}'_{M-r}$ é um vetor solução nula

$$\bar{\mathbf{A}} \bar{\mathbf{p}}^{null} = \bar{\mathbf{U}}_r \bar{\mathbf{S}}_r \bar{\mathbf{V}}_r^T \bar{\mathbf{V}}_{M-r} \bar{\mathbf{a}}'_{M-r} = \bar{\mathbf{0}}$$

Então sob a hipótese de **M – r valores singulares nulos** temos a existência do espaço nulo e conseqüentemente M-r vetores soluções nulas, implicando uma solução geral dada por

$$\bar{\mathbf{p}}' = \bar{\mathbf{V}}_r \bar{\mathbf{a}}'_r + \bar{\mathbf{V}}_{M-r} \bar{\mathbf{a}}'_{M-r}$$

ou ainda

$$\bar{\mathbf{p}}_{\text{geral}} = \bar{\mathbf{p}}_{\text{particular}} + \bar{\mathbf{p}}^{\text{null}}$$

CONCLUSÃO:

Sob a hipótese de **M – r valores singulares nulos** temos a **não unicidade de soluções** produzindo o **mesmo ajuste** aos dados.

Hipótese 2: M – r valores singulares muito próximos de zero:

Então queremos encontrar a estimativa $\bar{\mathbf{a}}'$ tal que o funcional Q seja mínimo, para isto vamos tomar $\bar{\nabla}_{\mathbf{a}} \mathbf{Q} = 0$. A solução que minimiza Q nesta condição em que temos M – r valores singulares próximos a zero é:

$$\bar{\mathbf{a}}' = \bar{\mathbf{S}}_M^{-1} \bar{\mathbf{p}}_M = \begin{bmatrix} \bar{\mathbf{a}}'_r \\ \bar{\mathbf{a}}'_{M-r} \end{bmatrix} = \begin{bmatrix} \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{p}}_r \\ \bar{\mathbf{S}}_{M-r}^{-1} \bar{\mathbf{p}}_{M-r} \end{bmatrix} \quad (28)$$

Vamos considerar que as observações geofísicas $\bar{\mathbf{y}}^o$ são exatas, ou seja sem contaminação de ruído. O vetor $\bar{\mathbf{p}}$ é dado por

$$\bar{\mathbf{U}}^T \bar{\mathbf{y}}^o = \bar{\mathbf{p}} \quad (29)$$

Vimos na equação (18) que o vetor de parâmetros estimado será obtido resolvendo-se:

$$\bar{\mathbf{p}}' = \bar{\mathbf{V}} \bar{\mathbf{a}}' = \bar{\mathbf{V}}_M \bar{\mathbf{a}}'_M = \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^{-1} \bar{\mathbf{p}}_M \quad (30)$$

O vetor $\bar{\mathbf{p}}$ é exato e esta solução estimada é única

Vamos considerar que o nosso vetor de observações geofísicas $\bar{\mathbf{y}}^o$ estão contaminados por ruído:

$$\bar{\mathbf{y}} = \bar{\mathbf{y}}^o + \bar{\boldsymbol{\varepsilon}} \quad (31)$$

O vetor $\bar{\boldsymbol{\beta}}^n$ será :

$$\bar{\boldsymbol{\beta}}^n = \bar{\mathbf{U}}^T \bar{\mathbf{y}}^n = \bar{\mathbf{U}}^T \bar{\mathbf{y}}^o + \bar{\mathbf{U}}^T \bar{\boldsymbol{\varepsilon}} \quad (32)$$

$$\bar{\boldsymbol{\beta}}^n = \bar{\boldsymbol{\beta}}_M + \bar{\boldsymbol{\beta}}_M^{Ruido} \quad (33)$$

sendo $\bar{\boldsymbol{\beta}}_M^{Ruido}$ é o vetor de valores aleatórios.

Vimos na equação (18) que o vetor de parâmetros estimado será obtido resolvendo-se:

$$\bar{\mathbf{p}}'' = \bar{\mathbf{V}} \bar{\boldsymbol{\alpha}}' = \bar{\mathbf{V}}_M \bar{\boldsymbol{\alpha}}'_M = \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^{-1} \bar{\boldsymbol{\beta}}^n \quad (34)$$

Substituindo-se a equação (33) na equação (34) temos:

$$\bar{\mathbf{p}}'' = \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^{-1} \bar{\boldsymbol{\beta}}_M + \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^{-1} \bar{\boldsymbol{\beta}}_M^{Ruido}$$

Como $\bar{\mathbf{p}}' = \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^{-1} \bar{\boldsymbol{\beta}}_M$ é a solução estimada para observações exatas (sem ruído) então, neste caso em que consideramos a existência de ruído temos:

$$\bar{\mathbf{p}}'' = \bar{\mathbf{p}}' + \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^{-1} \bar{\boldsymbol{\beta}}_M^{Ruido} \quad (35)$$

que pode ser rescrita como

$$\bar{\mathbf{p}}'' = \bar{\mathbf{p}}' + \sum_{i=1}^M \left(\frac{\beta_i^{Ruido}}{S_i} \right) \bar{\mathbf{v}}_i \quad (36)$$

Note que a distância entre $\bar{\mathbf{p}}'$ e $\bar{\mathbf{p}}''$ será:

$$\|\bar{\mathbf{p}}' - \bar{\mathbf{p}}''\|^2 = \left\| \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^{-1} \bar{\boldsymbol{\beta}}_M^{Ruido} \right\|^2 \quad (37)$$

$$\|\bar{\mathbf{p}}' - \bar{\mathbf{p}}''\|^2 = \bar{\boldsymbol{\beta}}_M^{Ruido T} \bar{\mathbf{S}}_M^{-1} \bar{\mathbf{V}}_M^T \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^{-1} \bar{\boldsymbol{\beta}}_M^{Ruido} \quad (38)$$

$$\|\bar{\mathbf{p}}' - \bar{\mathbf{p}}''\|^2 = \bar{\boldsymbol{\beta}}_M^{Ruido T} \bar{\mathbf{S}}_M^{-2} \bar{\boldsymbol{\beta}}_M^{Ruido} = \sum_{i=1}^M \left(\frac{\beta_i^{Ruido} \delta_i}{S_i} \right)^2 \quad (39)$$

$$\|\bar{\mathbf{p}}' - \bar{\mathbf{p}}''\|^2 = \sum_{i=1}^r \left(\frac{\beta_i^{Ruido}}{S_i} \right)^2 + \sum_{i=r+1}^M \left(\frac{\beta_i^{Ruido}}{S_i} \right)^2 \quad (40)$$

A equação (40) mostra que uma solução $\bar{\mathbf{p}}''$ estimada com dados contaminados por ruído e **sob a hipótese de $M - r$ valores próximos a zero** pode estar infinitamente distante da solução estimada com dados exatos $\bar{\mathbf{p}}'$. Isto ocorre devido a segunda

parcela do somatório da equação (40) $\left[\sum_{i=r+1}^M \left(\frac{\beta_i^{Ruido}}{S_i} \right)^2 \right]$; note que cada termo

desta parcela pode apresentar valores grandes pois temos $S_i \rightarrow 0$ para $i = r + 1, r + 2, \dots, M$.

Fazendo uma análise da equação (36) vemos que a solução estimada $\bar{\mathbf{p}}''$ é igual a solução estimada com dados exatos $\bar{\mathbf{p}}'$ somada a um vetor que envolve o ruído aleatório, os valores singulares e autovetores. Como β_i^{Ruido} é o ruído aleatório então pode assumir valores positivos ou negativos, os valores singulares $S_i, i = r + 1, \dots, M$ amplificarão este ruído aleatório fazendo com que as componentes da solução possam assumir valores bem elevados ora positivos ora negativos caracterizando assim a **INSTABILIDADE DAS SOLUÇÕES**.

CONCLUSÃO:

Sob a hipótese de **M – r valores singulares muito próximos a zero** temos a **instabilidade da solução** produzindo o **mesmo ajuste** aos dados.

OS VALORES SINGULARES NA ANÁLISE DO AJUSTE E DOS PARÂMETROS DETERMINADOS PELAS OBSERVAÇÕES:

Da análise dos valores singulares é possível detectar se um problema inverso tem solução não única ou se a solução é instável. Adicionalmente, esta análise permite:

- 1) Analisar se a solução estimada produzirá um ajuste exato dos dados (funcional ajustante passando exatamente pelas observações)
- 2) Descobrir quais os parâmetros ou combinações podem e quais não podem ser determinados pelas observações
- 3) Formular uma reparametrização do problema com vistas a estimar apenas os parâmetros (ou combinações de parâmetros) que podem ser determinados pelas observações

Ajuste exato:

Para a solução ser exata temos que obedecer a condição do resíduo Q ser igual a zero:

$$Q = 0$$

Se há M – r valores singulares nulos, a equação (27) fornece

$$Q_{\text{MIN}} = \|\bar{\mathbf{p}}_{M-r}\|_2^2 + \|\bar{\mathbf{p}}_{N-M}\|_2^2 = \|\bar{\mathbf{p}}_{N-r}\|_2^2$$

Note que o resíduo Q é igual ao norma Euclideana do vetor $\bar{\mathbf{p}}_{N-r}$. Como

$$\bar{\mathbf{p}}_{N-r} = \bar{\mathbf{U}}_{N-r}^T \bar{\mathbf{y}}^o$$

a condição para a solução ser exata ($Q=0$) será:

$$\left\| \bar{\mathbf{b}}_{N-r} \right\|_2^2 = \left\| \bar{\mathbf{U}}_{N-r}^T \bar{\mathbf{y}}^o \right\|_2^2 = 0$$

Isto ocorre em duas situações:

(1) $r = N \leq M$

Neste caso a matriz $\bar{\mathbf{U}}_{N-r} = \bar{\mathbf{0}}$.


Vamos considerar o caso em que $r = N=1$, $M=2$. Um exemplo poderia ser o ajuste de uma reta por um ponto y_o . Neste exemplo, o dado observado é o único ponto y_o e o nosso problema consiste em estimar os coeficientes angular e linear da reta ($M=2$) que explica este dado observado (y_o). Temos, portanto, infinitas soluções e todas passando exatamente pelo ponto y_o (ajuste exato).

Exemplo de um ajuste exato

Hipótese 1: $M - r$ valores singulares são nulos $\bar{\mathbf{S}}_{M-r} = \bar{\mathbf{0}}$

Condição 1: se $r = N \leq M$

$N = 1$ e $M = 2$



(2) $r < N$

Vimos que a condição para a solução ser exata ($Q=0$) será:

$$\left\| \bar{\beta}_{N-r} \right\|_2^2 = \left\| \bar{\bar{U}}_{N-r}^T \bar{y}^o \right\|_2^2 = 0$$

Como $r < N$ isto ocorre se os autovetores que compõe a matriz $\bar{\bar{U}}_{N-r}$ forem ortogonais ao vetor das observações \bar{y}^o . Há, portanto, um total de $N - r$ observações redundantes. Um exemplo poderia ser o ajuste de uma reta dado 5 pontos sendo que 3 pontos são colineares a 2 pontos quaisquer que são suficientes para ajustar uma reta. Geometricamente, isto corresponde ajustar uma reta dado $N - 3$ observações colineares então apenas 2 observações são suficientes para ajustar uma reta. Note que no exemplo abaixo as observações 2 e 5, por exemplo, são suficientes para determinar a reta. Assim as observações 1, 3 e 4 são redundantes. Neste caso $N=5$ e $r=2$


$$\begin{cases} \bar{\mathbf{u}}_3^T \bar{\mathbf{y}}^o = \bar{0} \\ \bar{\mathbf{u}}_4^T \bar{\mathbf{y}}^o = \bar{0} \\ \bar{\mathbf{u}}_5^T \bar{\mathbf{y}}^o = \bar{0} \end{cases}$$

Exemplo de um ajuste exato

Hipótese 1: $M - r$ valores singulares são nulos $\bar{\bar{S}}_{M-r} = \bar{0}$

Condição 2: se $r < N$

Ajuste de uma reta $M = 2$, com $N - 2$ observações colineares



Quais os parâmetros ou combinações de parâmetros podem ser determinados:

Considere a equação (23):

$$\mathbf{Q} = \left\| \bar{\mathbf{\beta}}_r - \bar{\bar{\mathbf{S}}}_r \bar{\mathbf{a}}_r \right\|_2^2 + \left\| \bar{\mathbf{\beta}}_{M-r} - \bar{\bar{\mathbf{S}}}_{M-r} \bar{\mathbf{a}}_{M-r} \right\|_2^2 + \left\| \bar{\mathbf{\beta}}_{N-M} \right\|_2^2$$

Se existem $M - r$ valores singulares nulos (ou muito próximos a zero) a matriz $\bar{\bar{\mathbf{S}}}_{M-r}$ será nula (ou virtualmente nula) de modo que o produto $\bar{\bar{\mathbf{S}}}_{M-r} \bar{\mathbf{a}}_{M-r}$ será praticamente nulo. Assim a condição para a minimização de \mathbf{Q} permite a penas determinar o vetor $\bar{\mathbf{a}}_r$ pela relação:

$$\bar{\mathbf{a}}_r = \bar{\bar{\mathbf{S}}}_r^{-1} \bar{\mathbf{\beta}}_r$$

Note que o vetor $\bar{\mathbf{a}}_{M-r}$ não pode ser determinado da condição de minimização de \mathbf{Q} , ou seja, $\bar{\mathbf{a}}_{M-r}$ não pode ser estimado usando-se apenas as observações. Assim temos que

$$\begin{cases} \bar{\mathbf{a}}_r \text{ pode ser determinado} \\ \bar{\mathbf{a}}_{M-r} \text{ não pode ser determinado} \end{cases}$$

Como $\bar{\mathbf{a}}_r = \bar{\bar{\mathbf{V}}}_r^T \bar{\mathbf{p}}$ e $\bar{\mathbf{a}}_{M-r} = \bar{\bar{\mathbf{V}}}_{M-r}^T \bar{\mathbf{p}}$, as combinações de parâmetros que podem ser determinadas são:

$$\bar{\mathbf{v}}_1^T \bar{\mathbf{p}}, \quad \bar{\mathbf{v}}_2^T \bar{\mathbf{p}}, \quad \dots, \quad \bar{\mathbf{v}}_r^T \bar{\mathbf{p}}.$$

As combinações de parâmetros que não podem ser determinados são:

$$\bar{\mathbf{v}}_{r+1}^T \bar{\mathbf{p}}, \quad \bar{\mathbf{v}}_{r+2}^T \bar{\mathbf{p}}, \quad \dots, \quad \bar{\mathbf{v}}_M^T \bar{\mathbf{p}}.$$

Veja então que podemos determinar dos dados observados geofísicos apenas a projeção dos parâmetros nas bases do espaço iluminado ($\bar{\bar{\mathbf{V}}}_r$ Figura 1), ou seja, o

vetor $\overline{\mathbf{a}}_r$ e NÃO podemos determinar dos dados observados geofísicos a projeção dos parâmetros nas bases do espaço não-iluminado (espaço nulo $\overline{\mathbf{V}}_{M-r}$, Figura 1).

Vamos retornar ao nosso exemplo simplificado que temos dois parâmetros e uma única observação relacionados pelo sistema de equações linear

$$\overline{\mathbf{A}} \overline{\mathbf{p}} = \overline{\mathbf{y}}^o$$

$$\begin{bmatrix} \frac{1}{2} & \frac{1}{2} \end{bmatrix} \begin{bmatrix} p_1 \\ p_2 \end{bmatrix} = y_1^o$$

Fazendo a SVD da matriz $\overline{\mathbf{A}}$ temos que

$$\overline{\mathbf{U}}_{(1 \times 1)} = \begin{bmatrix} \overline{\mathbf{U}}_r \end{bmatrix} = 1$$

$$\overline{\mathbf{V}}_{(2 \times 2)} = \begin{bmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix} = \begin{bmatrix} \overline{\mathbf{V}}_r & \overline{\mathbf{V}}_{M-r} \end{bmatrix} \text{ e}$$

$$\overline{\mathbf{S}}_{(1 \times 2)} = \begin{bmatrix} \frac{\sqrt{2}}{2} & 0 \end{bmatrix} = \begin{bmatrix} \overline{\mathbf{S}}_r & \overline{\mathbf{S}}_{M-r} \end{bmatrix}$$

Temos então $M=2$, $N=1$ e $r=1$. Há portanto, apenas um único valor singular diferente de zero. Já vimos que vetores colunas de $\overline{\mathbf{V}}_r$ formam as bases do espaço iluminado e os vetores colunas de $\overline{\mathbf{V}}_{M-r}$ formam as bases do espaço não-iluminado da matriz $\overline{\mathbf{A}}$, neste problema as matrizes $\overline{\mathbf{V}}_r$ e $\overline{\mathbf{V}}_{M-r}$ tem apenas um único vetor coluna que são respectivamente:

$$\overline{\overline{\mathbf{V}}}_{r \ (2 \times 1)} = \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{2}{\sqrt{2}} \\ \frac{\sqrt{2}}{2} \end{bmatrix} \mathbf{e} \quad \overline{\overline{\mathbf{V}}}_{M-r \ (2 \times 1)} = \begin{bmatrix} -\frac{\sqrt{2}}{2} \\ \frac{2}{\sqrt{2}} \\ \frac{\sqrt{2}}{2} \end{bmatrix}$$

As combinações de parâmetros que podem ser determinadas apenas a partir dos dados geofísicos observados são

$$\overline{\overline{\mathbf{V}}}_{r \ (1 \times 2)}^T \overline{\mathbf{p}}_{(2 \times 1)} = \overline{\mathbf{a}}_{r \ (1 \times 1)} = \frac{\sqrt{2} (p_1 + p_2)}{2}$$

Portanto as combinações de parâmetros que podem ser determinadas apenas a partir dos dados geofísicos observados são, a menos que uma constante multiplicativa, as médias dos parâmetros p_1 e p_2 .

Já as combinações de parâmetros que NÃO podem ser determinadas apenas a partir dos dados geofísicos observados são, a menos que uma constante multiplicativa, o contraste entre os parâmetros p_1 e p_2 .

$$\overline{\overline{\mathbf{V}}}_{M-r \ (1 \times 2)}^T \overline{\mathbf{p}}_{(2 \times 1)} = \overline{\mathbf{a}}_{M-r \ (1 \times 1)} = \frac{\sqrt{2} (p_1 - p_2)}{2}$$

Reparametrização:

Veja que a análise anterior mostrou que uma reparametrização imediata é fazer os novos parâmetros iguais a $\alpha_1, \alpha_2, \alpha_3, \dots, \alpha_r$ que podem ser determinados APENAS dos dados (geofísicos) observados. O problema com esta medida é que com a reparametrização os novos parâmetros são, em geral, desprovido de significado físico no sistema de parâmetros originais. Lembre-se que

$$\begin{matrix} \overline{\overline{\mathbf{V}}}_r^T & \overline{\mathbf{p}} & = & \overline{\mathbf{a}}_r \\ (r \times M) & (M \times 1) & & (r \times 1) \end{matrix}$$

No entanto, os $\alpha_1, \alpha_2, \alpha_3, \dots, \alpha_r$ podem guiar o intérprete para formular uma reparametrização que faça sentido físico

Um exemplo:

Considere que a matriz de sensibilidade é igual a:

$$\overline{\overline{\mathbf{A}}} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 1 & 1 \end{bmatrix}$$

A decomposição em valores singulares desta matriz é igual a:

$$\overline{\overline{\mathbf{A}}} = \overline{\overline{\mathbf{U}}}_r \overline{\overline{\mathbf{S}}}_r \overline{\overline{\mathbf{V}}}_r^T = \begin{pmatrix} \sqrt{3}/3 \\ \sqrt{3}/3 \\ \sqrt{3}/3 \end{pmatrix} \begin{pmatrix} \sqrt{6} \\ \sqrt{6} \end{pmatrix} \begin{pmatrix} \sqrt{2}/2 & \sqrt{2}/2 \\ \sqrt{2}/2 & -\sqrt{2}/2 \\ \sqrt{2}/2 & -\sqrt{2}/2 \end{pmatrix}$$

Já vimos que as combinações de parâmetros que podem ser determinadas apenas a partir dos dados geofísicos observados são dadas por

$$\begin{matrix} \overline{\overline{\mathbf{V}}}_r^T & \overline{\mathbf{p}} & = & \overline{\mathbf{a}}_r \\ (1 \times 2) & (2 \times 1) & & (1 \times 1) \end{matrix} = \frac{\sqrt{2}(p_1 + p_2)}{2}$$

Vamos achar agora as combinações de OBSERVAÇÕES que são LI

$$\overline{\overline{\mathbf{U}}}_r^T \overline{\mathbf{y}}^o = \overline{\mathbf{\beta}}_r$$

$$\overline{\mathbf{U}}_r^T \overline{\mathbf{y}}^o = \overline{\mathbf{p}}_r = \begin{bmatrix} \sqrt{3}/3 & \sqrt{3}/3 & \sqrt{3}/3 \end{bmatrix} \begin{pmatrix} y_1^0 \\ y_2^0 \\ y_3^0 \end{pmatrix} = \frac{\sqrt{3}(y_1^0 + y_2^0 + y_3^0)}{3}$$

Para determinar a combinação de parâmetros $(\overline{\mathbf{a}}_r)$ que podem ser determinadas apenas a partir dos dados geofísicos observados, não precisamos de todas as 3 observações, é necessário apenas as uma combinação de observações LI $(\overline{\mathbf{p}}_r)$.

Reparametrização:

O nosso sistema anterior é definido por

$$\overline{\mathbf{A}} \overline{\mathbf{p}} = \overline{\mathbf{y}}^0$$

$$\begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{pmatrix} p_1 \\ p_2 \end{pmatrix} = \begin{pmatrix} y_1^0 \\ y_2^0 \\ y_3^0 \end{pmatrix}$$

Portanto eu tenho dois parâmetros para serem estimados. Vamos definir um NOVO vetor de parâmetros de dimensão (1 x 1) :

$$p'_1 = \frac{(p_1 + p_2)}{2} \approx \alpha_r$$

Vamos definir um NOVO vetor de observações de dimensão (1 x 1):

$$y_1^{0'} = \frac{(y_1^0 + y_2^0 + y_3^0)}{3} \approx \beta_r$$

Um exemplo do uso da SVD como ferramenta de análise da não unicidade e instabilidade

Análise do estimador de Mínimos Quadrados Via decomposição em valores singulares da matriz de sensibilidade

A solução $\hat{\mathbf{p}}$ que chamamos de estimador de mínimos quadrados é

$$\hat{\mathbf{p}} = \left(\overline{\mathbf{A}}^T \overline{\mathbf{A}} \right)^{-1} \overline{\mathbf{A}}^T \overline{\mathbf{y}}$$

Consideraremos aqui que a matriz de sensibilidade $\overline{\mathbf{A}}$ (N x M) é de posto completo¹. Como o posto de uma matriz que é obtida pelo produto de duas outras matrizes é no máximo igual ao menor posto das matrizes, então temos que o posto de $\overline{\mathbf{A}}^T \overline{\mathbf{A}} \leq \min(M, N)$ como presumimos que $\overline{\mathbf{A}}$ tem posto completo, então o posto de $\overline{\mathbf{A}}^T \overline{\mathbf{A}} = \min(M, N)$. Já vimos anteriormente que para usarmos o estimador de mínimos quadrados é necessário, que $N \geq M$, isto é que o número de observações (N) seja pelo menos igual ao número de parâmetros (M). Como neste caso consideramos que a matriz $\overline{\mathbf{A}}$ é de posto completo temos que o posto da matriz $\overline{\mathbf{A}}^T \overline{\mathbf{A}}$ é igual a M. Em outras palavras, se o $r(\overline{\mathbf{A}}^T \overline{\mathbf{A}}) = M$ então há M valores singulares diferentes de zero. Então sob estas condições ($N \geq M = r$) a decomposição em valores singulares da matriz de sensibilidade é igual a $\overline{\mathbf{A}} = \overline{\mathbf{U}}_r \overline{\mathbf{S}}_r \overline{\mathbf{V}}_r^T$ em que $r = M$. Usando esta informação no estimador $\hat{\mathbf{p}}$

$$\hat{\mathbf{p}} = \left(\overline{\mathbf{A}}^T \overline{\mathbf{A}} \right)^{-1} \overline{\mathbf{A}}^T \overline{\mathbf{y}}$$

temos

$$\hat{\mathbf{p}} = \left(\overline{\mathbf{V}}_M \overline{\mathbf{S}}_M \overline{\mathbf{U}}_M^T \overline{\mathbf{U}}_M \overline{\mathbf{S}}_M \overline{\mathbf{V}}_M^T \right)^{-1} \overline{\mathbf{V}}_M \overline{\mathbf{S}}_M \overline{\mathbf{U}}_M^T \overline{\mathbf{y}}^o$$

$$\hat{\mathbf{p}} = \left(\overline{\mathbf{V}}_M \overline{\mathbf{S}}_M^2 \overline{\mathbf{V}}_M^T \right)^{-1} \overline{\mathbf{V}}_M \overline{\mathbf{S}}_M \overline{\mathbf{U}}_M^T \overline{\mathbf{y}}^o$$

como $r = M$ temos que $\overline{\mathbf{V}}_M^{-1} = \overline{\mathbf{V}}_M^T$ então temos que

$$\hat{\mathbf{p}} = \overline{\mathbf{V}}_M \overline{\mathbf{S}}_M^{-2} \overline{\mathbf{V}}_M^T \overline{\mathbf{V}}_M \overline{\mathbf{S}}_M \overline{\mathbf{U}}_M^T \overline{\mathbf{y}}^o$$

como $\overline{\mathbf{V}}_r^T \overline{\mathbf{V}}_r = \overline{\mathbf{I}}_{(r \times r)}$ e $\overline{\mathbf{V}}_{M-r}^T \overline{\mathbf{V}}_{M-r} = \overline{\mathbf{I}}_{(M-r \times M-r)}$ então temos que

$$\overline{\mathbf{V}}_M^T \overline{\mathbf{V}}_M = \overline{\mathbf{I}}_M$$

$$\hat{\mathbf{p}} = \overline{\mathbf{V}}_M \overline{\mathbf{S}}_M^{-2} \overline{\mathbf{S}}_M \overline{\mathbf{U}}_M^T \overline{\mathbf{y}}^o$$

$$\hat{\mathbf{p}} = \overline{\mathbf{V}}_M \overline{\mathbf{S}}_M^{-1} \overline{\mathbf{U}}_M^T \overline{\mathbf{y}}^o$$

Vamos chamar: o vetor $\overline{\mathbf{U}}_M^T \overline{\mathbf{y}}^o = \overline{\boldsymbol{\beta}}$ ($M \times 1$) então

$$\hat{\mathbf{p}} = \overline{\mathbf{V}}_M \overline{\mathbf{S}}_M^{-1} \overline{\boldsymbol{\beta}}$$

que pode ser escrito na forma de somatório como

$$\hat{\mathbf{p}} = \sum_{i=1}^M \overline{\mathbf{v}}_i \frac{\beta_i}{S_i}$$

em que $\overline{\mathbf{v}}_i, i = 1, 2, \dots, M$ são os M vetores colunas que formam a matriz dos autovetores $\overline{\mathbf{V}}_M (M \times M)$. Veja que o j -ésimo elemento de $\hat{\mathbf{p}}$ é

¹ Uma matriz $N \times M$ é de posto completo quando $r = \min(M, N)$

$$\hat{p}_j = \sum_{i=1}^M \frac{\beta_i}{S_i} v_{ij}$$

Análise da Unicidade e Estabilidade do estimador de Mínimos Quadrados usando a SVD como ferramenta:

A análise do estimador de Mínimos Quadrados via decomposição em valores singulares considerando a que a matriz de sensibilidade é de posto completo e a condição que $N \geq M$ resultou em

$$\hat{\mathbf{p}} = \sum_{i=1}^M \bar{\mathbf{v}}_i \frac{\beta_i}{S_i}$$

Veja que para a garantia da unicidade da solução estimada $\hat{\mathbf{p}}$ temos que ter, obrigatoriamente, M valores singulares diferentes de zero, caso contrário, teremos infinitas possíveis soluções produzindo o mesmo ajuste (mais adiante provaremos esta informação matematicamente).

Note no entanto que a condição de $N \geq M = r$, garante a unicidade da solução $\hat{\mathbf{p}}$ (MQ) porém a simples existência de M valores singulares diferentes de zero não garante a estabilidade da solução. Veja que o j-ésimo elemento de $\hat{\mathbf{p}}$ é

$$\hat{p}_j = \sum_{i=1}^M \frac{\beta_i}{S_i} v_{ij}$$

Note que a existência de valores singulares muito próximo a zero causará uma amplificação do ruído dos dados que está presente nos elementos do vetor

$\bar{\mathbf{p}}$ uma vez que este vetor é $\bar{\mathbf{p}} = \bar{\mathbf{U}}^T \bar{\mathbf{y}}^o$

² $\bar{\mathbf{p}} = \bar{\mathbf{U}}^T \bar{\mathbf{y}}^o$ é a projeção dos dados observados nos autovetores da matriz $\bar{\mathbf{U}}$

Esta análise da estabilidade de $\hat{\mathbf{p}}$ usando a SVD pode também ser feita via a matriz de covariância de $\hat{\mathbf{p}}$

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = \sigma^2 \left(\overline{\mathbf{A}}^T \overline{\mathbf{A}} \right)^{-1}$$

Sob as mesmas condições $N \geq M = r$ que estabelecemos para a garantia da unicidade da solução MQ, a decomposição em valores singulares da matriz de sensibilidade é igual a $\overline{\mathbf{A}} = \overline{\mathbf{U}}_r \overline{\mathbf{S}}_r \overline{\mathbf{V}}_r^T$ em que $r = M$, logo temos que

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = \sigma^2 \left(\overline{\mathbf{V}}_M \overline{\mathbf{S}}_M \overline{\mathbf{U}}_M^T \overline{\mathbf{U}}_M \overline{\mathbf{S}}_M \overline{\mathbf{V}}_M^T \right)^{-1}$$

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = \sigma^2 \left(\overline{\mathbf{V}}_M \overline{\mathbf{S}}_M^2 \overline{\mathbf{V}}_M^T \right)^{-1}$$

como $r = m$ temos que $\overline{\mathbf{V}}_M^{-1} = \overline{\mathbf{V}}_M^T$. Então a matriz de covariância do estimador MQ ($N \geq M = r$) é

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = \sigma^2 \overline{\mathbf{V}}_M \overline{\mathbf{S}}_M^{-2} \overline{\mathbf{V}}_M^T$$

Veja que a covariância do k -ésimo elemento da matriz $\text{cov} \left\{ \hat{\mathbf{p}} \right\}$ é

$$\text{cov} \left\{ \hat{\mathbf{p}}_k \right\} = \sigma^2 \sum_{j=1}^M \frac{v_{kj}^2}{S_j^2} \quad k = 1, \dots, M$$

Como a variância de $\hat{\mathbf{p}}$ são os elementos da diagonal da matriz de covariância ($\text{cov} \left\{ \hat{\mathbf{p}} \right\}$) então temos que a variância do k -ésimo parâmetro é

$$\text{var} \left\{ \hat{\mathbf{p}}_k \right\} = \sigma^2 \sum_{j=1}^M \frac{v_{kj}^2}{S_j^2}$$

Note que a variância do k -ésimo parâmetro estimado via estimador MQ ($N \geq M = r$) é inversamente proporcional aos valores singulares da matriz de sensibilidade $\overline{\mathbf{A}}$. Os elementos da matriz de autovetores (v_{kj}) não exercem influência na

variância dos parâmetros pois $\sum_{j=1}^M v_{kj}^2 = 1$. Concluimos, também, através da matriz de covariância de $\hat{\mathbf{p}}$ que a presença de valores singulares próximos a zero causam a instabilidade da solução estimada via estimador MQ pois haverá uma amplificação do ruído contido nos dados (variável σ^2 que é a variância do ruído dos dados).

Análise do ajuste dos dados observados produzido pela solução estimada via Mínimos Quadrados

Vamos analisar o ajuste dos dados observados produzido pela solução estimada via estimador MQ. Considerando que os dados observados estão contaminados por ruído aleatório aditivo $\bar{\boldsymbol{\varepsilon}}$ e que em um problema linear a componente determinística (vetor dos dados ajustados ou calculados) é $\bar{\mathbf{y}}^c = \bar{\mathbf{A}} \bar{\mathbf{p}}$. Então os dados geofísicos observados $\bar{\mathbf{y}}^o$ pode ser expresso por

$$\bar{\mathbf{y}}^o = \bar{\mathbf{y}}^c + \bar{\boldsymbol{\varepsilon}}$$

$$\bar{\mathbf{y}}^o = \bar{\mathbf{A}} \bar{\mathbf{p}} + \bar{\boldsymbol{\varepsilon}}$$

Como a estimativa do vetor de parâmetros via estimador MQ é dado por

$$\hat{\bar{\mathbf{p}}} = \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{y}}^o,$$

então o ajuste dos dados observados produzido pela solução estimada via estimador MQ é um AJUSTE dado por

$$\bar{\mathbf{y}}^o = \bar{\mathbf{A}} \hat{\bar{\mathbf{p}}} + \bar{\boldsymbol{\varepsilon}}$$

$$\bar{\mathbf{y}}^o = \bar{\mathbf{A}} \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{y}}^o + \bar{\boldsymbol{\varepsilon}}$$

$$\bar{\boldsymbol{\varepsilon}} = \bar{\mathbf{y}}^o - \bar{\mathbf{A}} \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{y}}^o$$

$$\bar{\varepsilon} = \left[\bar{\mathbf{I}} - \bar{\mathbf{A}} \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \right] \bar{\mathbf{y}}^o$$

Fazendo a decomposição em valores singulares e lembrando que $r = M$ para o estimador MQ temos que o resíduo é dado por

$$\bar{\varepsilon} = \left[\bar{\mathbf{I}} - \bar{\mathbf{U}}_M \bar{\mathbf{S}}_M \bar{\mathbf{V}}_M^T \left(\bar{\mathbf{V}}_M \bar{\mathbf{S}}_M \bar{\mathbf{U}}_M^T \bar{\mathbf{U}}_M \bar{\mathbf{S}}_M \bar{\mathbf{V}}_M^T \right)^{-1} \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M \bar{\mathbf{U}}_M^T \right] \bar{\mathbf{y}}^o$$

Como $\bar{\mathbf{U}}_M^T \bar{\mathbf{U}}_M = \bar{\mathbf{I}}_M$ temos que

$$\bar{\varepsilon} = \left[\bar{\mathbf{I}} - \bar{\mathbf{U}}_M \bar{\mathbf{S}}_M \bar{\mathbf{V}}_M^T \left(\bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^2 \bar{\mathbf{V}}_M^T \right)^{-1} \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M \bar{\mathbf{U}}_M^T \right] \bar{\mathbf{y}}^o$$

Como no estimador MQ o posto da matriz $\bar{\mathbf{A}}$ é igual ao número de parâmetros (i.e., $r = M$) temos que $\bar{\mathbf{V}}_M^{-1} = \bar{\mathbf{V}}_M^T$. Usando a propriedade da inversa do produto de várias matrizes é o produto das inversas na ordem inversa [i.e. $(\bar{\mathbf{A}}\bar{\mathbf{C}}\bar{\mathbf{B}})^{-1} = \bar{\mathbf{B}}^{-1}\bar{\mathbf{C}}^{-1}\bar{\mathbf{A}}^{-1}$]

então o termo a ser invertido na equação acima

$$\begin{aligned} \left(\bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^2 \bar{\mathbf{V}}_M^T \right)^{-1} &= \left(\bar{\mathbf{V}}_M^T \right)^{-1} \bar{\mathbf{S}}_M^{-2} \left(\bar{\mathbf{V}}_M \right)^{-1} \\ &= \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^{-2} \bar{\mathbf{V}}_M^T \end{aligned}$$

Logo o vetor de resíduos do estimador MQ pode ser escrito como

$$\bar{\varepsilon} = \left[\bar{\mathbf{I}} - \bar{\mathbf{U}}_M \bar{\mathbf{S}}_M \bar{\mathbf{V}}_M^T \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^{-2} \bar{\mathbf{V}}_M^T \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M \bar{\mathbf{U}}_M^T \right] \bar{\mathbf{y}}^o$$

Como $\bar{\mathbf{V}}_M^T \bar{\mathbf{V}}_M = \bar{\mathbf{I}}_M$ temos que o resíduo é dado por

$$\bar{\varepsilon} = \left[\bar{\mathbf{I}} - \bar{\mathbf{U}}_M \bar{\mathbf{S}}_M \bar{\mathbf{S}}_M^{-2} \bar{\mathbf{S}}_M \bar{\mathbf{U}}_M^T \right] \bar{\mathbf{y}}^o$$

$$\bar{\varepsilon} = \left[\bar{\mathbf{I}} - \bar{\mathbf{U}}_M \bar{\mathbf{U}}_M^T \right] \bar{\mathbf{y}}^o$$

Como $\overline{\overline{\mathbf{U}}}_r \overline{\overline{\mathbf{U}}}_r^T + \overline{\overline{\mathbf{U}}}_{N-r} \overline{\overline{\mathbf{U}}}_{N-r}^T = \overline{\overline{\mathbf{I}}}_{(N \times N)}$ e $r = M$ temos que

$$\overline{\overline{\mathbf{U}}}_M \overline{\overline{\mathbf{U}}}_M^T + \overline{\overline{\mathbf{U}}}_{N-M} \overline{\overline{\mathbf{U}}}_{N-M}^T = \overline{\overline{\mathbf{I}}}_{(N \times N)} \quad \text{portanto} \quad \overline{\overline{\mathbf{U}}}_{N-M} \overline{\overline{\mathbf{U}}}_{N-M}^T = \overline{\overline{\mathbf{I}}}_{(N \times N)} - \overline{\overline{\mathbf{U}}}_M \overline{\overline{\mathbf{U}}}_M^T.$$

Desta forma o vetor de resíduos do estimador MQ pode ser escrito como

$$\overline{\overline{\boldsymbol{\varepsilon}}} = \overline{\overline{\mathbf{U}}}_{N-M} \overline{\overline{\mathbf{U}}}_{N-M}^T \overline{\overline{\mathbf{y}}}^o$$

Logo os resíduos do estimador MQ é a projeção dos dados observados no espaço não iluminado das observações.