

Medidas de Eficiência dos Estimadores Genéricos

Obtemos as duas equações dos estimadores gerais $\tilde{\mathbf{p}}$ que chamaremos de **estimador genérico** são:

$$\tilde{\mathbf{p}} = \bar{\mathbf{p}}^0 + \left(\bar{\mathbf{A}}^T \bar{\mathbf{W}}_y \bar{\mathbf{A}} + \mu(\delta) \bar{\mathbf{W}}_p \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}}_y (\bar{\mathbf{y}}^0 - \bar{\mathbf{A}} \bar{\mathbf{p}}^0) \quad (1)$$

e

$$\tilde{\mathbf{p}} = \bar{\mathbf{p}}^0 + \bar{\mathbf{W}}_p^{-1} \bar{\mathbf{A}}^T \left[\bar{\mathbf{A}} \bar{\mathbf{W}}_p^{-1} \bar{\mathbf{A}}^T + \mu(\delta) \bar{\mathbf{W}}_y^{-1} \right]^{-1} (\bar{\mathbf{y}}^0 - \bar{\mathbf{A}} \bar{\mathbf{p}}^0) \quad (2)$$

Dentre os possíveis medidores de eficiência e desempenho dos estimadores $\tilde{\mathbf{p}}$ consideraremos:

1. A esperança de $\tilde{\mathbf{p}}$;
2. A matriz de covariância de $\tilde{\mathbf{p}}$;
3. A esperança da distância $(\tilde{\mathbf{p}} - \bar{\mathbf{p}})^T (\tilde{\mathbf{p}} - \bar{\mathbf{p}})$
4. A matriz de resolução associada a $\tilde{\mathbf{p}}$; e
5. A matriz de densidade de informação associada a $\tilde{\mathbf{p}}$;

Os estimadores genérico (1) e (2) podem ser escritos na forma geral

$$\tilde{\mathbf{p}} = \bar{\mathbf{p}}^0 + \bar{\mathbf{H}} (\bar{\mathbf{y}}^0 - \bar{\mathbf{A}} \bar{\mathbf{p}}^0)$$

(3)

com

$$\bar{\mathbf{H}} = \left(\bar{\mathbf{A}}^T \bar{\mathbf{W}}_y \bar{\mathbf{A}} + \mu(\delta) \bar{\mathbf{W}}_p \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}}_y \quad (4)$$

no caso do estimador (1) e com

$$\bar{\mathbf{H}} = \bar{\mathbf{W}}_p^{-1} \bar{\mathbf{A}}^T \left[\bar{\mathbf{A}} \bar{\mathbf{W}}_p^{-1} \bar{\mathbf{A}}^T + \mu(\delta) \bar{\mathbf{W}}_y^{-1} \right]^{-1} \quad (5)$$

no caso do estimador (2) .

Análise estatística da solução estimada :

(1) Esperança de $\tilde{\mathbf{p}}$:

Considerando as premissas estatísticas estabelecidas na Figura 1 e as propriedades da esperança, temos que a esperança dos estimadores genéricos escritos na forma (3) é

$$E \left\{ \tilde{\mathbf{p}} \right\} = E \left\{ \mathbf{p}^o + \overline{\mathbf{H}} \left(\mathbf{y}^o - \overline{\mathbf{A}} \mathbf{p}^o \right) \right\}$$

$$E \left\{ \tilde{\mathbf{p}} \right\} = E \left\{ \mathbf{p}^o \right\} + E \left\{ \overline{\mathbf{H}} \mathbf{y}^o \right\} - E \left\{ \overline{\mathbf{H}} \overline{\mathbf{A}} \mathbf{p}^o \right\}$$

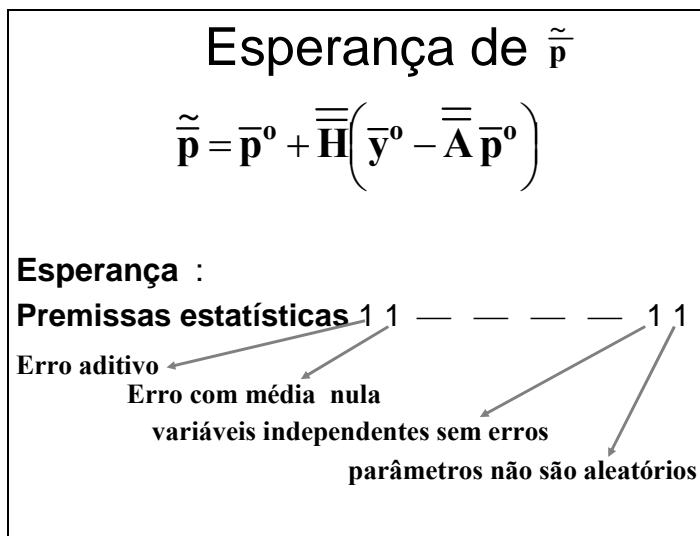


Figura 1

Usando a premissa 7 que as variáveis independentes não são v.a. temos

$$E \left\{ \tilde{\mathbf{p}} \right\} = \mathbf{p}^o + \overline{\mathbf{H}} E \left\{ \mathbf{y}^o \right\} - \overline{\mathbf{H}} \overline{\mathbf{A}} \mathbf{p}^o$$

$$E \left\{ \tilde{\mathbf{p}} \right\} = \overline{\mathbf{H}} E \left\{ \mathbf{y}^o \right\} + \left(\overline{\mathbf{I}} - \overline{\mathbf{H}} \overline{\mathbf{A}} \right) \mathbf{p}^o$$

Usando a premissa 1 que os erros são aditivos ($\mathbf{y}^o = \mathbf{y}^c + \boldsymbol{\varepsilon}$) e usando a informação que em um problema linear a componente determinística (vetor dos dados ajustados ou calculados) é $\mathbf{y}^c = \overline{\mathbf{A}} \mathbf{p}$ temos que

$$E \left\{ \tilde{\mathbf{p}} \right\} = \overline{\mathbf{H}} E \left\{ \overline{\mathbf{A}} \mathbf{p} + \boldsymbol{\varepsilon} \right\} + \left(\overline{\mathbf{I}} - \overline{\mathbf{H}} \overline{\mathbf{A}} \right) \mathbf{p}^o$$

$$E \left\{ \tilde{\mathbf{p}} \right\} = \overline{\mathbf{H}} E \left\{ \overline{\mathbf{A}} \overline{\mathbf{p}} \right\} + \overline{\mathbf{H}} E \{ \boldsymbol{\varepsilon} \} + \left(\overline{\mathbf{I}} - \overline{\mathbf{H}} \overline{\mathbf{A}} \right) \overline{\mathbf{p}}^0$$

Pela premissa 2 os erros tem média nula o que implica $E[\boldsymbol{\varepsilon}] = \overline{\mathbf{0}}$ então

$$E \left\{ \tilde{\mathbf{p}} \right\} = \overline{\mathbf{H}} E \left\{ \overline{\mathbf{A}} \overline{\mathbf{p}} \right\} + \left(\overline{\mathbf{I}} - \overline{\mathbf{H}} \overline{\mathbf{A}} \right) \overline{\mathbf{p}}^0$$

Usando a premissa 7 que as variáveis independentes não são v.a. temos

$$E \left\{ \tilde{\mathbf{p}} \right\} = \overline{\mathbf{H}} \overline{\mathbf{A}} E \left\{ \overline{\mathbf{p}} \right\} + \left(\overline{\mathbf{I}} - \overline{\mathbf{H}} \overline{\mathbf{A}} \right) \overline{\mathbf{p}}^0$$

Usando a premissa 8 que os parâmetros não são v.a. temos

$$E \left\{ \tilde{\mathbf{p}} \right\} = \overline{\mathbf{H}} \overline{\mathbf{A}} \overline{\mathbf{p}} + \left(\overline{\mathbf{I}} - \overline{\mathbf{H}} \overline{\mathbf{A}} \right) \overline{\mathbf{p}}^0 \quad (6)$$

(2) Matriz de covariância de $\tilde{\mathbf{p}}$:

Considerando as premissas estatísticas estabelecidas na Figura 2 e as propriedades da variância, temos que

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = E \left\{ \left[\hat{\mathbf{p}} - E(\hat{\mathbf{p}}) \right] \left[\hat{\mathbf{p}} - E(\hat{\mathbf{p}}) \right]^T \right\}$$

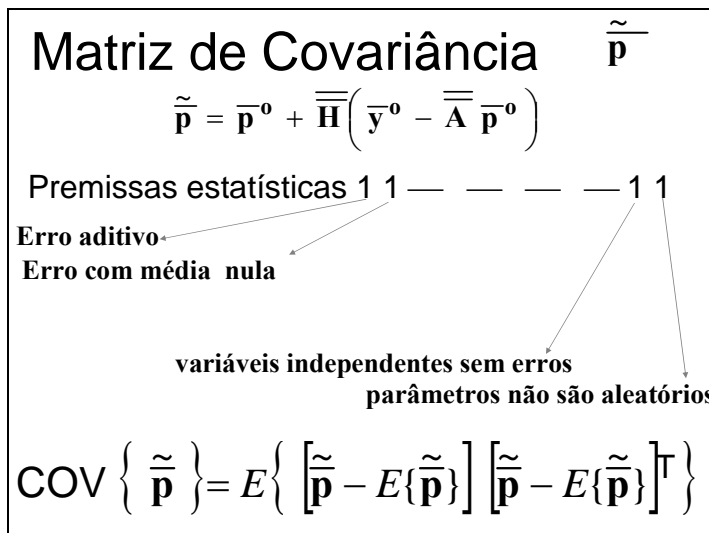


Figura 2

como o estimador genérico [equação (3)] é

$$\tilde{\mathbf{p}} = \overline{\mathbf{p}}^0 + \overline{\mathbf{H}} \left(\overline{\mathbf{y}}^0 - \overline{\mathbf{A}} \overline{\mathbf{p}}^0 \right)$$

e, pela equação (6), a esperança de $\tilde{\mathbf{p}}$

$$E \left\{ \tilde{\mathbf{p}} \right\} = \overline{\overline{\mathbf{H} \mathbf{A}}} \overline{\mathbf{p}} + \left(\overline{\mathbf{I}} - \overline{\overline{\mathbf{H} \mathbf{A}}} \right) \overline{\mathbf{p}}^o$$

então temos que

$$\text{COV} \left\{ \tilde{\mathbf{p}} \right\} = E \left\{ \left[\tilde{\mathbf{p}} - E \left(\tilde{\mathbf{p}} \right) \right] \left[\tilde{\mathbf{p}} - E \left(\tilde{\mathbf{p}} \right) \right]^T \right\}$$

$$\text{COV} \left\{ \tilde{\mathbf{p}} \right\} = E \left\{ \left[\overline{\mathbf{p}}^o + \overline{\overline{\mathbf{H}}} \left(\overline{\mathbf{y}}^o - \overline{\overline{\mathbf{A}}} \overline{\mathbf{p}}^o \right) - \overline{\overline{\mathbf{H} \mathbf{A}}} \overline{\mathbf{p}} - \left(\overline{\mathbf{I}} - \overline{\overline{\mathbf{H} \mathbf{A}}} \right) \overline{\mathbf{p}}^o \right] \right. \\ \left. \left[\overline{\mathbf{p}}^o + \overline{\overline{\mathbf{H}}} \left(\overline{\mathbf{y}}^o - \overline{\overline{\mathbf{A}}} \overline{\mathbf{p}}^o \right) - \overline{\overline{\mathbf{H} \mathbf{A}}} \overline{\mathbf{p}} - \left(\overline{\mathbf{I}} - \overline{\overline{\mathbf{H} \mathbf{A}}} \right) \overline{\mathbf{p}}^o \right]^T \right\}$$

$$\text{COV} \left\{ \tilde{\mathbf{p}} \right\} = E \left\{ \left[\overline{\mathbf{p}}^o + \overline{\overline{\mathbf{H}}} \overline{\mathbf{y}}^o - \overline{\overline{\mathbf{H} \mathbf{A}}} \overline{\mathbf{p}}^o - \overline{\overline{\mathbf{H} \mathbf{A}}} \overline{\mathbf{p}} - \overline{\mathbf{p}}^o + \overline{\overline{\mathbf{H} \mathbf{A}}} \overline{\mathbf{p}}^o \right] \right. \\ \left. \left[\overline{\mathbf{p}}^o + \overline{\overline{\mathbf{H}}} \overline{\mathbf{y}}^o - \overline{\overline{\mathbf{H} \mathbf{A}}} \overline{\mathbf{p}}^o - \overline{\overline{\mathbf{H} \mathbf{A}}} \overline{\mathbf{p}} - \overline{\mathbf{p}}^o + \overline{\overline{\mathbf{H} \mathbf{A}}} \overline{\mathbf{p}}^o \right]^T \right\}$$

$$\text{COV} \left\{ \tilde{\mathbf{p}} \right\} = E \left\{ \left[\overline{\overline{\mathbf{H}}} \overline{\mathbf{y}}^o - \overline{\overline{\mathbf{H} \mathbf{A}}} \overline{\mathbf{p}} \right] \left[\overline{\overline{\mathbf{H}}} \overline{\mathbf{y}}^o - \overline{\overline{\mathbf{H} \mathbf{A}}} \overline{\mathbf{p}} \right]^T \right\}$$

$$\text{COV} \left\{ \tilde{\mathbf{p}} \right\} = E \left\{ \left[\overline{\overline{\mathbf{H}}} \left(\overline{\mathbf{y}}^o - \overline{\overline{\mathbf{A}}} \overline{\mathbf{p}} \right) \right] \left[\overline{\overline{\mathbf{H}}} \left(\overline{\mathbf{y}}^o - \overline{\overline{\mathbf{A}}} \overline{\mathbf{p}} \right) \right]^T \right\}$$

$$\text{COV} \left\{ \tilde{\mathbf{p}} \right\} = E \left\{ \left[\overline{\overline{\mathbf{H}}} \overline{\boldsymbol{\varepsilon}} \right] \left[\overline{\overline{\mathbf{H}}} \overline{\boldsymbol{\varepsilon}} \right]^T \right\}$$

$$\text{COV} \left\{ \tilde{\mathbf{p}} \right\} = E \left\{ \overline{\overline{\mathbf{H}}} \overline{\boldsymbol{\varepsilon}} \overline{\boldsymbol{\varepsilon}}^T \overline{\overline{\mathbf{H}}}^T \right\}$$

Usando a premissa 7 que as variáveis independentes não são v.a. temos

$$\text{COV} \left\{ \tilde{\mathbf{p}} \right\} = \overline{\overline{\mathbf{H}}} E \left\{ \overline{\boldsymbol{\varepsilon}} \overline{\boldsymbol{\varepsilon}}^T \right\} \overline{\overline{\mathbf{H}}}^T$$

A esperança de $E \left\{ \overline{\boldsymbol{\varepsilon}} \overline{\boldsymbol{\varepsilon}}^T \right\}$ que nada mais é que a esperança de uma forma quadrática

(já vimos no Apêndice Matriz de Covariância dos Erros) que

$$E \left\{ \overline{\mathbf{x}} \overline{\mathbf{x}}^T \right\} = \text{cov}(\overline{\mathbf{x}}) + E(\overline{\mathbf{x}}) E(\overline{\mathbf{x}}^T)$$

Pela premissa 2 os erros tem média nula o que implica $E[\overline{\mathbf{e}}] = \overline{\mathbf{0}}$ temos que

$$E \left\{ \overline{\mathbf{x}} \overline{\mathbf{x}}^T \right\} = \text{cov}(\overline{\mathbf{x}})$$

Logo a covariância do estimador genérico é

$$\boxed{\text{COV} \left\{ \tilde{\overline{\mathbf{p}}} \right\} = \overline{\overline{\mathbf{H}}} \text{cov} \left\{ \overline{\mathbf{x}} \right\} \overline{\overline{\mathbf{H}}}^T} \quad (7)$$

(3) Esperança da distância entre $\tilde{\overline{\mathbf{p}}}$ e $\overline{\mathbf{p}}$:

A distância entre $\tilde{\overline{\mathbf{p}}}$ e $\overline{\mathbf{p}}$ pode ser expressa por

$$\|\tilde{\overline{\mathbf{p}}} - \overline{\mathbf{p}}\|_2^2 = (\tilde{\overline{\mathbf{p}}} - \overline{\mathbf{p}})^T (\tilde{\overline{\mathbf{p}}} - \overline{\mathbf{p}})$$

Vamos então calcular a esperança da distância entre $\tilde{\overline{\mathbf{p}}}$ e $\overline{\mathbf{p}}$ i.e.,

$$E \left\{ [\tilde{\overline{\mathbf{p}}} - \overline{\mathbf{p}}]^T [\tilde{\overline{\mathbf{p}}} - \overline{\mathbf{p}}] \right\}$$

Veja que temos a esperança de uma forma quadrática $E \left\{ \overline{\mathbf{x}}^T \overline{\mathbf{x}} \right\}$ é

$$E \left\{ \overline{\mathbf{x}}^T \overline{\mathbf{x}} \right\} = \text{Tr} \left\{ \text{cov}(\overline{\mathbf{x}}) \right\} + E \left\{ \overline{\mathbf{x}}^T \right\} E \left\{ \overline{\mathbf{x}} \right\}$$

isto porque

$$\text{cov} \left\{ \overline{\mathbf{x}} \right\} = E \left\{ [\overline{\mathbf{x}} - E \left\{ \overline{\mathbf{x}} \right\}] [\overline{\mathbf{x}} - E \left\{ \overline{\mathbf{x}} \right\}]^T \right\}$$

$$\text{cov} \left\{ \overline{\mathbf{x}} \right\} = E \left\{ \overline{\mathbf{x}} \overline{\mathbf{x}}^T \right\} - 2 E \left\{ \overline{\mathbf{x}} \right\} E \left\{ \overline{\mathbf{x}} \right\}^T + E \left\{ \overline{\mathbf{x}} \right\} E \left\{ \overline{\mathbf{x}} \right\}^T$$

$$\text{cov} \left\{ \overline{\mathbf{x}} \right\} = E \left\{ \overline{\mathbf{x}} \overline{\mathbf{x}}^T \right\} - E \left\{ \overline{\mathbf{x}} \right\} E \left\{ \overline{\mathbf{x}} \right\}^T$$

$$E \left\{ \overline{\mathbf{x}} \overline{\mathbf{x}}^T \right\} = \text{cov} \left\{ \overline{\mathbf{x}} \right\} + E \left\{ \overline{\mathbf{x}} \right\} E \left\{ \overline{\mathbf{x}} \right\}^T$$

Usando o operador traço temos:

$$tr \left\{ E \left\{ \overline{\mathbf{x}} \overline{\mathbf{x}}^T \right\} \right\} = tr \left\{ \text{cov} \left\{ \overline{\mathbf{x}} \right\} \right\} + tr \left\{ E \left\{ \overline{\mathbf{x}} \right\} E \left\{ \overline{\mathbf{x}} \right\}^T \right\}$$

$$E \left\{ \overline{\mathbf{x}}^T \overline{\mathbf{x}} \right\} = tr \left\{ \text{cov} \left\{ \overline{\mathbf{x}} \right\} \right\} + E \left\{ \overline{\mathbf{x}}^T \right\} E \left\{ \overline{\mathbf{x}} \right\}$$

Então a

$$E \left\{ [\tilde{\mathbf{p}} - \overline{\mathbf{p}}]^T [\tilde{\mathbf{p}} - \overline{\mathbf{p}}] \right\} = tr \left\{ \text{cov}(\tilde{\mathbf{p}} - \overline{\mathbf{p}}) \right\} + E \left\{ (\tilde{\mathbf{p}} - \overline{\mathbf{p}})^T \right\} E \left\{ (\tilde{\mathbf{p}} - \overline{\mathbf{p}}) \right\}$$

Vamos calcular o termo

$$E \left\{ (\tilde{\mathbf{p}} - \overline{\mathbf{p}}) \right\} = E \left\{ \tilde{\mathbf{p}} \right\} - E \left\{ \overline{\mathbf{p}} \right\}$$

$$E \left\{ (\tilde{\mathbf{p}} - \overline{\mathbf{p}}) \right\} = E \left\{ \tilde{\mathbf{p}} \right\} - \overline{\mathbf{p}}$$

Substituindo a equação (6) temos

$$E \left\{ (\tilde{\mathbf{p}} - \overline{\mathbf{p}}) \right\} = \overline{\overline{\mathbf{H}\mathbf{A}}} \overline{\mathbf{p}} + \left(\overline{\mathbf{I}} - \overline{\overline{\mathbf{H}\mathbf{A}}} \right) \overline{\mathbf{p}}^0 - \overline{\mathbf{p}}$$

$$E \left\{ (\tilde{\mathbf{p}} - \overline{\mathbf{p}}) \right\} = \left(\overline{\overline{\mathbf{H}\mathbf{A}}} - \overline{\mathbf{I}} \right) \overline{\mathbf{p}} + \left(\overline{\mathbf{I}} - \overline{\overline{\mathbf{H}\mathbf{A}}} \right) \overline{\mathbf{p}}^0$$

$$E \left\{ (\tilde{\mathbf{p}} - \overline{\mathbf{p}}) \right\} = \left(\overline{\overline{\mathbf{H}\mathbf{A}}} - \overline{\mathbf{I}} \right) (\overline{\mathbf{p}} - \overline{\mathbf{p}}^0)$$

Substituindo a equação acima na expressão da Esperança da distância temos

$$E \left\{ [\tilde{\mathbf{p}} - \overline{\mathbf{p}}]^T [\tilde{\mathbf{p}} - \overline{\mathbf{p}}] \right\} = tr \left\{ \text{cov}(\tilde{\mathbf{p}} - \overline{\mathbf{p}}) \right\} + (\overline{\mathbf{p}} - \overline{\mathbf{p}}^0)^T \left(\overline{\overline{\mathbf{H}\mathbf{A}}} - \overline{\mathbf{I}} \right)^T \left(\overline{\overline{\mathbf{H}\mathbf{A}}} - \overline{\mathbf{I}} \right) (\overline{\mathbf{p}} - \overline{\mathbf{p}}^0)$$

Como a covariância de uma constante é zero então a $\text{cov}(\tilde{\mathbf{p}} - \overline{\mathbf{p}}) = \text{cov}(\tilde{\mathbf{p}})$.

Substituindo a equação (7) na equação acima temos

$$E\{[\tilde{\mathbf{p}} - \bar{\mathbf{p}}]^T [\tilde{\mathbf{p}} - \bar{\mathbf{p}}]\} = tr\{cov(\tilde{\mathbf{p}})\} + (\bar{\mathbf{p}} - \bar{\mathbf{p}}^o)^T (\overline{\mathbf{H}\mathbf{A}} - \bar{\mathbf{I}})^T (\overline{\mathbf{H}\mathbf{A}} - \bar{\mathbf{I}})(\bar{\mathbf{p}} - \bar{\mathbf{p}}^o) \quad (8)$$

Da equação (6) temos que

$$E\left\{\tilde{\mathbf{p}}\right\} = \overline{\mathbf{H}\mathbf{A}}\bar{\mathbf{p}} + \left(\bar{\mathbf{I}} - \overline{\mathbf{H}\mathbf{A}}\right)\bar{\mathbf{p}}^o$$

reescrevendo esta equação temos que

$$E\left\{\tilde{\mathbf{p}}\right\} = \overline{\mathbf{H}\mathbf{A}}(\bar{\mathbf{p}} - \bar{\mathbf{p}}^o) + \bar{\mathbf{p}}^o$$

subtraindo dos dois lados da equação acima $\bar{\mathbf{p}}$ temos

$$E\left\{\tilde{\mathbf{p}}\right\} - \bar{\mathbf{p}} = \overline{\mathbf{H}\mathbf{A}}(\bar{\mathbf{p}} - \bar{\mathbf{p}}^o) + \bar{\mathbf{p}}^o - \bar{\mathbf{p}}$$

$$E\left\{\tilde{\mathbf{p}}\right\} - \bar{\mathbf{p}} = \left(\overline{\mathbf{H}\mathbf{A}} - \bar{\mathbf{I}}\right)(\bar{\mathbf{p}} - \bar{\mathbf{p}}^o)$$

$$E\left\{\tilde{\mathbf{p}}\right\} - \bar{\mathbf{p}} = \left(\overline{\mathbf{H}\mathbf{A}} - \bar{\mathbf{I}}\right)(\bar{\mathbf{p}} - \bar{\mathbf{p}}^o) \quad (9)$$

Comparando o segundo termo do somatório da equação (8) com a expressão (9),

podemos então reescrever a equação (8) como

$$E\{[\tilde{\mathbf{p}} - \bar{\mathbf{p}}]^T [\tilde{\mathbf{p}} - \bar{\mathbf{p}}]\} = tr\{cov(\tilde{\mathbf{p}})\} + \left[E\left\{\tilde{\mathbf{p}}\right\} - \bar{\mathbf{p}}\right]^T \left[E\left\{\tilde{\mathbf{p}}\right\} - \bar{\mathbf{p}}\right]$$

Como $\bar{\mathbf{u}}^T \bar{\mathbf{u}} = \|\bar{\mathbf{u}}\|_2^2$ então a equação acima da expressão da Esperança da

distância pode ser reescrita como

$$E\left\{\left\|\tilde{\mathbf{p}} - \bar{\mathbf{p}}\right\|_2^2\right\} = tr\{cov(\tilde{\mathbf{p}})\} + \left\|E\left\{\tilde{\mathbf{p}}\right\} - \bar{\mathbf{p}}\right\|_2^2 \quad (10)$$

Veja que a Esperança da distância $\|\tilde{\mathbf{p}} - \bar{\mathbf{p}}\|_2^2$ equação (10) é formada por duas parcelas:

1) $tr\{cov(\tilde{\mathbf{p}})\}$ é a primeira parcela e representa uma medida de covariância do estimador, ou seja, uma medida da estabilidade da solução estimada

2) $\|E\{\tilde{\mathbf{p}}\} - \bar{\mathbf{p}}\|_2^2$ é a segunda parcela representa uma medida da distância da esperança do estimador ($\tilde{\mathbf{p}}$) e o vetor de parâmetros ($\bar{\mathbf{p}}$). Veja portanto que esta segunda parcela é uma medida da tendenciosidade do estimador $\tilde{\mathbf{p}}$

(4) A matriz de resolução associada a $\tilde{\mathbf{p}} - \bar{\mathbf{p}}^0$;

Vamos considerar que os nossos dados geofísicos estão livres de ruído. Imagine que exista um conjunto de parâmetros desconhecido que explique os dados geofísicos sem ruído, ou seja, $\bar{\mathbf{y}}^0 = \bar{\mathbf{A}}\bar{\mathbf{p}}$. Sob estas premissas o estimador genérico (3),

$$\tilde{\mathbf{p}} = \bar{\mathbf{p}}^0 + \bar{\mathbf{H}}\left(\bar{\mathbf{y}}^0 - \bar{\mathbf{A}}\bar{\mathbf{p}}^0\right),$$

pode ser reescrito como

$$\tilde{\mathbf{p}} = \bar{\mathbf{p}}^0 + \bar{\mathbf{H}}\left(\bar{\mathbf{A}}\bar{\mathbf{p}} - \bar{\mathbf{A}}\bar{\mathbf{p}}^0\right)$$

$$\tilde{\mathbf{p}} = \bar{\mathbf{p}}^0 + \bar{\mathbf{H}}\bar{\mathbf{A}}\left(\bar{\mathbf{p}} - \bar{\mathbf{p}}^0\right)$$

$$\tilde{\mathbf{p}} - \bar{\mathbf{p}}^0 = \bar{\mathbf{H}}\bar{\mathbf{A}}\left(\bar{\mathbf{p}} - \bar{\mathbf{p}}^0\right) \quad (11)$$

O produto $\bar{\mathbf{H}}\bar{\mathbf{A}}$ é chamada de matriz resolução de $\tilde{\mathbf{p}} - \bar{\mathbf{p}}^0$

$$\boxed{\bar{\mathbf{R}} = \bar{\mathbf{H}}\bar{\mathbf{A}}} \quad (12)$$

A matriz de resolução, $\bar{\mathbf{R}}$, é uma matriz de dimensão (M x M).

Note que a matriz de resolução é função apenas da matriz de sensibilidade ($\bar{\bar{A}}$), do kernel do nosso problema (matriz $\bar{\bar{H}}$) e das informações a priori adicionadas ao nosso problema (matrizes de peso).

Para entendermos o significado da matriz de resolução vamos considerar que $\bar{p}^o = \bar{0}$.

Então temos que

$$\begin{aligned}\tilde{\bar{p}} &= \bar{\bar{H}} \bar{\bar{A}} \bar{p} \\ \tilde{\bar{p}} &= \bar{\bar{R}} \bar{p}\end{aligned}\tag{13}$$

Veja que a matriz de resolução mede a proximidade entre uma solução particular estimada ($\tilde{\bar{p}}$) e a solução de parâmetros considerando os dados exatos, \bar{p} , i.e., considerando os dados sem ruído.

Vamos fazer agora um rearranjo da equação (9)

$$\begin{aligned}\tilde{\bar{p}} - \bar{p}^o &= \bar{\bar{H}} \bar{\bar{A}} (\bar{p} - \bar{p}^o) \\ \tilde{\bar{p}} &= \bar{p}^o + \bar{\bar{H}} \bar{\bar{A}} (\bar{p} - \bar{p}^o) \\ \tilde{\bar{p}} &= \bar{\bar{H}} \bar{\bar{A}} \bar{p} + \left(\bar{\bar{I}} - \bar{\bar{H}} \bar{\bar{A}} \right) \bar{p}^o\end{aligned}\tag{14}$$

Veja que se a matriz de resolução $\bar{\bar{R}} = \bar{\bar{H}} \bar{\bar{A}}$ for igual a matriz identidade, i.e., $\bar{\bar{R}} = \bar{\bar{I}}$ temos que

$$\tilde{\bar{p}} = \bar{p}$$

Neste caso em que $\overline{\overline{\mathbf{R}}} = \overline{\overline{\mathbf{I}}}$, então cada elemento do vetor de parâmetros é unicamente determinado, ou seja, os parâmetros podem ser estimados independentemente. Por outro lado, se a matriz de resolução for diferente da matriz identidade, $\overline{\overline{\mathbf{R}}} \neq \overline{\overline{\mathbf{I}}}$ então cada elemento do vetor de parâmetros estimados, $\tilde{\mathbf{p}}$, será uma soma ponderada de todos os elementos do vetor de parâmetros $\overline{\mathbf{p}}$. Veja que se considerarmos $\overline{\mathbf{p}}^0 = \overline{\mathbf{0}}$ temos que

$$\tilde{\mathbf{p}} = \overline{\overline{\mathbf{R}}} \overline{\mathbf{p}}$$

$$\begin{pmatrix} \tilde{p}_1 \\ \tilde{p}_2 \\ \vdots \\ \tilde{p}_M \end{pmatrix} = \begin{bmatrix} r_{11} & r_{12} & \cdots & r_{1M} \\ r_{21} & r_{22} & \cdots & r_{2M} \\ \vdots & \vdots & \vdots & \vdots \\ r_{M1} & r_{M2} & \cdots & r_{MM} \end{bmatrix} \begin{pmatrix} p_1 \\ p_2 \\ \vdots \\ p_M \end{pmatrix}$$

$$\tilde{p}_1 = r_{11} p_1 + r_{12} p_2 + \cdots + r_{1M} p_M ,$$

$$\tilde{p}_2 = r_{21} p_1 + r_{22} p_2 + \cdots + r_{2M} p_M$$

$$\vdots$$

Veja então que se a matriz de resolução for diferente da matriz identidade, $\overline{\overline{\mathbf{R}}} \neq \overline{\overline{\mathbf{I}}}$ o j-ésimo elemento do vetor de parâmetros estimados, $\tilde{\mathbf{p}}$ é

$$\begin{pmatrix} \tilde{p}_1 \\ \vdots \\ \tilde{p}_j \\ \vdots \end{pmatrix} = \begin{bmatrix} r_{11} & r_{12} & \cdots & r_{1M} \\ \vdots & \vdots & \cdots & \vdots \\ r_{j1} & r_{j2} & \vdots & r_{jM} \\ \vdots & \vdots & \cdots & \vdots \end{bmatrix} \begin{pmatrix} p_1 \\ \vdots \\ p_j \\ \vdots \end{pmatrix}$$

$$\tilde{p}_j = r_{j1} p_1 + r_{j2} p_2 + \cdots + r_{jM} p_M$$

$$\tilde{p}_j = \sum_{i=1}^M r_{ji} p_i$$

(5) A matriz densidade de informação (Data resolution matrix) associada a $\tilde{\mathbf{p}}$;

Estimamos um vetor de parâmetros $\tilde{\mathbf{p}}$

$$\tilde{\mathbf{p}} = \overline{\mathbf{p}}^0 + \overline{\mathbf{H}} \left(\overline{\mathbf{y}}^0 - \overline{\mathbf{A}} \overline{\mathbf{p}}^0 \right)$$

Este vetor de parâmetros estimado produz um ajuste (dados geofísicos estimados ou calculados pelo modelo $\tilde{\mathbf{p}}$) que é dado por

$$\tilde{\mathbf{y}} = \overline{\mathbf{A}} \tilde{\mathbf{p}}$$

$$\tilde{\mathbf{y}} = \overline{\mathbf{A}} \left[\overline{\mathbf{p}}^0 + \overline{\mathbf{H}} \left(\overline{\mathbf{y}}^0 - \overline{\mathbf{A}} \overline{\mathbf{p}}^0 \right) \right]$$

$$\tilde{\mathbf{y}} = \overline{\mathbf{A}} \overline{\mathbf{p}}^0 + \overline{\mathbf{A}} \overline{\mathbf{H}} \overline{\mathbf{y}}^0 - \overline{\mathbf{A}} \overline{\mathbf{H}} \overline{\mathbf{A}} \overline{\mathbf{p}}^0 \quad (15)$$

Vamos considerar que $\overline{\mathbf{y}}^a = \overline{\mathbf{A}} \overline{\mathbf{p}}^0$, ou seja, o vetor de parâmetros a priori, $\overline{\mathbf{p}}^0$, produz um ajuste $\overline{\mathbf{y}}^a$. Então $\overline{\mathbf{y}}^a$ é a resposta geofísica calculada pelo modelo de parâmetros $\overline{\mathbf{p}}^0$. Então a equação (15) pode ser reescrita como

$$\begin{aligned}\tilde{\bar{\mathbf{y}}} &= \bar{\mathbf{y}}^a + \overline{\overline{\mathbf{A} \mathbf{H}}} \bar{\mathbf{y}}^o - \overline{\overline{\mathbf{A} \mathbf{H}}} \bar{\mathbf{y}}^a \\ \tilde{\bar{\mathbf{y}}} - \bar{\mathbf{y}}^a &= \overline{\overline{\mathbf{A} \mathbf{H}}} (\bar{\mathbf{y}}^o - \bar{\mathbf{y}}^a)\end{aligned}\quad (16)$$

O produto $\overline{\overline{\mathbf{A} \mathbf{H}}}$ é chamado de matriz densidade de informação de $\tilde{\bar{\mathbf{y}}} - \bar{\mathbf{y}}^a$.

$$\boxed{\begin{matrix} \overline{\overline{\mathbf{F}}} \\ (N \times N) \end{matrix}} = \overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{H}}}\quad (17)$$

A matriz densidade de informação, $\overline{\overline{\mathbf{F}}}$, é uma matriz de dimensão (N x N). Note que a matriz densidade de informação é função apenas da matriz de sensibilidade ($\overline{\overline{\mathbf{A}}}$), do kernel do nosso problema (matriz $\overline{\overline{\mathbf{H}}}$) e das informações a priori adicionadas ao nosso problema (matrizes de peso).

Para entendermos o significado da matriz densidade de informação, $\overline{\overline{\mathbf{F}}}$, vamos considerar que $\bar{\mathbf{p}}^o = \bar{\mathbf{0}}$. Então temos que a equação (15),

$$\tilde{\bar{\mathbf{y}}} = \overline{\overline{\mathbf{A}}} \bar{\mathbf{p}}^o + \overline{\overline{\mathbf{A} \mathbf{H}}} \bar{\mathbf{y}}^o - \overline{\overline{\mathbf{A} \mathbf{H} \mathbf{A}}} \bar{\mathbf{p}}^o,$$

pode ser reescrita como

$$\tilde{\bar{\mathbf{y}}} = \overline{\overline{\mathbf{A} \mathbf{H}}} \bar{\mathbf{y}}^o \quad (18)$$

Veja que se a matriz densidade de informação, $\overline{\overline{\mathbf{F}}} = \overline{\overline{\mathbf{A} \mathbf{H}}}$, for igual a matriz identidade, i.e., $\overline{\overline{\mathbf{F}}} = \bar{\mathbf{I}}$ temos que

$$\tilde{\bar{\mathbf{y}}} = \bar{\mathbf{y}}^o$$

Neste caso em que $\overline{\overline{\mathbf{F}}} = \bar{\mathbf{I}}$, então o dado geofísico observado, $\bar{\mathbf{y}}^o$, é exatamente igual ao dado geofísico estimado, $\tilde{\bar{\mathbf{y}}}$. Isto significa dizer que o erro (ruído) dos dados é

zero, $\bar{\epsilon} = \bar{0}$. Veja que a matriz densidade de informação, $\bar{\bar{F}}$, mede a proximidade entre os dados observados e os dados ajustados. Em outras palavras a matriz densidade de informação, $\bar{\bar{F}}$, diz o quão próximo os dados estimados $\tilde{\bar{y}}$ estão dos dados geofísicos observados, \bar{y}^o . Vamos calcular o resíduo $\bar{\epsilon}$

$$\bar{\epsilon} = \bar{y}^o - \tilde{\bar{y}}$$

Usando a equação que $\tilde{\bar{y}} = \bar{y}^a + \bar{\bar{A}} \bar{\bar{H}} \bar{y}^o - \bar{\bar{A}} \bar{\bar{H}} \bar{y}^a$ temos

$$\begin{aligned}\bar{\epsilon} &= \bar{y}^o - \bar{y}^a - \bar{\bar{A}} \bar{\bar{H}} \bar{y}^o + \bar{\bar{A}} \bar{\bar{H}} \bar{y}^a \\ \bar{\epsilon} &= \left(\bar{\bar{I}} - \bar{\bar{A}} \bar{\bar{H}} \right) (\bar{y}^o - \bar{y}^a)\end{aligned}\tag{19}$$

A equação (18) mostra explicitamente que se a matriz densidade de informação, $\bar{\bar{F}} = \bar{\bar{A}} \bar{\bar{H}}$, for igual a matriz identidade, i.e., $\bar{\bar{F}} = \bar{\bar{I}}$ temos que o erro (ruído) será zero $\bar{\epsilon} = \bar{0}$. Isto não é desejável porque os dados contém ruído.

Por outro lado, se a matriz densidade de informação for diferente da matriz identidade,

$\bar{\bar{F}} \neq \bar{\bar{I}}$ então cada elemento do vetor de dados estimados, $\tilde{\bar{y}}$, será uma soma ponderada de todos os elementos que compõem o vetor de dados observados \bar{y}^o .

Veja que se considerarmos $\bar{p}^o = \bar{0}$ temos que

$$\begin{pmatrix} \tilde{y}_1 \\ \vdots \\ \tilde{y}_i \\ \vdots \\ \tilde{y}_N \end{pmatrix} = \begin{bmatrix} F_{11} & F_{12} & \cdots & F_{1N} \\ \vdots & \vdots & & \vdots \\ F_{i1} & F_{i2} & \cdots & F_{iN} \\ \vdots & \vdots & & \vdots \\ F_{N1} & F_{N2} & \cdots & F_{NN} \end{bmatrix} \begin{pmatrix} y_1^o \\ y_2^o \\ \vdots \\ y_N^o \end{pmatrix}$$

Veja então que se a matriz densidade de informação for diferente da matriz identidade, $\bar{\bar{\mathbf{F}}} \neq \bar{\bar{\mathbf{I}}}$ então o j -ésimo elemento do vetor de dados estimados, $\tilde{\mathbf{y}}$, é

$$\tilde{y}_i = F_{i1} y_1^o + F_{i2} y_2^o + \cdots + F_{iN} y_N^o$$

$$\tilde{y}_i = \sum_{j=1}^N F_{ij} y_j^o .$$