

Análise dos estimadores MQ e MQ-SUB via Estimador Genérico:

Apresentaremos neste tópico a dedução dos estimadores MQ e MQ-sub através dos estimadores genéricos. Em seguida apresentaremos as medidas de eficiências, i.e. Esperança, Covariância. Matriz de Resolução, Matriz Densidade de Informação, dos estimadores MQ e MQ-sub a partir das genéricas destas medidas (equações deduzidas no tópico 30).

REVISÃO:

Obtemos, no Tópico 20 as duas equações dos estimadores gerais $\tilde{\mathbf{p}}$ que chamamos de **estimador genérico** são:

$$\tilde{\mathbf{p}} = \bar{\mathbf{p}}^0 + \left(\bar{\mathbf{A}}^T \bar{\mathbf{W}}_y \bar{\mathbf{A}} + \mu(\delta) \bar{\mathbf{W}}_p \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}}_y (\bar{\mathbf{y}}^0 - \bar{\mathbf{A}} \bar{\mathbf{p}}^0) \quad (1)$$

e

$$\tilde{\mathbf{p}} = \bar{\mathbf{p}}^0 + \bar{\mathbf{W}}_p^{-1} \bar{\mathbf{A}}^T \left[\bar{\mathbf{A}} \bar{\mathbf{W}}_p^{-1} \bar{\mathbf{A}}^T + \mu(\delta) \bar{\mathbf{W}}_y^{-1} \right]^{-1} (\bar{\mathbf{y}}^0 - \bar{\mathbf{A}} \bar{\mathbf{p}}^0) \quad (2)$$

Note que os estimadores genérico (1) e (2) podem ser escritos na forma geral

$$\tilde{\mathbf{p}} = \bar{\mathbf{p}}^0 + \bar{\mathbf{H}} (\bar{\mathbf{y}}^0 - \bar{\mathbf{A}} \bar{\mathbf{p}}^0)$$

(3)

com

$$\bar{\mathbf{H}} = \left(\bar{\mathbf{A}}^T \bar{\mathbf{W}}_y \bar{\mathbf{A}} + \mu(\delta) \bar{\mathbf{W}}_p \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{W}}_y \quad (4)$$

no caso do estimador (1) e com

$$\bar{\mathbf{H}} = \bar{\mathbf{W}}_p^{-1} \bar{\mathbf{A}}^T \left[\bar{\mathbf{A}} \bar{\mathbf{W}}_p^{-1} \bar{\mathbf{A}}^T + \mu(\delta) \bar{\mathbf{W}}_y^{-1} \right]^{-1} \quad (5)$$

no caso do estimador (2) .

Posteriormente, deduzimos no Tópico 21 expressões genéricas dos medidores de eficiência e desempenho dos estimadores $\tilde{\mathbf{p}}$.

Especificamente estes medidores gerais são

1) A esperança de $\tilde{\mathbf{p}}$;

$$E \left\{ \tilde{\mathbf{p}} \right\} = \overline{\overline{\mathbf{H} \mathbf{A} \mathbf{p}}} + \left(\overline{\overline{\mathbf{I}}} - \overline{\overline{\mathbf{H} \mathbf{A}}} \right) \mathbf{p}^o \quad (6)$$

2) A matriz de covariância de $\tilde{\mathbf{p}}$;

$$\text{COV} \left\{ \tilde{\mathbf{p}} \right\} = \overline{\overline{\mathbf{H}}} \text{cov} \left\{ \overline{\overline{\boldsymbol{\varepsilon}}} \right\} \overline{\overline{\mathbf{H}}}^T \quad (7)$$

3) A esperança da distância $(\tilde{\mathbf{p}} - \overline{\mathbf{p}})^T (\tilde{\mathbf{p}} - \overline{\mathbf{p}})$

$$E \left\{ \left\| \tilde{\mathbf{p}} - \overline{\mathbf{p}} \right\|_2^2 \right\} = \text{tr} \{ \text{cov}(\tilde{\mathbf{p}}) \} + \left\| E \left\{ \tilde{\mathbf{p}} \right\} - \overline{\mathbf{p}} \right\|_2^2 \quad (8)$$

4) A matriz de resolução associada a $\tilde{\mathbf{p}}$; e

$$\overline{\overline{\mathbf{R}}}_{(M \times M)} = \overline{\overline{\mathbf{H}}} \overline{\overline{\mathbf{A}}} \quad (9)$$

5) A matriz de densidade de informação associada a $\tilde{\mathbf{p}}$;

$$\overline{\overline{\mathbf{F}}}_{(N \times N)} = \overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{H}}} \quad (10)$$

1) ANÁLISE DO ESTIMADOR MQ SOBRE (r = M) VIA ESTIMADOR GENÉRICO

Vimos anteriormente que o estimador de MQ sobredeterminado é dado pela equação

$$\hat{\bar{\mathbf{p}}} = \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{y}}^o \quad (1.1)$$

Comparando a equação (1.1) com a equação (3) concluímos que no estimador MQ sobredeterminado

$$\bar{\mathbf{H}} = \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \quad (1.2)$$

$$\bar{\mathbf{p}}^o = \bar{\mathbf{0}} \quad (1.3)$$

$$\bar{\bar{\mathbf{W}}}_y = \bar{\mathbf{I}} \quad (1.4)$$

$$\bar{\bar{\mathbf{W}}}_p = \bar{\mathbf{0}} \quad (1.5)$$

$$\mu = 0 \quad (1.6)$$

Logo no estimador MQ sobre temos que

$$\hat{\bar{\mathbf{p}}} = \bar{\mathbf{H}} \bar{\mathbf{y}}^o \quad (17)$$

1.1) Análise Estatística do Estimador MQ Sobre (R = M) Via Estimador Genérico

1.1.1) A esperança de $\hat{\bar{\mathbf{p}}}$ sob as premissas estatísticas 1 1 — — — — 1 1

Vimos na equação (6) que

$$E \left\{ \hat{\bar{\mathbf{p}}} \right\} = \bar{\mathbf{H}} \bar{\mathbf{A}} \bar{\mathbf{p}} + \left(\bar{\mathbf{I}} - \bar{\mathbf{H}} \bar{\mathbf{A}} \right) \bar{\mathbf{p}}^o$$

Como no estimador MQ sobre $\bar{\mathbf{p}}^0 = \bar{\mathbf{0}}$ e $\bar{\mathbf{H}} = \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T$ temos que a equação acima é dada por

$$E \left\{ \hat{\bar{\mathbf{p}}} \right\} = \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{A}} \bar{\mathbf{p}}$$

$E \{ \hat{\bar{\mathbf{p}}} \} = \bar{\mathbf{p}}$

(1.8)

Portanto o estimador MQ sobre é um estimador não tendencioso.

1.1.2) A Matriz de Covariância de $\hat{\bar{\mathbf{p}}}$ sob as premissas estatísticas 1 1 1 1 — — 1 1

Vimos na equação (7) que

$$\text{COV} \left\{ \hat{\bar{\mathbf{p}}} \right\} = \bar{\mathbf{H}} \text{cov} \left\{ \bar{\boldsymbol{\varepsilon}} \right\} \bar{\mathbf{H}}^T$$

Como no estimador MQ sobre e $\bar{\mathbf{H}} = \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T$ temos que a equação acima é dada por

$$\text{COV} \left\{ \hat{\bar{\mathbf{p}}} \right\} = \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \text{cov} \left\{ \bar{\boldsymbol{\varepsilon}} \right\} \bar{\mathbf{A}} \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1}$$

Usando a premissa 3 que os erros tem variância constante e a premissa 4 que os erros não são correlacionáveis temos que

$$\text{COV} \left\{ \bar{\boldsymbol{\varepsilon}} \right\} = \sigma^2 \bar{\mathbf{I}}$$

$$\text{COV} \left\{ \hat{\bar{\mathbf{p}}} \right\} = \sigma^2 \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{A}} \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1}$$

$\text{COV} \left\{ \hat{\bar{\mathbf{p}}} \right\} = \sigma^2 \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1}$

(1.9)

Sob as mesmas condições $N \geq M = r$ que estabelecemos para a garantia da unicidade da solução MQ, a decomposição em valores singulares da matriz de sensibilidade é igual a $\bar{\mathbf{A}} = \bar{\mathbf{U}}_r \bar{\mathbf{S}}_r \bar{\mathbf{V}}_r^T$ em que $r = M$, logo temos que

$$\text{COV} \left\{ \hat{\bar{\mathbf{p}}} \right\} = \sigma^2 \left(\bar{\mathbf{V}}_M \bar{\mathbf{S}}_M \bar{\mathbf{U}}_M^T \bar{\mathbf{U}}_M \bar{\mathbf{S}}_M \bar{\mathbf{V}}_M^T \right)^{-1}$$

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = \sigma^2 \left(\overline{\mathbf{V}}_M \overline{\mathbf{S}}_M^{-2} \overline{\mathbf{V}}_M^T \right)^{-1}$$

como $r = m$ temos que $\overline{\mathbf{V}}_M^{-1} = \overline{\mathbf{V}}_M^T$. Então a matriz de covariância do estimador MQ ($N \geq M = r$) é

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = \sigma^2 \overline{\mathbf{V}}_M \overline{\mathbf{S}}_M^{-2} \overline{\mathbf{V}}_M^T$$

Veja que a covariância do k -ésimo elemento da matriz $\text{cov} \left\{ \hat{\mathbf{p}} \right\}$ é

$$\text{cov} \left\{ \hat{\mathbf{p}}_k \right\} = \sigma^2 \sum_{j=1}^M \frac{v_{kj}^2}{S_j^2} \quad k = 1, \dots, M$$

Como a variância de $\hat{\mathbf{p}}$ são os elementos da diagonal da matriz de covariância ($\text{cov} \left\{ \hat{\mathbf{p}} \right\}$) então temos que a variância do k -ésimo parâmetro é

$$\text{var} \left\{ \hat{\mathbf{p}}_k \right\} = \sigma^2 \sum_{j=1}^M \frac{v_{kj}^2}{S_j^2}$$

Note que a variância do k -ésimo parâmetro estimado via estimador MQ ($N \geq M = r$) é inversamente proporcional aos valores singulares da matriz de sensibilidade $\overline{\mathbf{A}}$. Os elementos da matriz de autovetores (v_{kj}) não exercem influência na variância dos parâmetros pois $\sum_{j=1}^M v_{kj}^2 = 1$. Concluimos, também, através da matriz de

covariância de $\hat{\mathbf{p}}$ que a presença de valores singulares próximos a zero causam a instabilidade da solução estimada via estimador MQ pois haverá uma amplificação do ruído contido nos dados (variável σ^2 que é a variância do ruído dos dados).

1.1.3) A esperança da distância $\left(\hat{\mathbf{p}} - \overline{\mathbf{p}} \right)^T \left(\hat{\mathbf{p}} - \overline{\mathbf{p}} \right)$

Vimos na equação (8) que

$$E \left\{ \left\| \hat{\mathbf{p}} - \overline{\mathbf{p}} \right\|_2^2 \right\} = \text{tr} \{ \text{cov}(\hat{\mathbf{p}}) \} + \left\| E \left\{ \hat{\mathbf{p}} \right\} - \overline{\mathbf{p}} \right\|_2^2$$

Na equação (1.9) deduzimos que no estimador MQ sobre

$$\mathbf{COV} \left\{ \hat{\mathbf{p}} \right\} = \sigma^2 \left(\overline{\mathbf{A}}^T \overline{\mathbf{A}} \right)^{-1}$$

e na equação (1.8) deduzimos que

$$E\{\hat{\mathbf{p}}\} = \overline{\mathbf{p}}$$

Logo temos que a esperança da distância $(\hat{\mathbf{p}} - \overline{\mathbf{p}})^T (\hat{\mathbf{p}} - \overline{\mathbf{p}})$ é dada por

$$E\{[\hat{\mathbf{p}} - \overline{\mathbf{p}}]^T [\hat{\mathbf{p}} - \overline{\mathbf{p}}]\} = \text{tr}\{\sigma^2 (\overline{\mathbf{A}}^T \overline{\mathbf{A}})^{-1}\} + \|\overline{\mathbf{p}} - \overline{\mathbf{p}}\|_2^2$$

$$\boxed{E\{[\hat{\mathbf{p}} - \overline{\mathbf{p}}]^T [\hat{\mathbf{p}} - \overline{\mathbf{p}}]\} = \sigma^2 \text{tr}\{(\overline{\mathbf{A}}^T \overline{\mathbf{A}})^{-1}\}} \quad (1.10)$$

Sob as mesmas condições $N \geq M = r$ que estabelecemos para a garantia da unicidade da solução MQ, a decomposição em valores singulares da matriz de sensibilidade é igual a $\overline{\mathbf{A}} = \overline{\mathbf{U}}_r \overline{\mathbf{S}}_r \overline{\mathbf{V}}_r^T$ em que $r = M$, logo temos que

$$E\{[\hat{\mathbf{p}} - \overline{\mathbf{p}}]^T [\hat{\mathbf{p}} - \overline{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\left(\overline{\mathbf{V}}_M \overline{\mathbf{S}}_M \overline{\mathbf{U}}_M^T \overline{\mathbf{U}}_M \overline{\mathbf{S}}_M \overline{\mathbf{V}}_M^T\right)^{-1}\right\}$$

$$E\{[\hat{\mathbf{p}} - \overline{\mathbf{p}}]^T [\hat{\mathbf{p}} - \overline{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\left(\overline{\mathbf{V}}_M \overline{\mathbf{S}}_M^{-2} \overline{\mathbf{V}}_M^T\right)^{-1}\right\}$$

como $r = m$ temos que $\overline{\mathbf{V}}_M^{-1} = \overline{\mathbf{V}}_M^T$. Então temos que a esperança da distância

$(\hat{\mathbf{p}} - \overline{\mathbf{p}})^T (\hat{\mathbf{p}} - \overline{\mathbf{p}})$ é dada por

$$E\{[\hat{\mathbf{p}} - \overline{\mathbf{p}}]^T [\hat{\mathbf{p}} - \overline{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\overline{\mathbf{V}}_M \overline{\mathbf{S}}_M^{-2} \overline{\mathbf{V}}_M^T\right\}$$

Lembrando da propriedade do traço do produto de matrizes

$$\text{tr}\{\overline{\mathbf{C}}\overline{\mathbf{B}}\} = \text{tr}\{\overline{\mathbf{B}}\overline{\mathbf{C}}\}$$

Então podemos escrever que

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \operatorname{tr}\left\{\bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^{-2} \bar{\mathbf{V}}_M^T\right\} = \sigma^2 \operatorname{tr}\left\{\bar{\mathbf{S}}_M^{-2} \bar{\mathbf{V}}_M^T \bar{\mathbf{V}}_M\right\}$$

Como $\bar{\mathbf{V}}_M^T \bar{\mathbf{V}}_M = \bar{\mathbf{I}}$ temos que

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \operatorname{tr}\left\{\bar{\mathbf{S}}_M^{-2}\right\}$$

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \sum_{i=1}^M \frac{1}{S_i^2} \quad (1.11)$$

em que $S_i, i=1,2,\dots,M$ são os valores singulares da matriz de sensibilidade $\bar{\mathbf{A}}$ (caso MQ sobre $N \geq M = r$). Note que basta a presença de um único valor singular próximo a zero para haver uma amplificação do ruído contido nos dados (variável σ^2 que é a variância do ruído dos dados). Isto faz com que a esperança da distância entre os parâmetros estimados via MQ sobre $(\hat{\mathbf{p}})$ e os parâmetros $\bar{\mathbf{p}}$, que explicam os dados geofísicos exatos (dados sem ruído), seja um valor muito grande.

1.1.4) A matriz de resolução associada a $\hat{\mathbf{p}}$

Vimos na equação (9) que

$$\bar{\mathbf{R}} = \bar{\mathbf{H}} \bar{\mathbf{A}}$$

Como no estimador MQ sobre $\bar{\mathbf{H}} = \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}}\right)^{-1} \bar{\mathbf{A}}^T$ temos que a equação acima é dada por

$$\bar{\mathbf{R}} = \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}}\right)^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{A}}$$

$$\bar{\mathbf{R}}_{(M \times M)} = \bar{\mathbf{I}} \quad (1.12)$$

Veja que a matriz de resolução estimador MQ sobre ($N \geq M = r$) é igual a matriz identidade. Isto significa dizer que cada elemento é estimado de modo ÚNICO (i.e., $\hat{p}_j, j=1,2,\dots,M$ são estimados independentemente). Dizemos que cada elemento de $\hat{\mathbf{p}}$ é perfeitamente resolvido (RESOLUÇÃO MÁXIMA).

Se os dados não tiverem ruído ($\bar{\mathbf{y}}^0 = \bar{\mathbf{A}} \bar{\mathbf{p}}^0$), neste caso em que $\bar{\mathbf{R}} = \bar{\mathbf{I}}_M$ a solução estimada via MQ sobre ($\hat{\mathbf{p}}$) será igual aos parâmetros $\bar{\mathbf{p}}$, i.e., parâmetros que explicam os dados geofísicos exatos (dados sem ruído). No entanto, se houver ruído, isto não ocorre. Veja se partirmos da equação (3), i.e.,

$$\tilde{\mathbf{p}} = \bar{\mathbf{p}}^0 + \bar{\mathbf{H}}(\bar{\mathbf{y}}^0 - \bar{\mathbf{A}} \bar{\mathbf{p}}^0)$$

considerando os dados com ruído, temos que o estimador acima pode ser escrito como

$$\tilde{\mathbf{p}} = \bar{\mathbf{p}}^0 + \bar{\mathbf{H}}(\bar{\mathbf{A}} \bar{\mathbf{p}} + \bar{\boldsymbol{\varepsilon}} - \bar{\mathbf{A}} \bar{\mathbf{p}}^0)$$

$$\boxed{\tilde{\mathbf{p}} = \bar{\mathbf{H}} \bar{\mathbf{A}} \bar{\mathbf{p}} + \bar{\mathbf{H}} \bar{\boldsymbol{\varepsilon}} + (\bar{\mathbf{I}} - \bar{\mathbf{H}} \bar{\mathbf{A}}) \bar{\mathbf{p}}^0} \quad (1.13)$$

Como no estimador MQ sobre $\bar{\mathbf{p}}^0 = \bar{\mathbf{0}}$ então temos que o estimador MQ sobre pode ser escrito como

$$\hat{\mathbf{p}} = \bar{\mathbf{H}} \bar{\mathbf{A}} \bar{\mathbf{p}} + \bar{\mathbf{H}} \bar{\boldsymbol{\varepsilon}}$$

Veja que como $\bar{\mathbf{R}} = \bar{\mathbf{H}} \bar{\mathbf{A}}$ e que no caso do MQ sobre $\bar{\mathbf{R}} = \bar{\mathbf{I}}_M$, então a solução estimada via MQ sobre ($\hat{\mathbf{p}}$) para caso com ruído é dado por

$$\boxed{\hat{\mathbf{p}} = \bar{\mathbf{p}} + \bar{\mathbf{H}} \bar{\boldsymbol{\varepsilon}}} \quad (1.14)$$

Como no estimador MQ sobre $\bar{\mathbf{H}} = \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T$ temos que a equação acima é dada por

$$\hat{\mathbf{p}} = \bar{\mathbf{p}} + \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \bar{\boldsymbol{\varepsilon}}$$

Usando a decomposição em valores singulares da matriz de sensibilidade é igual a

$$\bar{\mathbf{A}} = \bar{\mathbf{U}}_r \bar{\mathbf{S}}_r \bar{\mathbf{V}}_r^T \text{ em que } r = M, \text{ logo temos que}$$

$$\hat{\mathbf{p}} = \bar{\mathbf{p}} + \left(\bar{\mathbf{V}}_M \bar{\mathbf{S}}_M \bar{\mathbf{U}}_M^T \bar{\mathbf{U}}_M \bar{\mathbf{S}}_M \bar{\mathbf{V}}_M^T \right)^{-1} \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M \bar{\mathbf{U}}_M^T \bar{\boldsymbol{\varepsilon}}$$

$$\hat{\mathbf{p}} = \bar{\mathbf{p}} + \left(\bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^2 \bar{\mathbf{V}}_M^T \right)^{-1} \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M \bar{\mathbf{U}}_M^T \bar{\boldsymbol{\varepsilon}}$$

como $r = m$ temos que $\bar{\mathbf{V}}_M^{-1} = \bar{\mathbf{V}}_M^T$ então

$$\hat{\mathbf{p}} = \bar{\mathbf{p}} + \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^{-2} \bar{\mathbf{V}}_M^T \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M \bar{\mathbf{U}}_M^T \bar{\boldsymbol{\varepsilon}}$$

$$\hat{\mathbf{p}} = \bar{\mathbf{p}} + \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^{-1} \bar{\mathbf{U}}_M^T \bar{\boldsymbol{\varepsilon}}$$

Chamando $\bar{\boldsymbol{\beta}}^{Ruido} = \bar{\mathbf{U}}_M^T \bar{\boldsymbol{\varepsilon}}$ então temos que

$$\hat{\mathbf{p}} = \bar{\mathbf{p}} + \bar{\mathbf{V}}_M \bar{\mathbf{S}}_M^{-1} \bar{\boldsymbol{\beta}}^{Ruido}$$

$$\hat{\mathbf{p}} = \bar{\mathbf{p}} + \sum_{j=1}^M \frac{\bar{\mathbf{v}}_j}{S_j} \beta_j^{Ruido} \quad (1.15)$$

A equação (1.15) mostra que cada elemento é estimado de modo ÚNICO (i.e., $\hat{p}_j, j = 1, 2, \dots, M$ são estimados independentemente), porém a solução estimada via MQ sobre $(\hat{\mathbf{p}})$ pode ser muito distante dos parâmetros $\bar{\mathbf{p}}$ (parâmetros que explicam os dados geofísicos exatos), devido a segunda parcela da equação (1.15).

1.1.5) A matriz densidade de informação associada a $\hat{\mathbf{p}}$

Vimos na equação (10) que

$$\bar{\mathbf{F}}_{(N \times N)} = \bar{\mathbf{A}} \bar{\mathbf{H}}$$

Como no estimador MQ sobre $\bar{\mathbf{H}} = \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T$ temos que a equação

acima é dada por

$$\bar{\mathbf{F}} = \bar{\mathbf{A}} \left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \right)^{-1} \bar{\mathbf{A}}^T \quad (1.16)$$

Fazendo a decomposição em valores singulares da matriz de sensibilidade é igual a

$\bar{\bar{\mathbf{A}}} = \bar{\bar{\mathbf{U}}}_r \bar{\bar{\mathbf{S}}}_r \bar{\bar{\mathbf{V}}}_r^T$ em que $r = M$, temos que equação (1.16) é dada por

$$\bar{\bar{\mathbf{F}}} = \bar{\bar{\mathbf{U}}}_M \bar{\bar{\mathbf{S}}}_M \bar{\bar{\mathbf{V}}}_M^T \left(\bar{\bar{\mathbf{V}}}_M \bar{\bar{\mathbf{S}}}_M \bar{\bar{\mathbf{U}}}_M^T \bar{\bar{\mathbf{U}}}_M \bar{\bar{\mathbf{S}}}_M \bar{\bar{\mathbf{V}}}_M^T \right)^{-1} \bar{\bar{\mathbf{V}}}_M \bar{\bar{\mathbf{S}}}_M \bar{\bar{\mathbf{U}}}_M^T$$

$$\bar{\bar{\mathbf{F}}} = \bar{\bar{\mathbf{U}}}_M \bar{\bar{\mathbf{S}}}_M \bar{\bar{\mathbf{V}}}_M^T \left(\bar{\bar{\mathbf{V}}}_M \bar{\bar{\mathbf{S}}}_M^2 \bar{\bar{\mathbf{V}}}_M^T \right)^{-1} \bar{\bar{\mathbf{V}}}_M \bar{\bar{\mathbf{S}}}_M \bar{\bar{\mathbf{U}}}_M^T$$

como $r = m$ temos que $\bar{\bar{\mathbf{V}}}_M^{-1} = \bar{\bar{\mathbf{V}}}_M^T$ então

$$\bar{\bar{\mathbf{F}}} = \bar{\bar{\mathbf{U}}}_M \bar{\bar{\mathbf{S}}}_M \bar{\bar{\mathbf{V}}}_M^T \bar{\bar{\mathbf{V}}}_M \bar{\bar{\mathbf{S}}}_M^{-2} \bar{\bar{\mathbf{V}}}_M^T \bar{\bar{\mathbf{V}}}_M \bar{\bar{\mathbf{S}}}_M \bar{\bar{\mathbf{U}}}_M^T$$

$\bar{\bar{\mathbf{F}}} = \bar{\bar{\mathbf{U}}}_M \bar{\bar{\mathbf{U}}}_M^T$

(1.17)

Lembre-se que no estimador MQ sobre $M = r$ e $N > M$, neste caso

$$\bar{\bar{\mathbf{U}}}_N \bar{\bar{\mathbf{U}}}_N^T = \bar{\bar{\mathbf{U}}}_M \bar{\bar{\mathbf{U}}}_M^T + \bar{\bar{\mathbf{U}}}_{N-M} \bar{\bar{\mathbf{U}}}_{N-M}^T = \bar{\bar{\mathbf{I}}}_N$$

A equação (1.17) mostra que a matriz densidade de informação do estimador MQ Sobre é diferente da matriz identidade. Isto quer dizer que os dados observados e os dados ajustados via estimador MQ Sobre é diferente de zero ($\bar{\bar{\boldsymbol{\varepsilon}}} \neq \bar{\bar{\mathbf{0}}}$).

2) ANÁLISE DO ESTIMADOR MQ SUB ($r = N$) VIA ESTIMADOR GENÉRICO

Vimos anteriormente que o estimador de MQ Subdeterminado é dado pela equação

$$\hat{\bar{p}} = \bar{\bar{A}}^T \left(\bar{\bar{A}} \bar{\bar{A}}^T \right)^{-1} \bar{y}^o \quad (2.1)$$

Comparando a equação (2.1) com a equação (3) concluímos que no estimador MQ Subdeterminado

$$\bar{\bar{H}} = \bar{\bar{A}}^T \left(\bar{\bar{A}} \bar{\bar{A}}^T \right)^{-1} \quad (2.2)$$

$$\bar{p}^o = \bar{0} \quad (2.3)$$

$$\bar{\bar{W}}_y = \bar{\bar{I}} \quad (2.4)$$

$$\bar{\bar{W}}_p = \bar{0} \quad (2.5)$$

$$\mu = 0 \quad (2.6)$$

Logo no estimador MQ Sub temos que

$$\hat{\bar{p}} = \bar{\bar{H}} \bar{y}^o \quad (2.7)$$

Dedução do Estimador de Mínimos Quadrados Subdeterminado via decomposição em valores singulares:

A decomposição em valores singulares da matriz $\bar{\bar{A}}$

$$\bar{\bar{A}} = \bar{\bar{U}}_r \bar{\bar{S}}_r \bar{\bar{V}}_r^T$$

Substituindo a equação acima na equação (2.1) e lembrando que o estimador MQ SUB o posto é igual ao número de observações $r = N \leq M$ temos

$$\hat{\mathbf{p}} = \overline{\mathbf{V}}_N \overline{\mathbf{S}}_N \overline{\mathbf{U}}_N^T \left(\overline{\mathbf{U}}_N \overline{\mathbf{S}}_N \overline{\mathbf{V}}_N^T \overline{\mathbf{V}}_N \overline{\mathbf{S}}_N \overline{\mathbf{U}}_N^T \right)^{-1} \overline{\mathbf{y}}^o$$

Como $\overline{\mathbf{V}}_N^T \overline{\mathbf{V}}_N = \overline{\mathbf{I}}_N$

$$\hat{\mathbf{p}} = \overline{\mathbf{V}}_N \overline{\mathbf{S}}_N \overline{\mathbf{U}}_N^T \left(\overline{\mathbf{U}}_N \overline{\mathbf{S}}_N^2 \overline{\mathbf{U}}_N^T \right)^{-1} \overline{\mathbf{y}}^o$$

como $r = N$ temos que $\overline{\mathbf{U}}_N^{-1} = \overline{\mathbf{U}}_N^T$ então temos que

$$\hat{\mathbf{p}} = \overline{\mathbf{V}}_N \overline{\mathbf{S}}_N \overline{\mathbf{U}}_N^T \overline{\mathbf{U}}_N \overline{\mathbf{S}}_N^{-2} \overline{\mathbf{U}}_N^T \overline{\mathbf{y}}^o$$

Como $\overline{\mathbf{U}}_N^T \overline{\mathbf{U}}_N = \overline{\mathbf{I}}_N$ temos que o **Estimador Mínimos Quadrados SUBDETERMINADO** pode ser expresso como

$$\hat{\mathbf{p}} = \overline{\mathbf{V}}_N \overline{\mathbf{S}}_N^{-1} \overline{\mathbf{U}}_N^T \overline{\mathbf{y}}^o$$

Vamos chamar: o vetor $\overline{\mathbf{U}}_N^T \overline{\mathbf{y}}^o = \overline{\boldsymbol{\beta}}$ ($N \times 1$) então

$$\hat{\mathbf{p}} = \overline{\mathbf{V}}_N \overline{\mathbf{S}}_N^{-1} \overline{\boldsymbol{\beta}}$$

que pode ser escrito na forma de somatório como

$$\hat{\mathbf{p}} = \sum_{i=1}^N \overline{\mathbf{v}}_i \frac{\beta_i}{S_i}$$

em que $\overline{\mathbf{v}}_i, i = 1, 2, \dots, N$ são os N vetores colunas que formam a matriz dos autovetores $\overline{\mathbf{V}}_N (M \times N)$. Veja que o j -ésimo elemento de $\hat{\mathbf{p}}$ é

$$\hat{p}_j = \sum_{i=1}^N \frac{\beta_i}{S_i} v_{ij}$$

Análise da Unicidade e Estabilidade do estimador de Mínimos Quadrados SUBDETERMINADO usando a SVD como ferramenta:

Unicidade da estimativa via Mínimos Quadrados SUBDETERMINADO:

A análise do estimador de Mínimos Quadrados Subdeterminado via decomposição em valores singulares considerando que a matriz de sensibilidade é de posto completo e a condição que $r = N \leq M$ resultou em

$$\hat{\bar{\mathbf{p}}} = \sum_{i=1}^N \bar{\mathbf{v}}_i \frac{\beta_i}{S_i}$$

Veja que para a garantia da unicidade da solução estimada $\hat{\bar{\mathbf{p}}}$ via MQ SUB temos que ter, obrigatoriamente, N valores singulares diferentes de zero, caso contrário, teremos infinitas possíveis soluções produzindo o mesmo ajuste (mais adiante provaremos esta informação matematicamente).

Note no entanto que a condição de $M \geq N = r$, garante a unicidade da solução $\hat{\bar{\mathbf{p}}}$ (MQ SUB) porém a simples existência de N valores singulares diferentes de zero não garante a estabilidade da solução. Veja que o j-ésimo elemento de $\hat{\bar{\mathbf{p}}}$ é

$$\hat{p}_j = \sum_{i=1}^N \frac{\beta_i}{S_i} v_{ij}$$

Note que a existência de valores singulares muito próximo a zero causará uma amplificação do ruído dos dados que está presente nos elementos do vetor $\bar{\mathbf{\beta}}$ uma vez que este vetor é $\bar{\mathbf{\beta}} = \bar{\mathbf{U}}^T \bar{\mathbf{y}}^o$

$\bar{\mathbf{\beta}} = \bar{\mathbf{U}}^T \bar{\mathbf{y}}^o$ é a projeção dos dados observados nos autovetores da matriz $\bar{\mathbf{U}}$

2.1) Análise Estatística do Estimador MQ Sub (r = N) Via Estimador Genérico

2.1.1) A esperança de $\hat{\mathbf{p}}$ sob as premissas estatísticas 1 1 — — — 1 1

Vimos na equação (6) que

$$E \left\{ \tilde{\mathbf{p}} \right\} = \overline{\overline{\mathbf{H} \mathbf{A}}} \overline{\mathbf{p}} + \left(\overline{\mathbf{I}} - \overline{\overline{\mathbf{H} \mathbf{A}}} \right) \overline{\mathbf{p}}^o$$

Como no estimador MQ Sub $\overline{\mathbf{p}}^o = \overline{\mathbf{0}}$ e $\overline{\overline{\mathbf{H}}} = \overline{\overline{\mathbf{A}}}^T \left(\overline{\overline{\mathbf{A} \mathbf{A}}}^T \right)^{-1}$ temos que a equação acima é dada por

$$E \{ \hat{\mathbf{p}} \} = \overline{\overline{\mathbf{A}}}^T \left(\overline{\overline{\mathbf{A} \mathbf{A}}}^T \right)^{-1} \overline{\overline{\mathbf{A}}} \overline{\mathbf{p}} \quad (2.8)$$

Portanto o estimador MQ Sub é um estimador tendencioso.

Sob as condições $M \geq N = r$ que estabelecemos para a garantia da unicidade da solução MQ Sub e usando a decomposição em valores singulares da matriz de sensibilidade é igual a $\overline{\overline{\mathbf{A}}} = \overline{\overline{\mathbf{U}}}_r \overline{\overline{\mathbf{S}}}_r \overline{\overline{\mathbf{V}}}_r^T$ em que $r = N$, temos que

$$E \{ \hat{\mathbf{p}} \} = \overline{\overline{\mathbf{V}}}_N \overline{\overline{\mathbf{S}}}_N \overline{\overline{\mathbf{U}}}_N^T \left(\overline{\overline{\mathbf{U}}}_N \overline{\overline{\mathbf{S}}}_N \overline{\overline{\mathbf{V}}}_N^T \overline{\overline{\mathbf{V}}}_N \overline{\overline{\mathbf{S}}}_N \overline{\overline{\mathbf{U}}}_N^T \right)^{-1} \overline{\overline{\mathbf{U}}}_N \overline{\overline{\mathbf{S}}}_N \overline{\overline{\mathbf{V}}}_N^T \overline{\mathbf{p}}$$

$$E \{ \hat{\mathbf{p}} \} = \overline{\overline{\mathbf{V}}}_N \overline{\overline{\mathbf{S}}}_N \overline{\overline{\mathbf{U}}}_N^T \left(\overline{\overline{\mathbf{U}}}_N \overline{\overline{\mathbf{S}}}_N^2 \overline{\overline{\mathbf{U}}}_N^T \right)^{-1} \overline{\overline{\mathbf{U}}}_N \overline{\overline{\mathbf{S}}}_N \overline{\overline{\mathbf{V}}}_N^T \overline{\mathbf{p}}$$

como $r = N$ temos que $\overline{\overline{\mathbf{U}}}_N^{-1} = \overline{\overline{\mathbf{U}}}_N^{T1}$

$$E \{ \hat{\mathbf{p}} \} = \overline{\overline{\mathbf{V}}}_N \overline{\overline{\mathbf{S}}}_N \overline{\overline{\mathbf{U}}}_N^T \overline{\overline{\mathbf{U}}}_N \overline{\overline{\mathbf{S}}}_N^{-2} \overline{\overline{\mathbf{U}}}_N^T \overline{\overline{\mathbf{U}}}_N \overline{\overline{\mathbf{S}}}_N \overline{\overline{\mathbf{V}}}_N^T \overline{\mathbf{p}}$$

$$E \{ \hat{\mathbf{p}} \} = \overline{\overline{\mathbf{V}}}_N \overline{\overline{\mathbf{V}}}_N^T \overline{\mathbf{p}} \quad (2.9)$$

2.1.2) A Matriz de Covariância de $\hat{\mathbf{p}}$ sob as premissas estatísticas 1 1 1 1 — — 1 1

Vimos na equação (7) que

$$\text{COV} \left\{ \tilde{\mathbf{p}} \right\} = \overline{\overline{\mathbf{H}}} \text{cov} \{ \tilde{\boldsymbol{\varepsilon}} \} \overline{\overline{\mathbf{H}}}^T$$

Como no estimador MQ Sub e $\overline{\overline{\mathbf{H}}} = \overline{\overline{\mathbf{A}}}^T \left(\overline{\overline{\mathbf{A} \mathbf{A}}}^T \right)^{-1}$ temos que a equação acima é

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = \overline{\overline{\mathbf{A}}}^T \left(\overline{\overline{\mathbf{A} \mathbf{A}}}^T \right)^{-1} \text{cov} \{ \tilde{\boldsymbol{\varepsilon}} \} \left(\overline{\overline{\mathbf{A} \mathbf{A}}}^T \right)^{-1} \overline{\overline{\mathbf{A}}}$$

Usando a premissa 3 que os erros tem variância constante e a premissa 4 que os erros não são correlacionáveis temos que

$$\begin{aligned} \text{COV} \{ \bar{\boldsymbol{\varepsilon}} \} &= \sigma^2 \bar{\mathbf{I}} \\ \text{COV} \{ \hat{\bar{\mathbf{p}}} \} &= \sigma^2 \bar{\mathbf{A}}^T \left(\bar{\mathbf{A}} \bar{\mathbf{A}}^T \right)^{-1} \left(\bar{\mathbf{A}} \bar{\mathbf{A}}^T \right)^{-1} \bar{\mathbf{A}} \\ \boxed{\text{COV} \{ \hat{\bar{\mathbf{p}}} \} &= \sigma^2 \bar{\mathbf{A}}^T \left(\bar{\mathbf{A}} \bar{\mathbf{A}}^T \right)^{-2} \bar{\mathbf{A}}} \end{aligned} \quad (2.10)$$

Sob as mesmas condições $M \geq N = r$ que estabelecemos para a garantia da unicidade da solução MQ Sub, a decomposição em valores singulares da matriz de sensibilidade

é igual a $\bar{\mathbf{A}} = \bar{\mathbf{U}}_r \bar{\mathbf{S}}_r \bar{\mathbf{V}}_r^T$ em que $r = N$, logo temos que

$$\text{COV} \{ \hat{\bar{\mathbf{p}}} \} = \sigma^2 \bar{\mathbf{V}}_N \bar{\mathbf{S}}_N \bar{\mathbf{U}}_N^T \left(\bar{\mathbf{U}}_N \bar{\mathbf{S}}_N \bar{\mathbf{V}}_N^T \bar{\mathbf{V}}_N \bar{\mathbf{S}}_N \bar{\mathbf{U}}_N^T \right)^{-2} \bar{\mathbf{U}}_N \bar{\mathbf{S}}_N \bar{\mathbf{V}}_N^T$$

$$\text{COV} \{ \hat{\bar{\mathbf{p}}} \} = \sigma^2 \bar{\mathbf{V}}_N \bar{\mathbf{S}}_N \bar{\mathbf{U}}_N^T \left(\bar{\mathbf{U}}_N \bar{\mathbf{S}}_N^2 \bar{\mathbf{U}}_N^T \right)^{-2} \bar{\mathbf{U}}_N \bar{\mathbf{S}}_N \bar{\mathbf{V}}_N^T$$

como $r = N$ temos que $\bar{\mathbf{U}}_N^{-1} = \bar{\mathbf{U}}_N^{T1}$

$$\text{COV} \{ \hat{\bar{\mathbf{p}}} \} = \sigma^2 \bar{\mathbf{V}}_N \bar{\mathbf{S}}_N \bar{\mathbf{U}}_N^T \bar{\mathbf{U}}_N \bar{\mathbf{S}}_N^{-4} \bar{\mathbf{U}}_N^T \bar{\mathbf{U}}_N \bar{\mathbf{S}}_N \bar{\mathbf{V}}_N^T$$

$$\text{COV} \{ \hat{\bar{\mathbf{p}}} \} = \sigma^2 \bar{\mathbf{V}}_N \bar{\mathbf{S}}_N \bar{\mathbf{S}}_N^{-4} \bar{\mathbf{S}}_N \bar{\mathbf{V}}_N^T$$

$$\text{COV} \{ \hat{\bar{\mathbf{p}}} \} = \sigma^2 \bar{\mathbf{V}}_N \bar{\mathbf{S}}_N^{-2} \bar{\mathbf{V}}_N^T$$

Veja que a covariância do kj -ésimo elemento da matriz $\text{cov} \{ \hat{\bar{\mathbf{p}}} \}$ é

$$\text{cov} \{ \hat{\bar{\mathbf{p}}}_{kj} \} = \sigma^2 \sum_{j=1}^N \frac{v_{kj} v_{kj}}{S_j^2}, \quad k = 1, \dots, M$$

Como a variância de $\hat{\bar{\mathbf{p}}}$ são os elementos da diagonal da matriz de covariância ($\text{cov} \{ \hat{\bar{\mathbf{p}}} \}$) então temos que a variância do k -ésimo parâmetro é

$$\text{var} \{ \hat{\mathbf{p}}_k \} = \sigma^2 \sum_{j=1}^N \frac{v_{kj}^2}{S_j^2} \quad (2.11)$$

Note que a variância do k-ésimo parâmetro estimado via estimador MQ ($M \geq N = r$) é inversamente proporcional aos valores singulares da matriz de sensibilidade $\overline{\overline{\mathbf{A}}}$. O

termo $\sum_{j=1}^N v_{kj}^2$ é sempre igual a 1 (um). No entanto, diferentemente do

estimador MQ sobre, vemos que o somatório na equação (2.11) envolve apenas N valores singulares. Lembrando que o estimador MQ Sub, $M \geq N = r$. Se $r = N$ (posto é igual ao número de observações) isto significa dizer que há N valores singulares diferentes de zero, ou seja, há garantia da unicidade da solução estimada via MQ SUB. No entanto, veja que se as variâncias no MQ SUB é inversamente proporcional aos N valores singulares da matriz $\overline{\overline{\mathbf{A}}}$, então se dentre estes N valores singulares próximos houver valores próximos a zero ($S_j \approx 0, j = 1, 2, \dots, N$) haverá uma instabilidade na solução estimada via MQ SUB, uma vez que haverá uma amplificação do ruído contido nos dados (a variável σ^2 é a variância do ruído dos dados observados).

Note que, não há nenhuma garantia que estes N valores singulares sejam valores grandes e o estimador MQ SUB não permite a exclusão destes valores singulares próximos a zero. Então NÃO há garantia de estabilidade da solução estimada via MQ SUB.

Concluimos que há garantia de unicidade da solução estimada via estimador MQ SUB já que $r = N$, porém NÃO HÁ GARANTIA DE ESTABILIDADE. O estimador MQ SUB não é um regularizador de Tikhonov.

2.1.3) A esperança da distância $(\hat{\mathbf{p}} - \overline{\mathbf{p}})^T (\hat{\mathbf{p}} - \overline{\mathbf{p}})$

Vimos na equação (8) que

$$E \left\{ \left\| \tilde{\mathbf{p}} - \overline{\mathbf{p}} \right\|_2^2 \right\} = \text{tr} \{ \text{cov}(\tilde{\mathbf{p}}) \} + \left\| E \left\{ \tilde{\mathbf{p}} \right\} - \overline{\mathbf{p}} \right\|_2^2$$

Na equação (2.10) deduzimos que no estimador MQ sobre

$$\text{COV}\left\{\hat{\bar{\mathbf{p}}}\right\} = \sigma^2 \bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-2} \bar{\bar{\mathbf{A}}}$$

e na equação (2.9) deduzimos que

$$E\{\hat{\bar{\mathbf{p}}}\} = \bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-1} \bar{\bar{\mathbf{A}}} \bar{\mathbf{p}}$$

Logo temos que no estimador MQ Sub a esperança da distância $(\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}})^T (\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}})$ é dada por

$$E\{[\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}]^T [\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}]\} = \text{tr}\left\{\sigma^2 \bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-2} \bar{\bar{\mathbf{A}}}\right\} + \bar{\mathbf{p}}^T \left(\bar{\bar{\mathbf{H}}\bar{\mathbf{A}}} - \bar{\bar{\mathbf{I}}}\right)^T \left(\bar{\bar{\mathbf{H}}\bar{\mathbf{A}}} - \bar{\bar{\mathbf{I}}}\right) \bar{\mathbf{p}}$$

$$E\{[\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}]^T [\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-2} \bar{\bar{\mathbf{A}}}\right\} + \left\|\bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-1} \bar{\bar{\mathbf{A}}}\bar{\mathbf{p}} - \bar{\mathbf{p}}\right\|_2^2$$

$$E\{[\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}]^T [\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-2} \bar{\bar{\mathbf{A}}}\right\} + \left\|\left(\bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-1} \bar{\bar{\mathbf{A}}} - \bar{\bar{\mathbf{I}}}\right) \bar{\mathbf{p}}\right\|_2^2$$

$$E\{[\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}]^T [\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-2} \bar{\bar{\mathbf{A}}}\right\} + \bar{\mathbf{p}}^T \left[\bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-1} \bar{\bar{\mathbf{A}}} - \bar{\bar{\mathbf{I}}}\right]^T \left[\bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-1} \bar{\bar{\mathbf{A}}} - \bar{\bar{\mathbf{I}}}\right] \bar{\mathbf{p}}$$

$$E\{[\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}]^T [\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-2} \bar{\bar{\mathbf{A}}}\right\} + \bar{\mathbf{p}}^T \left[\bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-1} \bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-1} \bar{\bar{\mathbf{A}}} - 2\bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-1} \bar{\bar{\mathbf{A}}} + \bar{\bar{\mathbf{I}}}\right] \bar{\mathbf{p}}$$

$$E\{[\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}]^T [\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-2} \bar{\bar{\mathbf{A}}}\right\} + \bar{\mathbf{p}}^T \left[\bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-1} \bar{\bar{\mathbf{A}}} - 2\bar{\bar{\mathbf{A}}}^T \left(\bar{\bar{\mathbf{A}}\bar{\mathbf{A}}}^T\right)^{-1} \bar{\bar{\mathbf{A}}} + \bar{\bar{\mathbf{I}}}\right] \bar{\mathbf{p}}$$

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\{\bar{\bar{\mathbf{A}}}^T (\bar{\bar{\mathbf{A}}\bar{\bar{\mathbf{A}}}^T})^{-2} \bar{\bar{\mathbf{A}}}\} + \bar{\mathbf{p}}^T \left[\bar{\mathbf{I}} - \bar{\bar{\mathbf{A}}}^T (\bar{\bar{\mathbf{A}}\bar{\bar{\mathbf{A}}}^T})^{-1} \bar{\bar{\mathbf{A}}} \right] \bar{\mathbf{p}} \quad (2.12)$$

Sob as mesmas condições $M \geq N = r$ que estabelecemos para a garantia da unicidade da solução MQ SUB, a decomposição em valores singulares da matriz de sensibilidade é igual a $\bar{\bar{\mathbf{A}}} = \bar{\bar{\mathbf{U}}}_r \bar{\bar{\mathbf{S}}}_r \bar{\bar{\mathbf{V}}}_r^T$ em que $r = N$, temos que a

$$E\left\{\left\|\tilde{\mathbf{p}} - \bar{\mathbf{p}}\right\|_2^2\right\} = \text{tr}\{\text{cov}(\tilde{\mathbf{p}})\} + \left\|E\left\{\tilde{\mathbf{p}}\right\} - \bar{\mathbf{p}}\right\|_2^2$$

considerando para o estimador MQ SUB que a $\text{COV}\left\{\hat{\mathbf{p}}\right\} = \sigma^2 \bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{S}}}_N^{-2} \bar{\bar{\mathbf{V}}}_N^T$ (como deduzimos acima) e que $E\{\hat{\mathbf{p}}\} = \bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T \bar{\mathbf{p}}$ então temos que

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{S}}}_N^{-2} \bar{\bar{\mathbf{V}}}_N^T\right\} + \left\|\bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T \bar{\mathbf{p}} - \bar{\mathbf{p}}\right\|_2^2$$

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{S}}}_N^{-2} \bar{\bar{\mathbf{V}}}_N^T\right\} + \left\|(\bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T - \bar{\mathbf{I}}) \bar{\mathbf{p}}\right\|_2^2$$

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{S}}}_N^{-2} \bar{\bar{\mathbf{V}}}_N^T\right\} + \bar{\mathbf{p}}^T (\bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T - \bar{\mathbf{I}})^T (\bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T - \bar{\mathbf{I}}) \bar{\mathbf{p}}$$

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{S}}}_N^{-2} \bar{\bar{\mathbf{V}}}_N^T\right\} + (\bar{\mathbf{p}}^T \bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T - \bar{\mathbf{p}}^T) (\bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T \bar{\mathbf{p}} - \bar{\mathbf{p}})$$

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{S}}}_N^{-2} \bar{\bar{\mathbf{V}}}_N^T\right\} + \bar{\mathbf{p}}^T \bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T \bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T \bar{\mathbf{p}} - 2\bar{\mathbf{p}}^T \bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T \bar{\mathbf{p}} + \bar{\mathbf{p}}^T \bar{\mathbf{p}}$$

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{S}}}_N^{-2} \bar{\bar{\mathbf{V}}}_N^T\right\} + \bar{\mathbf{p}}^T \bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T \bar{\mathbf{p}} - 2\bar{\mathbf{p}}^T \bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T \bar{\mathbf{p}} + \bar{\mathbf{p}}^T \bar{\mathbf{p}}$$

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{S}}}_N^{-2} \bar{\bar{\mathbf{V}}}_N^T\right\} - \bar{\mathbf{p}}^T \bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T \bar{\mathbf{p}} + \bar{\mathbf{p}}^T \bar{\mathbf{p}}$$

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{S}}}_N^{-2} \bar{\bar{\mathbf{V}}}_N^T\right\} + \bar{\mathbf{p}}^T [\bar{\mathbf{I}} - \bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T] \bar{\mathbf{p}}$$

Lembrando da propriedade do traço do produto de matrizes

$$\text{tr}\{\bar{\bar{\mathbf{C}}}\bar{\bar{\mathbf{B}}}\} = \text{tr}\{\bar{\bar{\mathbf{B}}}\bar{\bar{\mathbf{C}}}\}$$

Então podemos escrever que

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\mathbf{S}}_N^{-2} \bar{\mathbf{V}}_N^T \bar{\mathbf{V}}_N\right\} + \bar{\mathbf{p}}^T \left[\bar{\mathbf{I}} - \bar{\mathbf{V}}_N \bar{\mathbf{V}}_N^T\right] \bar{\mathbf{p}}$$

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\mathbf{S}}_N^{-2}\right\} + \bar{\mathbf{p}}^T \left[\bar{\mathbf{I}} - \bar{\mathbf{V}}_N \bar{\mathbf{V}}_N^T\right] \bar{\mathbf{p}}$$

Como no caso MQ Sub $M \geq N = r$ então temos que

$$\bar{\mathbf{V}}_M \bar{\mathbf{V}}_M^T = \bar{\mathbf{V}}_N \bar{\mathbf{V}}_N^T + \bar{\mathbf{V}}_{M-N} \bar{\mathbf{V}}_{M-N}^T = \bar{\mathbf{I}}_M$$

então temos que $\bar{\mathbf{I}}_M - \bar{\mathbf{V}}_N \bar{\mathbf{V}}_N^T = \bar{\mathbf{V}}_{M-N} \bar{\mathbf{V}}_{M-N}^T$

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\mathbf{S}}_N^{-2}\right\} + \bar{\mathbf{p}}^T \left[\bar{\mathbf{V}}_{M-N} \bar{\mathbf{V}}_{M-N}^T\right] \bar{\mathbf{p}}$$

Chamando $\bar{\mathbf{V}}_{M-N}^T \bar{\mathbf{p}} = \bar{\mathbf{a}}_{M-N}$ temos que

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\mathbf{S}}_N^{-2}\right\} + \bar{\mathbf{a}}_{M-N}^T \bar{\mathbf{a}}_{M-N}$$

Com a decomposição em valores singulares da matriz de sensibilidade é igual a

$$\bar{\mathbf{A}} = \bar{\mathbf{U}}_r \bar{\mathbf{S}}_r \bar{\mathbf{V}}_r^T \text{ em que } r = N, \text{ temos que esperança da distância } (\hat{\mathbf{p}} - \bar{\mathbf{p}})^T (\hat{\mathbf{p}} - \bar{\mathbf{p}})$$

do estimador MQ Subdeterminado é dado por

$$E\{[\hat{\mathbf{p}} - \bar{\mathbf{p}}]^T [\hat{\mathbf{p}} - \bar{\mathbf{p}}]\} = \sigma^2 \sum_{i=1}^N \frac{1}{S_i^2} + \sum_{i=N+1}^M \alpha_i^2$$

(2.13)

em que $S_i, i = 1, 2, \dots, M$ são os valores singulares da matriz de sensibilidade $\bar{\mathbf{A}}$ (caso MQ Sub $N \geq M = r$). Note que basta a presença de um único valor singular próximo a zero para haver uma amplificação do ruído contido nos dados (variável σ^2 que é a variância do ruído dos dados). Isto faz com que a esperança da distância entre os

parâmetros estimados via MQ Sub ($\hat{\mathbf{p}}$) e os parâmetros $\bar{\mathbf{p}}$, que explicam os dados geofísicos exatos (dados sem ruído), seja um valor muito grande.

1.1.4) A matriz de resolução associada a $\hat{\mathbf{p}}$

Vimos na equação (9) que

$$\bar{\mathbf{R}} = \bar{\mathbf{H}} \bar{\mathbf{A}}$$

Como no estimador MQ Sub $\bar{\mathbf{H}} = \bar{\mathbf{A}}^T (\bar{\mathbf{A}} \bar{\mathbf{A}}^T)^{-1}$ temos que a equação acima é

dada por

$$\boxed{\bar{\mathbf{R}} = \bar{\mathbf{A}}^T (\bar{\mathbf{A}} \bar{\mathbf{A}}^T)^{-1} \bar{\mathbf{A}}} \quad (2.14)$$

Veja que a matriz de resolução estimador MQ Sub ($M \geq N = r$) NÃO é igual a matriz identidade. Isto significa dizer que cada elemento NÃO é estimado de modo ÚNICO (i.e., $\hat{p}_j, j = 1, 2, \dots, M$ NÃO são estimados independentemente). Dizemos que cada elemento de $\hat{\mathbf{p}}$ NÃO é perfeitamente resolvido. Em outras palavras, se a matriz de resolução estimador MQ Sub é diferente da a matriz identidade, isto significa dizer que o j-ésimo parâmetro estimado via MQ SUB é obtido como uma combinação linear de TODOS os parâmetros. Logo no estimador MQ SUB a resolução não é máxima.

Embora a matriz de resolução do estimador MQ SUB não seja máxima é a que mais se aproxima da $\bar{\mathbf{I}}_M$ (resolução máxima) no sentido de mínimos quadrados dentre a classe dos estimadores lineares inversos.

Usando a decomposição em valores singulares da matriz de sensibilidade é igual a $\bar{\mathbf{A}} = \bar{\mathbf{U}}_r \bar{\mathbf{S}}_r \bar{\mathbf{V}}_r^T$ em que $r = N$, logo temos que a equação (2.14) pode ser expressa como

$$\bar{\mathbf{R}} = \bar{\mathbf{V}}_N \bar{\mathbf{S}}_N \bar{\mathbf{U}}_N^T \left(\bar{\mathbf{U}}_N \bar{\mathbf{S}}_N \bar{\mathbf{V}}_N^T \bar{\mathbf{V}}_N \bar{\mathbf{S}}_N \bar{\mathbf{U}}_N^T \right)^{-1} \bar{\mathbf{U}}_N \bar{\mathbf{S}}_N \bar{\mathbf{V}}_N^T$$

$$\bar{\mathbf{R}} = \bar{\mathbf{V}}_N \bar{\mathbf{S}}_N \bar{\mathbf{U}}_N^T \left(\bar{\mathbf{U}}_N \bar{\mathbf{S}}_N^2 \bar{\mathbf{U}}_N^T \right)^{-1} \bar{\mathbf{U}}_N \bar{\mathbf{S}}_N \bar{\mathbf{V}}_N^T$$

como $r = N$ temos que $\bar{\bar{\mathbf{U}}}_N^{-1} = \bar{\bar{\mathbf{U}}}_N^T$

$$\bar{\bar{\mathbf{R}}} = \bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{S}}}_N \bar{\bar{\mathbf{U}}}_N^T \bar{\bar{\mathbf{U}}}_N \bar{\bar{\mathbf{S}}}_N^{-2} \bar{\bar{\mathbf{U}}}_N^T \bar{\bar{\mathbf{U}}}_N \bar{\bar{\mathbf{S}}}_N \bar{\bar{\mathbf{V}}}_N^T$$

$$\bar{\bar{\mathbf{R}}} = \bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{S}}}_N \bar{\bar{\mathbf{S}}}_N^{-2} \bar{\bar{\mathbf{S}}}_N \bar{\bar{\mathbf{V}}}_N^T$$

$$\boxed{\bar{\bar{\mathbf{R}}} = \bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T} \quad (2.15)$$

Vamos analisar a equação (2.15). Veja que no caso MQ Sub $M \geq N = r$ então temos

$$\text{que } \bar{\bar{\mathbf{V}}}_M \bar{\bar{\mathbf{V}}}_M^T = \bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T + \bar{\bar{\mathbf{V}}}_{M-N} \bar{\bar{\mathbf{V}}}_{M-N}^T = \bar{\bar{\mathbf{I}}}_M$$

então temos que

$$\bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T = \bar{\bar{\mathbf{I}}}_M - \bar{\bar{\mathbf{V}}}_{M-N} \bar{\bar{\mathbf{V}}}_{M-N}^T$$

Sabemos que

$$\hat{\bar{\mathbf{p}}} = \bar{\bar{\mathbf{R}}} \bar{\mathbf{p}}$$

então podemos escrever que o estimador MQ SUB é expresso como

$$\hat{\bar{\mathbf{p}}} = \bar{\bar{\mathbf{V}}}_N \bar{\bar{\mathbf{V}}}_N^T \bar{\mathbf{p}}$$

$$\hat{\bar{\mathbf{p}}} = \left(\bar{\bar{\mathbf{I}}}_M - \bar{\bar{\mathbf{V}}}_{M-N} \bar{\bar{\mathbf{V}}}_{M-N}^T \right) \bar{\mathbf{p}}$$

$$\hat{\bar{\mathbf{p}}} = \bar{\mathbf{p}} - \bar{\bar{\mathbf{V}}}_{M-N} \bar{\bar{\mathbf{V}}}_{M-N}^T \bar{\mathbf{p}}$$

Chamando $\bar{\bar{\mathbf{V}}}_{M-N}^T \bar{\mathbf{p}} = \bar{\bar{\alpha}}_{M-N}$ temos que

$$\hat{\bar{\mathbf{p}}} = \bar{\mathbf{p}} - \bar{\bar{\mathbf{V}}}_{M-N} \bar{\bar{\alpha}}_{M-N}$$

Como $\bar{\bar{\mathbf{V}}}_{M-N} \bar{\bar{\alpha}}_{M-N} = \bar{\mathbf{p}}^{null}$ então o estimador MQ SUB é expresso como

$$\boxed{\hat{\bar{\mathbf{p}}} = \bar{\mathbf{p}} - \bar{\mathbf{p}}^{Null}} \quad (2.16)$$

O resultado mostrado pela equação (2.16) diz que o estimador MQ SUB é uma solução que nunca contém qualquer solução nula ($\bar{\mathbf{p}}^{null}$)

2.1.5) A matriz densidade de informação associada a $\hat{\mathbf{p}}$

Vimos na equação (10) que

$$\overline{\overline{\mathbf{F}}}_{(N \times N)} = \overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{H}}}$$

Como no estimador MQ Sub $\overline{\overline{\mathbf{H}}} = \overline{\overline{\mathbf{A}}}^T (\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{A}}}^T)^{-1}$ temos que a equação acima é dada por

$$\overline{\overline{\mathbf{F}}} = \overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{A}}}^T (\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{A}}}^T)^{-1}$$

$$\overline{\overline{\mathbf{F}}} = \overline{\overline{\mathbf{I}}}_N$$

(2.17)

A equação (2.17) mostra que a matriz densidade de informação do estimador MQ Sub é igual a matriz identidade. Isto quer dizer que os dados observados e os dados ajustados via estimador MQ Sub é igual a zero ($\overline{\overline{\boldsymbol{\varepsilon}}} = \overline{\overline{\mathbf{0}}}$). Conclusão, no estimador MQ SUB o ajuste é EXATO.

Análise do ajuste dos dados observados produzido pela solução estimada via Mínimos Quadrados SUBDETERMINADO

Vamos analisar o ajuste dos dados observados produzido pela solução estimada via estimador MQ SUB. Considerando que os dados observados estão contaminados por ruído aleatório aditivo $\overline{\overline{\boldsymbol{\varepsilon}}}$ e que em um problema linear a componente determinística (vetor dos dados ajustados ou calculados) é $\overline{\overline{\mathbf{y}}}^c = \overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{p}}}$. Então os dados geofísicos observados $\overline{\overline{\mathbf{y}}}^o$ pode ser expresso por

$$\overline{\overline{\mathbf{y}}}^o = \overline{\overline{\mathbf{y}}}^c + \overline{\overline{\boldsymbol{\varepsilon}}}$$

$$\overline{\overline{\mathbf{y}}}^o = \overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{p}}} + \overline{\overline{\boldsymbol{\varepsilon}}}$$

Como a estimativa do vetor de parâmetros via estimador MQ SUB é dado por

$$\hat{\mathbf{p}} = \overline{\overline{\mathbf{A}}}^T (\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{A}}}^T)^{-1} \overline{\overline{\mathbf{y}}}^o$$

então o ajuste dos dados observados produzido pela solução estimada via estimador MQ SUB é um AJUSTE EXATO, isto porque $\overline{\overline{\boldsymbol{\varepsilon}}} = \overline{\overline{\mathbf{0}}}$:

$$\bar{\mathbf{y}}^o = \bar{\mathbf{A}} \hat{\bar{\mathbf{p}}} + \bar{\boldsymbol{\varepsilon}}$$

$$\bar{\mathbf{y}}^o = \bar{\mathbf{A}} \bar{\mathbf{A}}^T \left(\bar{\mathbf{A}} \bar{\mathbf{A}}^T \right)^{-1} \bar{\mathbf{y}}^o + \bar{\boldsymbol{\varepsilon}}$$

$$\bar{\mathbf{y}}^o = \bar{\mathbf{y}}^o + \bar{\boldsymbol{\varepsilon}}$$

$$\bar{\boldsymbol{\varepsilon}} = \bar{\mathbf{0}}$$

Esta mesma análise pode ser realizada via SVD considerando que o estimador de MQ

SUB é dado por $\hat{\bar{\mathbf{p}}} = \bar{\mathbf{V}}_N \bar{\mathbf{S}}_N^{-1} \bar{\mathbf{U}}_N^T \bar{\mathbf{y}}^o$ e que o $r = N$

$$\bar{\mathbf{y}}^o = \bar{\mathbf{A}} \hat{\bar{\mathbf{p}}} + \bar{\boldsymbol{\varepsilon}}$$

$$\bar{\mathbf{y}}^o = \bar{\mathbf{U}}_N \bar{\mathbf{S}}_N \bar{\mathbf{V}}_N^T \left(\bar{\mathbf{V}}_N \bar{\mathbf{S}}_N^{-1} \bar{\mathbf{U}}_N^T \bar{\mathbf{y}}^o \right) + \bar{\boldsymbol{\varepsilon}}$$

$$\bar{\mathbf{y}}^o = \bar{\mathbf{U}}_N \bar{\mathbf{U}}_N^T \bar{\mathbf{y}}^o + \bar{\boldsymbol{\varepsilon}}$$

como $r = N$ então $\bar{\mathbf{U}}_N \bar{\mathbf{U}}_N^T = \bar{\mathbf{I}}$

$$\bar{\boldsymbol{\varepsilon}} = \bar{\mathbf{0}}$$