

DEDUÇÃO DO ESTIMADOR INVERSA GENERALIZADA

VIA MÉTODO DOS MULTIPLICADORES DE LAGRANGE

Vimos que quando há $M-r$ valores singulares nulos temos infinitas soluções uma vez que a solução que minimiza a soma dos quadrados dos resíduos é

$$\bar{\mathbf{a}}_r' = \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{\beta}}_r \quad (1)$$

Portanto a parte do vetor $\bar{\mathbf{a}}$ correspondente a $\bar{\mathbf{a}}_{M-r}$ não é usada para minimizar o funcional

$$Q = \left\| \bar{\mathbf{\beta}}_r - \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{a}}_r \right\|_2^2 + \left\| \bar{\mathbf{\beta}}_{M-r} \right\|_2^2 + \left\| \bar{\mathbf{\beta}}_{N-M} \right\|_2^2 \quad (2)$$

Então, se temos $M-r$ valores singulares nulos temos

$$\begin{aligned} \bar{\mathbf{p}}^* = \bar{\mathbf{V}} \bar{\mathbf{a}}' &= \begin{bmatrix} \bar{\mathbf{V}}_r & \bar{\mathbf{V}}_{M-r} \\ (M \times r) & (M \times M-r) \end{bmatrix} \begin{bmatrix} \bar{\mathbf{a}}_r' \\ \bar{\mathbf{a}}_{M-r}' \end{bmatrix} \\ \bar{\mathbf{p}}^* = \bar{\mathbf{V}} \bar{\mathbf{a}}' &= \begin{bmatrix} \bar{\mathbf{V}}_r & \bar{\mathbf{V}}_{M-r} \\ (M \times r) & (M \times M-r) \end{bmatrix} \begin{bmatrix} \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{\beta}}_r \\ \bar{\mathbf{S}}_{M-r}^{-1} \bar{\mathbf{\beta}}_{M-r} \end{bmatrix} \\ \bar{\mathbf{p}}^* &= \bar{\mathbf{V}}_r \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{\beta}}_r + \bar{\mathbf{V}}_{M-r} \bar{\mathbf{S}}_{M-r}^{-1} \bar{\mathbf{\beta}}_{M-r} \end{aligned}$$

¹. Veja a dedução do estimador $\bar{\mathbf{a}}'$ na aula Tópico 15 SVD como ferramenta

$$\bar{\mathbf{p}}^* = \sum_{i=1}^r \frac{\beta_i}{S_i} \bar{\mathbf{v}}_i + \underbrace{\sum_{i=r+1}^M \frac{\beta_i}{S_i} \bar{\mathbf{v}}_i}_{\in \text{Espaço Nulo}}$$

Vimos que no caso de $M - r$ valores singulares nulos, podemos atribuir ao vetor

$\bar{\alpha}'_{M-r}$ qualquer valor, então teremos por consequência infinitas soluções (não unicidade da solução)

$$\bar{\mathbf{p}}^* = \bar{\bar{\mathbf{V}}}_r \bar{\alpha}'_r + \underbrace{\bar{\bar{\mathbf{V}}}_{M-r} \bar{\alpha}'_{M-r}}_{\bar{\mathbf{p}}^{null}} \quad (3)$$

produzindo o mesmo mínimo da função Q dado pela equação (2). Em outras palavras temos a existência do espaço nulo e consequentemente $M-r$ vetores soluções nulas, implicando uma solução geral dada por

$$\bar{\mathbf{p}}_{\text{geral}} = \bar{\mathbf{p}}_{\text{particular}} + \bar{\mathbf{p}}^{null}$$

Vimos também que no caso de $M - r$ valores singulares próximos a zero temos:

$$\bar{\mathbf{p}}^* = \bar{\bar{\mathbf{V}}}_r \bar{\alpha}'_r + \bar{\bar{\mathbf{V}}}_{M-r} \bar{\alpha}'_{M-r} \quad (4)$$

$$\bar{\mathbf{p}}^* = \sum_{i=1}^r \alpha'_i \bar{\mathbf{v}}_i + \sum_{i=r+1}^M \alpha'_i \bar{\mathbf{v}}_i \quad (5)$$

$$\bar{\mathbf{p}}^* = \sum_{i=1}^r \frac{\beta_i}{S_i} \bar{\mathbf{v}}_i + \underbrace{\sum_{i=r+1}^M \frac{\beta_i}{S_i} \bar{\mathbf{v}}_i}_{\text{valores pequenos de } S_i} \quad (6)$$

Como temos $S_i, i = r + 1, \dots, M$ muito pequenos teremos uma instabilidade da solução promovida pela segunda parcela da equação (6), especificamente devida a parcela de $\bar{\mathbf{a}}'$ correspondente a $\bar{\mathbf{a}}'_{M-r}$ [equação (4)]. Neste caso, a solução é única porém, instável e produzirão um mínimo de Q [equação (2)].

Em resumo, em qualquer destes dois casos apresentados [caso (1) M - r valores singulares nulos e caso (2) M - r valores singulares muito pequenos] os elementos de $\bar{\mathbf{a}}'_{M-r}$ não podem ser determinados apenas das observações geofísicas. Então buscaremos um modo de tornar o espaço desconhecido composto pelo vetor $\bar{\mathbf{a}}'_{M-r}$ em um espaço conhecido. Para isto usaremos informações independentes das observações geofísicas para determinarmos os elementos do vetor $\bar{\mathbf{a}}'_{M-r}$.

Formularemos então o seguinte problema matemático vinculado

$$\text{Minimize } \left\| \bar{\mathbf{W}}_{\mathbf{p}}^{1/2} \bar{\mathbf{p}} \right\|_2^2 \quad (7)$$

Sujeito a

$$\left\| \bar{\mathbf{W}}_{\mathbf{e}}^{1/2} \bar{\mathbf{e}} \right\|_2^2 = \delta$$

que pode ser re-escrito como

$$\text{Minimize } \bar{\mathbf{p}}^T \bar{\mathbf{W}}_{\mathbf{p}} \bar{\mathbf{p}} \quad (8)$$

Sujeito a

$$\left(\bar{\mathbf{A}}\bar{\mathbf{p}} - \bar{\mathbf{y}}^0 \right)^T \bar{\mathbf{W}}_{\mathbf{e}} \left(\bar{\mathbf{A}}\bar{\mathbf{p}} - \bar{\mathbf{y}}^0 \right) = \delta$$

Façamos

$$\overline{\overline{\mathbf{W}}}_p = \overline{\overline{\mathbf{V}}} \begin{bmatrix} \overline{\overline{\mathbf{0}}} & \overline{\overline{\mathbf{0}}} \\ \overline{\overline{\mathbf{0}}} & \overline{\overline{\boldsymbol{\eta}}} \end{bmatrix} \overline{\overline{\mathbf{V}}}^T$$

em que $\overline{\overline{\boldsymbol{\eta}}}$ é uma matriz diagonal, não singular com dimensão $(M - r \times M - r)$ e

$$\overline{\overline{\mathbf{W}}}_e = \overline{\overline{\mathbf{U}}} \begin{bmatrix} \overline{\overline{\boldsymbol{\gamma}}} & \overline{\overline{\mathbf{0}}} \\ \overline{\overline{\mathbf{0}}} & \overline{\overline{\mathbf{0}}} \end{bmatrix} \overline{\overline{\mathbf{U}}}^T$$

em que $\overline{\overline{\boldsymbol{\gamma}}}$ é uma matriz diagonal, não singular com dimensão $(r \times r)$.

Particionando a matriz $\overline{\overline{\mathbf{V}}}$ podemos re-escrever a matriz $\overline{\overline{\mathbf{W}}}_p$ como

$$\overline{\overline{\mathbf{W}}}_p = \begin{bmatrix} \overline{\overline{\mathbf{V}}}_r & \overline{\overline{\mathbf{V}}}_{M-r} \end{bmatrix} \begin{bmatrix} \overline{\overline{\mathbf{0}}} & \overline{\overline{\mathbf{0}}} \\ \overline{\overline{\mathbf{0}}} & \overline{\overline{\boldsymbol{\eta}}} \end{bmatrix} \begin{bmatrix} \overline{\overline{\mathbf{V}}}_r^T \\ \overline{\overline{\mathbf{V}}}_{M-r}^T \end{bmatrix} = \overline{\overline{\mathbf{V}}}_{M-r} \overline{\overline{\boldsymbol{\eta}}} \overline{\overline{\mathbf{V}}}_{M-r}^T \quad (9)$$

Particionando a matriz $\overline{\overline{\mathbf{U}}}$ podemos re-escrever a matriz $\overline{\overline{\mathbf{W}}}_e$ como

$$\overline{\overline{\mathbf{W}}}_e = \begin{bmatrix} \overline{\overline{\mathbf{U}}}_r & \overline{\overline{\mathbf{U}}}_{N-r} \end{bmatrix} \begin{bmatrix} \overline{\overline{\boldsymbol{\gamma}}} & \overline{\overline{\mathbf{0}}} \\ \overline{\overline{\mathbf{0}}} & \overline{\overline{\mathbf{0}}} \end{bmatrix} \begin{bmatrix} \overline{\overline{\mathbf{U}}}_r^T \\ \overline{\overline{\mathbf{U}}}_{N-r}^T \end{bmatrix} = \overline{\overline{\mathbf{U}}}_r \overline{\overline{\boldsymbol{\gamma}}} \overline{\overline{\mathbf{U}}}_r^T \quad (10)$$

Em resumo, o nosso problema consiste em resolver o seguinte problema vinculado

$$\text{Minimize } \overline{\overline{\mathbf{p}}}^T \overline{\overline{\mathbf{W}}}_p \overline{\overline{\mathbf{p}}} \quad (11)$$

Sujeito a

$$\left(\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{p}}} - \overline{\overline{\mathbf{y}}}^0 \right)^T \overline{\overline{\mathbf{W}}}_e \left(\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{p}}} - \overline{\overline{\mathbf{y}}}^0 \right) = \delta$$

em que

$$\overline{\overline{\mathbf{W}}}_p = \overline{\overline{\mathbf{V}}}_{M-r} \overline{\overline{\boldsymbol{\eta}}} \overline{\overline{\mathbf{V}}}_{M-r}^T \quad (12)$$

e

$$\overline{\overline{\mathbf{W}_e}} = \overline{\overline{\mathbf{U}_r}} \overline{\overline{\boldsymbol{\gamma}}} \overline{\overline{\mathbf{U}_r}}^T \quad (13)$$

Transformando um problema vinculado em um problema não vinculado via método dos multiplicadores de Lagrange temos que a função objeto não vinculada a ser minimizada é

$$\Gamma = \overline{\overline{\mathbf{p}}}^T \overline{\overline{\mathbf{W}_p}} \overline{\overline{\mathbf{p}}} + \frac{1}{\lambda} \left[\left(\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{p}}} - \overline{\overline{\mathbf{y}^0}} \right)^T \overline{\overline{\mathbf{W}_e}} \left(\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{p}}} - \overline{\overline{\mathbf{y}^0}} \right) - \delta \right] \quad (14)$$

Condição de mínimo da função não vinculada $\Gamma(\overline{\overline{\mathbf{p}}})$ é

$$\overline{\overline{\nabla_{\overline{\overline{\mathbf{p}}}}}(\Gamma)} = \overline{\overline{\mathbf{0}}}$$

O vetor gradiente em relação ao vetor de parâmetros da função não vinculada é

$$\overline{\overline{\nabla_{\overline{\overline{\mathbf{p}}}}}(\Gamma)} = 2 \overline{\overline{\nabla_{\overline{\overline{\mathbf{p}}}}} \{ \overline{\overline{\mathbf{p}}}^T \} \overline{\overline{\mathbf{W}_p}} \overline{\overline{\mathbf{p}}} + \frac{1}{\lambda} 2 \left[\left(\overline{\overline{\nabla_{\overline{\overline{\mathbf{p}}}}} \{ \overline{\overline{\mathbf{p}}}^T \overline{\overline{\mathbf{A}}}^T \} - \overline{\overline{\nabla_{\overline{\overline{\mathbf{p}}}}} \{ \overline{\overline{\mathbf{y}^0}}^T \} \right) \overline{\overline{\mathbf{W}_e}} \left(\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{p}}} - \overline{\overline{\mathbf{y}^0}} \right) \right]$$

$$\overline{\overline{\nabla_{\overline{\overline{\mathbf{p}}}}}(\Gamma)} = 2 \overline{\overline{\mathbf{W}_p}} \overline{\overline{\mathbf{p}}} + \frac{1}{\lambda} 2 \overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}_e}} \left(\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{p}}} - \overline{\overline{\mathbf{y}^0}} \right)$$

$$\overline{\overline{\nabla_{\overline{\overline{\mathbf{p}}}}}(\Gamma)} = 2 \lambda \overline{\overline{\mathbf{W}_p}} \overline{\overline{\mathbf{p}}} + 2 \overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}_e}} \overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{p}}} - 2 \overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}_e}} \overline{\overline{\mathbf{y}^0}}$$

igualando o vetor gradiente acima ao vetor nulo temos

$$2 \lambda \overline{\overline{\mathbf{W}_p}} \overline{\overline{\mathbf{p}}} + 2 \overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}_e}} \overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{p}}} - 2 \overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}_e}} \overline{\overline{\mathbf{y}^0}} = \overline{\overline{\mathbf{0}}}$$

Dividindo ambos os lados da equação acima por 2 temos

$$\left(\overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}_e}} \overline{\overline{\mathbf{A}}} + \lambda \overline{\overline{\mathbf{W}_p}} \right) \overline{\overline{\mathbf{p}}} = \overline{\overline{\mathbf{A}}}^T \overline{\overline{\mathbf{W}_e}} \overline{\overline{\mathbf{y}^0}} \quad (15)$$

Vamos agora usar a decomposição em valores singulares da matriz de sensibilidade

(i.e. $\overline{\overline{\mathbf{A}}} = \overline{\overline{\mathbf{U}_r}} \overline{\overline{\mathbf{S}_r}} \overline{\overline{\mathbf{V}_r}}^T$) e substituir as matrizes (12) e (13) na equação acima

$$\begin{aligned} \left(\overline{\mathbf{V}}_r \overline{\mathbf{S}}_r \overline{\mathbf{U}}_r^T \left(\overline{\mathbf{U}}_r \quad \overline{\boldsymbol{\gamma}} \quad \overline{\mathbf{U}}_r^T \right) \overline{\mathbf{U}}_r \overline{\mathbf{S}}_r \overline{\mathbf{V}}_r^T + \lambda \overline{\mathbf{V}}_{M-r} \quad \overline{\boldsymbol{\eta}} \quad \overline{\mathbf{V}}_{M-r}^T \right) \overline{\mathbf{p}}^+ &= \overline{\mathbf{V}}_r \overline{\mathbf{S}}_r \overline{\mathbf{U}}_r^T \left(\overline{\mathbf{U}}_r \quad \overline{\boldsymbol{\gamma}} \quad \overline{\mathbf{U}}_r^T \right) \overline{\mathbf{y}}^0 \\ \left(\overline{\mathbf{V}}_r \overline{\mathbf{S}}_r \overline{\boldsymbol{\gamma}} \overline{\mathbf{S}}_r \overline{\mathbf{V}}_r^T + \lambda \overline{\mathbf{V}}_{M-r} \quad \overline{\boldsymbol{\eta}} \quad \overline{\mathbf{V}}_{M-r}^T \right) \overline{\mathbf{p}}^+ &= \overline{\mathbf{V}}_r \overline{\mathbf{S}}_r \overline{\boldsymbol{\gamma}} \overline{\mathbf{U}}_r^T \overline{\mathbf{y}}^0 \end{aligned}$$

Vamos agora pré-multiplicar os dois lados da equação acima por $\overline{\mathbf{V}}_r^T$

$$\begin{aligned} \overline{\mathbf{V}}_r^T \left(\overline{\mathbf{V}}_r \overline{\mathbf{S}}_r \overline{\boldsymbol{\gamma}} \overline{\mathbf{S}}_r \overline{\mathbf{V}}_r^T + \lambda \overline{\mathbf{V}}_{M-r} \quad \overline{\boldsymbol{\eta}} \quad \overline{\mathbf{V}}_{M-r}^T \right) \overline{\mathbf{p}}^+ &= \overline{\mathbf{V}}_r^T \overline{\mathbf{V}}_r \overline{\mathbf{S}}_r \overline{\boldsymbol{\gamma}} \overline{\mathbf{U}}_r^T \overline{\mathbf{y}}^0 \\ \left(\overline{\mathbf{V}}_r^T \overline{\mathbf{V}}_r \overline{\mathbf{S}}_r \overline{\boldsymbol{\gamma}} \overline{\mathbf{S}}_r \overline{\mathbf{V}}_r^T + \lambda \overline{\mathbf{V}}_r^T \overline{\mathbf{V}}_{M-r} \quad \overline{\boldsymbol{\eta}} \quad \overline{\mathbf{V}}_{M-r}^T \right) \overline{\mathbf{p}}^+ &= \overline{\mathbf{V}}_r^T \overline{\mathbf{V}}_r \overline{\mathbf{S}}_r \overline{\boldsymbol{\gamma}} \overline{\mathbf{U}}_r^T \overline{\mathbf{y}}^0 \end{aligned}$$

Como $\overline{\mathbf{V}}_r^T \overline{\mathbf{V}}_{M-r} = \overline{\mathbf{0}}$ porque os autovetores são ortogonais então temos

$$\left(\overline{\mathbf{S}}_r \overline{\boldsymbol{\gamma}} \overline{\mathbf{S}}_r \overline{\mathbf{V}}_r^T \right) \overline{\mathbf{p}}^+ = \overline{\mathbf{S}}_r \overline{\boldsymbol{\gamma}} \overline{\mathbf{U}}_r^T \overline{\mathbf{y}}^0 \quad (16)$$

Como as matrizes $\overline{\boldsymbol{\gamma}}$ e $\overline{\mathbf{S}}_r$ são matrizes não singulares podemos escrever

$$\begin{aligned} \left(\overline{\mathbf{V}}_r^T \right) \overline{\mathbf{p}}^+ &= \left(\overline{\mathbf{S}}_r \quad \overline{\boldsymbol{\gamma}} \quad \overline{\mathbf{S}}_r \right)^{-1} \overline{\mathbf{S}}_r \overline{\boldsymbol{\gamma}} \overline{\mathbf{U}}_r^T \overline{\mathbf{y}}^0 \\ \overline{\mathbf{V}}_r^T \overline{\mathbf{p}}^+ &= \overline{\mathbf{S}}_r^{-1} \overline{\boldsymbol{\gamma}}^{-1} \overline{\mathbf{S}}_r^{-1} \overline{\mathbf{S}}_r \overline{\boldsymbol{\gamma}} \overline{\mathbf{U}}_r^T \overline{\mathbf{y}}^0 \\ \overline{\mathbf{V}}_r^T \overline{\mathbf{p}}^+ &= \overline{\mathbf{S}}_r^{-1} \overline{\mathbf{U}}_r^T \overline{\mathbf{y}}^0 \end{aligned} \quad (17)$$

Se $r = M$ a solução $\bar{\mathbf{p}}^+$ que satisfaz a equação (17) é única porque, se multiplicarmos os dois lados da equação (17) por $\bar{\mathbf{V}}_r$ teremos, neste caso $\bar{\mathbf{V}}_r \bar{\mathbf{V}}_r^T = \bar{\mathbf{I}}_M$ logo a equação (17) é dada por

$$\bar{\mathbf{p}}^+ = \bar{\mathbf{V}}_r \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{U}}_r^T \bar{\mathbf{y}}^0 \quad \text{se } r = M \quad (18)$$

O estimador acima $\bar{\mathbf{p}}^+$ é chamado como **estimador IG (Inversa Generalizada)**.

Por outro lado, se $r < M$, não há uma solução única que satisfaz a equação (17).

Isto porque $\bar{\mathbf{V}}_r$ é singular. Então se multiplicarmos os dois lados da equação (17) por $\bar{\mathbf{V}}_r$ teremos

$$\bar{\mathbf{V}}_r \bar{\mathbf{V}}_r^T \bar{\mathbf{p}}^+ = \bar{\mathbf{V}}_r \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{U}}_r^T \bar{\mathbf{y}}^0 \quad \text{se } r < M \quad (19)$$

Note, neste caso em que $r < M$, não há uma solução única para $\bar{\mathbf{p}}^+$ isto porque

$\bar{\mathbf{V}}_r \bar{\mathbf{V}}_r^T$ é uma matriz é singular.²

No entanto, observe que apesar de não existir uma solução única da equação (19) podemos afirmar que o estimador IG [equação (18)] é uma das possíveis soluções isto porque se substituirmos a equação (18) na equação (19) temos

$$\begin{aligned} \bar{\mathbf{V}}_r \bar{\mathbf{V}}_r^T \left(\bar{\mathbf{V}}_r \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{U}}_r^T \bar{\mathbf{y}}^0 \right) &= \bar{\mathbf{V}}_r \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{U}}_r^T \bar{\mathbf{y}}^0 \\ \bar{\mathbf{V}}_r \bar{\mathbf{V}}_r^T \bar{\mathbf{V}}_r \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{U}}_r^T \bar{\mathbf{y}}^0 &= \bar{\mathbf{V}}_r \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{U}}_r^T \bar{\mathbf{y}}^0 \end{aligned}$$

². Lembre-se que $\bar{\mathbf{V}} \bar{\mathbf{V}}^T = \bar{\mathbf{V}}_r \bar{\mathbf{V}}_r^T + \bar{\mathbf{V}}_{M-r} \bar{\mathbf{V}}_{M-r}^T = \bar{\mathbf{I}}_M$

$$\overline{\overline{\mathbf{V}}}_r \overline{\overline{\mathbf{S}}}_r^{-1} \overline{\overline{\mathbf{U}}}_r^T \overline{\mathbf{y}}^0 \equiv \overline{\overline{\mathbf{V}}}_r \overline{\overline{\mathbf{S}}}_r^{-1} \overline{\overline{\mathbf{U}}}_r^T \overline{\mathbf{y}}^0$$

Análise da Informação a priori introduzida pelo estimador Inversa Generalizada

Introduzimos a informação a priori da solução estimada

$$\text{mínimar } \phi(\overline{\mathbf{p}}) = \|\overline{\overline{\mathbf{W}}}_p^{1/2} \overline{\mathbf{p}}\|_2^2$$

i.e.,

$$\text{minimizar } \phi(\overline{\mathbf{p}}) = \overline{\mathbf{p}}^T \overline{\overline{\mathbf{W}}}_p \overline{\mathbf{p}}$$

$$\text{em que } \overline{\overline{\mathbf{W}}}_p = \overline{\overline{\mathbf{V}}}_{M-r} \overline{\overline{\boldsymbol{\eta}}} \overline{\overline{\mathbf{V}}}_{M-r}^T$$

Portanto, minimizamos a função

$$\phi(\overline{\mathbf{p}}) = \overline{\mathbf{p}}^T \overline{\overline{\mathbf{V}}}_{M-r} \overline{\overline{\boldsymbol{\eta}}} \overline{\overline{\mathbf{V}}}_{M-r}^T \overline{\mathbf{p}} \quad (20)$$

Considerando que o vetor $\overline{\boldsymbol{\alpha}}$ é a projeção dos parâmetros $\overline{\mathbf{p}}$ nos autovetores da matriz $\overline{\overline{\mathbf{V}}}$ (na base que gera o espaço dos parâmetros), i.e.,

$$\overline{\overline{\mathbf{V}}}^T \overline{\mathbf{p}} = \overline{\boldsymbol{\alpha}}.$$

Se $r = m$ pré-multiplicando os dois lados da equação por $\overline{\overline{\mathbf{V}}}$ temos que

$$\begin{aligned} \overline{\overline{\mathbf{V}}} \overline{\overline{\mathbf{V}}}^T \overline{\mathbf{p}} &= \overline{\overline{\mathbf{V}}} \overline{\boldsymbol{\alpha}} \\ \overline{\mathbf{p}} &= \overline{\overline{\mathbf{V}}} \overline{\boldsymbol{\alpha}} \end{aligned}$$

Substituindo o vetor $\overline{\mathbf{p}} = \overline{\overline{\mathbf{V}}} \overline{\boldsymbol{\alpha}}$ na equação (20) temos:

$$\phi(\overline{\mathbf{p}}) = \overline{\boldsymbol{\alpha}}^T \overline{\overline{\mathbf{V}}}^T \overline{\overline{\mathbf{V}}}_{M-r} \overline{\overline{\boldsymbol{\eta}}} \overline{\overline{\mathbf{V}}}_{M-r}^T \overline{\overline{\mathbf{V}}} \overline{\boldsymbol{\alpha}}$$

$$\begin{aligned}\phi(\bar{\mathbf{p}}) &= \begin{bmatrix} \bar{\mathbf{a}}_r^T & \bar{\mathbf{a}}_{M-r}^T \\ (1 \times 2) & \end{bmatrix} \begin{bmatrix} \bar{\bar{\mathbf{V}}}_r^T \\ \bar{\bar{\mathbf{V}}}_{M-r}^T \\ (2 \times 1) \end{bmatrix} \begin{bmatrix} \bar{\mathbf{0}} & \bar{\bar{\mathbf{V}}}_{M-r} \\ (1 \times 2) \end{bmatrix} \begin{bmatrix} \bar{\mathbf{0}} & \bar{\mathbf{0}} \\ \bar{\mathbf{0}} & \bar{\bar{\eta}} \\ (2 \times 2) \end{bmatrix} \begin{bmatrix} \bar{\mathbf{0}} \\ \bar{\bar{\mathbf{V}}}_{M-r}^T \\ (2 \times 1) \end{bmatrix} \begin{bmatrix} \bar{\bar{\mathbf{V}}}_r & \bar{\bar{\mathbf{V}}}_{M-r} \\ (1 \times 2) \end{bmatrix} \begin{bmatrix} \bar{\mathbf{a}}_r \\ \bar{\mathbf{a}}_{M-r} \\ (2 \times 1) \end{bmatrix} \\ \phi(\bar{\mathbf{p}}) &= \left(\bar{\mathbf{a}}_r^T \bar{\bar{\mathbf{V}}}_r^T + \bar{\mathbf{a}}_{M-r}^T \bar{\bar{\mathbf{V}}}_{M-r}^T \right) \begin{bmatrix} \bar{\mathbf{0}} & \bar{\bar{\mathbf{V}}}_{M-r} \\ (1 \times 2) \end{bmatrix} \begin{bmatrix} \bar{\mathbf{0}} & \bar{\mathbf{0}} \\ \bar{\mathbf{0}} & \bar{\bar{\eta}} \\ (2 \times 2) \end{bmatrix} \begin{bmatrix} \bar{\mathbf{0}} \\ \bar{\bar{\mathbf{V}}}_{M-r}^T \\ (2 \times 1) \end{bmatrix} \left(\bar{\bar{\mathbf{V}}}_r \bar{\mathbf{a}}_r + \bar{\bar{\mathbf{V}}}_{M-r} \bar{\mathbf{a}}_{M-r} \right) \\ \phi(\bar{\mathbf{p}}) &= \begin{bmatrix} \bar{\mathbf{0}} & \bar{\mathbf{a}}_{M-r}^T \bar{\bar{\mathbf{V}}}_{M-r}^T \bar{\bar{\mathbf{V}}}_{M-r} \\ (1 \times 2) \end{bmatrix} \begin{bmatrix} \bar{\mathbf{0}} & \bar{\mathbf{0}} \\ \bar{\mathbf{0}} & \bar{\bar{\eta}} \\ (2 \times 2) \end{bmatrix} \begin{bmatrix} \bar{\bar{\mathbf{V}}}_{M-r}^T & \bar{\bar{\mathbf{V}}}_{M-r} \bar{\mathbf{a}}_{M-r} \\ (2 \times 1) \end{bmatrix}\end{aligned}$$

Como $\bar{\bar{\mathbf{V}}}_{M-r}^T \bar{\bar{\mathbf{V}}}_{M-r} = \bar{\bar{\mathbf{I}}}_{M-r}$

$$\begin{aligned}\phi(\bar{\mathbf{p}}) &= \begin{bmatrix} \bar{\mathbf{0}} & \bar{\mathbf{a}}_{M-r}^T \bar{\bar{\mathbf{I}}}_{M-r} \\ (1 \times 2) \end{bmatrix} \begin{bmatrix} \bar{\mathbf{0}} & \bar{\mathbf{0}} \\ \bar{\mathbf{0}} & \bar{\bar{\eta}} \\ (2 \times 2) \end{bmatrix} \begin{bmatrix} \bar{\mathbf{0}} \\ \bar{\mathbf{a}}_{M-r} \bar{\bar{\mathbf{I}}}_{M-r} \\ (2 \times 1) \end{bmatrix} \\ \phi(\bar{\mathbf{p}}) &= \begin{bmatrix} \bar{\mathbf{0}} & \bar{\mathbf{a}}_{M-r}^T \bar{\bar{\eta}} \\ (1 \times 2) \end{bmatrix} \begin{bmatrix} \bar{\mathbf{0}} \\ \bar{\mathbf{a}}_{M-r} \bar{\bar{\mathbf{I}}}_{M-r} \\ (2 \times 1) \end{bmatrix}\end{aligned}$$

$$\phi(\bar{\mathbf{p}}) = \bar{\mathbf{a}}_{M-r}^T \bar{\bar{\eta}} \bar{\mathbf{a}}_{M-r} \quad (21)$$

A informação a priori introduzida pelo estimador IG é de minimizar o funcional

$$\phi(\bar{\mathbf{p}}) = \bar{\mathbf{p}}^T \bar{\bar{\mathbf{W}}}_p \bar{\mathbf{p}}$$

Mostramos que a minimização deste funcional acima é equivalente a minimizar o funcional (21)

$$\phi(\bar{\mathbf{p}}) = \bar{\mathbf{a}}_{M-r}^T \bar{\bar{\eta}} \bar{\mathbf{a}}_{M-r}$$

ou ainda que

$$\phi(\bar{\mathbf{p}}) = \sum_{i=r+1}^M \alpha_i^2 \eta_i$$

i.e., a informação introduzida pelo estimador IG é equivalente a minimizar a seguinte soma

$$\phi(\bar{\mathbf{p}}) = \alpha_{r+1}^2 \eta_1 + \alpha_{r+2}^2 \eta_2 + \dots + \alpha_M^2 \eta_{M-r}. \quad (22)$$

Note, para que o funcional $\phi(\bar{\mathbf{p}}) = \bar{\mathbf{p}}^T \overline{\overline{\mathbf{W}_p}} \bar{\mathbf{p}}$ seja mínimo há duas possibilidades:

(1) Estabelecer valores infinitamente grandes para os elementos

η_i , $i = 1, 2, \dots, M - r$. Neste caso a matriz de pesos $\overline{\overline{\mathbf{W}_p}}$ assumiria um padrão particular, ou seja

$$\overline{\overline{\mathbf{W}_p}} = \overline{\overline{\mathbf{V}}} \begin{bmatrix} \overline{\overline{\mathbf{0}}} & \overline{\overline{\mathbf{0}}} \\ \overline{\overline{\mathbf{0}}} & \overline{\overline{\boldsymbol{\eta}}} \end{bmatrix} \overline{\overline{\mathbf{V}}}^T = \overline{\overline{\mathbf{V}}} \begin{bmatrix} \overline{\overline{\mathbf{0}}} & \overline{\overline{\mathbf{0}}} \\ \overline{\overline{\mathbf{0}}} & \infty \end{bmatrix} \overline{\overline{\mathbf{V}}}^T$$

Note que esta primeira possibilidade seria um caso particular, ao contrário queremos que $\phi(\bar{\mathbf{p}}) = \bar{\mathbf{p}}^T \overline{\overline{\mathbf{W}_p}} \bar{\mathbf{p}}$ seja mínimo para quaisquer valores de η_i , $i = 1, 2, \dots, M - r$

(2) A segunda possibilidade para que o funcional $\phi(\bar{\mathbf{p}}) = \bar{\mathbf{p}}^T \overline{\overline{\mathbf{W}_p}} \bar{\mathbf{p}}$ seja mínimo é estabelecer que os α_i , $i = r + 1, r + 2, \dots, M$ devem ser nulos

Diante destas duas possibilidades concluímos que o estimador IG utiliza a informação a priori que o vetor $\overline{\overline{\mathbf{a}}}_{M-r} = \overline{\overline{\mathbf{0}}}$ uma vez que este estimador (caso $r = M$) é dado por

$$\bar{\mathbf{p}}^+ = \bar{\mathbf{V}}_r \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{U}}_r^T \bar{\mathbf{y}}^0$$

que não utiliza os valores da matriz diagonal $\bar{\boldsymbol{\eta}}$.

Em resumo, o estimador IG introduz a informação a priori que a projeção do vetor de parâmetros nas bases que geram o espaço nulo é o vetor nulo. Em outras palavras, o estimador IG introduz a informação a priori que

$$\bar{\boldsymbol{\alpha}}_{M-r} = \bar{\mathbf{0}}.$$

Como o vetor $\bar{\boldsymbol{\alpha}}_{M-r}$ é a projeção da solução nula na base do espaço nulo do espaço dos parâmetros, i.e.,

$$\bar{\mathbf{p}}^{null} = \bar{\mathbf{V}}_{M-r} \bar{\boldsymbol{\alpha}}_{M-r},$$

então podemos dizer que o estimador IG introduz a informação a priori que a solução nula é igual ao vetor nulo

$$\bar{\mathbf{p}}^{null} = \bar{\mathbf{0}}$$

Deduzindo o estimador Inversa Generalizada via minimização de Q e a introdução

direta que $\bar{\boldsymbol{\alpha}}_{M-r} = \bar{\mathbf{0}}$

Já vimos no Tópico 15 que

$$Q = \|\bar{\boldsymbol{\varepsilon}}\|_2^2 = \left\| \bar{\boldsymbol{\beta}}_r - \bar{\mathbf{S}}_r \bar{\boldsymbol{\alpha}}_r \right\|_2^2 + \left\| \bar{\boldsymbol{\beta}}_{M-r} - \bar{\mathbf{S}}_{M-r} \bar{\boldsymbol{\alpha}}_{M-r} \right\|_2^2 + \left\| \bar{\boldsymbol{\beta}}_{N-M} \right\|_2^2$$

considerando que no IG $\bar{\boldsymbol{\alpha}}_{M-r} = \bar{\mathbf{0}}$ temos

$$Q = \left\| \begin{bmatrix} \bar{\beta}_r - \bar{\bar{S}}_r \bar{\alpha}_r \end{bmatrix} \right\|_2^2 + \left\| \bar{\beta}_{M-r} \right\|_2^2 + \left\| \bar{\beta}_{N-M} \right\|_2^2$$

$$Q = (\bar{\beta}_r - \bar{\bar{S}}_r \bar{\alpha}_r)^T (\bar{\beta}_r - \bar{\bar{S}}_r \bar{\alpha}_r) + \bar{\beta}_{M-r}^T \bar{\beta}_{M-r} + \bar{\beta}_{N-M}^T \bar{\beta}_{N-M}$$

A condição para que Q seja mínimo é:

$$\bar{\nabla}_{\bar{\alpha}_r} \{Q\} = \bar{\mathbf{0}}$$

$$\bar{\nabla}_{\bar{\alpha}_r} \{Q\} = 2 \bar{\nabla}_{\bar{\alpha}_r} \left\{ (\bar{\beta}_r - \bar{\bar{S}}_r \bar{\alpha}_r)^T \right\} (\bar{\beta}_r - \bar{\bar{S}}_r \bar{\alpha}_r)$$

$$\bar{\nabla}_{\bar{\alpha}_r} \{Q\} = -2 \bar{\bar{S}}_r^T (\bar{\beta}_r - \bar{\bar{S}}_r \bar{\alpha}_r)$$

$$\bar{\nabla}_{\bar{\alpha}_r} \{Q\} = -2 \bar{\bar{S}}_r^T \bar{\beta}_r + 2 \bar{\bar{S}}_r^T \bar{\bar{S}}_r \bar{\alpha}_r$$

Como $\bar{\bar{S}}_r$ é uma matriz diagonal então

$$\bar{\nabla}_{\bar{\alpha}_r} \{Q\} = -2 \bar{\bar{S}}_r \bar{\beta}_r + 2 \bar{\bar{S}}_r^2 \bar{\alpha}_r$$

Pela condição de mínimo i.e. $\bar{\nabla}_{\bar{\alpha}_r} \{Q\} = \bar{\mathbf{0}}$ temos

$$-2 \bar{\bar{S}}_r \bar{\beta}_r + 2 \bar{\bar{S}}_r^2 \bar{\alpha}_r^* = \bar{\mathbf{0}}$$

$$2 \bar{\bar{S}}_r^2 \bar{\alpha}_r^* = 2 \bar{\bar{S}}_r \bar{\beta}_r$$

$$\bar{\alpha}_r^* = \bar{\bar{S}}_r^{-1} \bar{\beta}_r \quad (23)$$

Como o vetor $\bar{\mathbf{a}}^*$ é a projeção do vetor de parâmetros nos vetores base que geram o espaço de parâmetros (i.e., vetores colunas da matriz $\bar{\mathbf{V}}$ de autovetores) então temos que o estimador IG é dado por

$$\bar{\mathbf{p}}^+ = \bar{\mathbf{V}}_r \bar{\mathbf{a}}_r^* + \bar{\mathbf{V}}_{M-r} \bar{\mathbf{a}}_{M-r}^*$$

Como o estimador IG introduz a informação a priori que $\bar{\mathbf{a}}_{M-r} = \bar{\mathbf{0}}$ temos

$$\bar{\mathbf{p}}^+ = \bar{\mathbf{V}}_r \bar{\mathbf{a}}_r^*$$

Substituindo a equação (23) na equação acima temos:

$$\bar{\mathbf{p}}^+ = \bar{\mathbf{V}}_r \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{\beta}}_r$$

Lembrando que o vetor $\bar{\mathbf{\beta}}$ é a projeção do vetor dos dados observados nos vetores base que geram o espaço das observações i.e. $\bar{\mathbf{U}}^T \bar{\mathbf{y}}^o = \bar{\mathbf{\beta}}$. Então temos que

$$\begin{bmatrix} \bar{\mathbf{\beta}}_r \\ \bar{\mathbf{\beta}}_{M-r} \\ \bar{\mathbf{\beta}}_{N-M} \end{bmatrix} = \begin{bmatrix} \bar{\mathbf{U}}_r \\ \bar{\mathbf{U}}_{M-r} \\ \bar{\mathbf{U}}_{N-M} \end{bmatrix} \bar{\mathbf{y}}^o$$

logo

$$\bar{\mathbf{\beta}}_r = \bar{\mathbf{U}}_r^T \bar{\mathbf{y}}^o$$

$$\bar{\mathbf{p}}^+ = \bar{\mathbf{V}}_r \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{U}}_r^T \bar{\mathbf{y}}^o \quad (24)$$

O estimador IG impõe que $\bar{\mathbf{a}}_{M-r} = \bar{\mathbf{0}}$. Portanto o IG impõe que a solução estimada $\bar{\mathbf{p}}^+$ seja ortogonal ao espaço nulo.. Em outras palavras, o estimador IG introduz a informação a priori que a projeção da solução estimada $\bar{\mathbf{p}}^+$ no espaço nulo seja zero.

Analisando o estimador Inversa Generalizada para dados com ruído em comparação ao estimador MQ

Vimos que o estimador IG é definido como

$$\bar{\mathbf{p}}^+ = \bar{\mathbf{V}}_r \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{U}}_r^T \bar{\mathbf{y}}^o$$

ou ainda

$$\bar{\mathbf{p}}^+ = \bar{\mathbf{V}}_r \bar{\mathbf{S}}_r^{-1} \bar{\boldsymbol{\beta}}_r$$

Se, em uma situação hipotética, pudéssemos decompor os dados observados $\bar{\mathbf{y}}^o$ em duas parcelas sendo que uma delas é o dado livre de ruído $\bar{\mathbf{y}}^{Exato}$ e a segunda parcela é o ruído aditivo $\bar{\boldsymbol{\varepsilon}}$, então teríamos $\bar{\mathbf{y}}^o = \bar{\mathbf{y}}^{Exato} + \bar{\boldsymbol{\varepsilon}}$. Nesta situação hipotética o vetor $\bar{\boldsymbol{\beta}}$ é dado por

$$\begin{aligned}\bar{\boldsymbol{\beta}}_r &= \bar{\mathbf{U}}_r^T \bar{\mathbf{y}}^o \\ \bar{\boldsymbol{\beta}}_r &= \bar{\mathbf{U}}_r^T (\bar{\mathbf{y}}^{Exato} + \bar{\boldsymbol{\varepsilon}}) \\ \bar{\boldsymbol{\beta}}_r &= \bar{\mathbf{U}}_r^T \bar{\mathbf{y}}^{Exato} + \bar{\mathbf{U}}_r^T \bar{\boldsymbol{\varepsilon}} \\ \bar{\boldsymbol{\beta}}_r &= \bar{\boldsymbol{\beta}}_r^{Exato} + \bar{\boldsymbol{\beta}}_r^{Ruido}\end{aligned}$$

Portanto o vetor $\bar{\beta}_r$ foi dividido em duas parcelas em que a primeira parcela ($\bar{\beta}_r^{Exato}$) é a projeção dos dados hipotéticos livre de ruído \bar{y}^{Exato} nos autovetores da matriz \bar{U}_r e a segunda parcela ($\bar{\beta}_r^{Ruido}$) é a projeção o ruído $\bar{\epsilon}$ nos autovetores da matriz \bar{U}_r . Substituindo a expressão acima no estimador IG temos que

$$\begin{aligned}\bar{p}^+ &= \bar{V}_r \bar{S}_r^{-1} (\bar{\beta}_r^{Exato} + \bar{\beta}_r^{Ruido}) \\ \bar{p}^+ &= \bar{V}_r \bar{S}_r^{-1} \bar{\beta}_r^{Exato} + \bar{V}_r \bar{S}_r^{-1} \bar{\beta}_r^{Ruido} \\ \bar{p}^+ &= \sum_{i=1}^r \frac{\beta_i^{Exato}}{S_i} \bar{v}_i + \sum_{i=1}^r \frac{\beta_i^{Ruido}}{S_i} \bar{v}_i\end{aligned}\quad (25)$$

Vamos agora comparar o estimador IG [equação (25)] com o estimador MQ usando a mesma situação hipotética em que os dados observados \bar{y}^o foram decompostos em duas parcelas sendo que uma delas é o dado livre de ruído \bar{y}^{Exato} e a segunda parcela é o ruído aditivo $\bar{\epsilon}$.

Vimos no Tópico 15 que o estimador MQ é expresso como

$$\hat{\bar{p}} = \bar{V}_M \bar{S}_M^{-1} \bar{\beta}$$

Vimos que nesta situação hipotética o i-ésimo elemento do vetor N-dimensional $\bar{\beta}$ é dado

$$\beta_i = \beta_i^{Exato} + \beta_i^{Ruido}$$

Substituindo a expressão acima no estimador MQ temos

$$\hat{\bar{\mathbf{p}}} = \sum_{i=1}^M \frac{\beta_i^{Exato}}{S_i} \bar{\mathbf{v}}_i + \sum_{i=1}^M \frac{\beta_i^{Ruido}}{S_i} \bar{\mathbf{v}}_i \quad (26)$$

Comparando o estimador MQ (equação 26) com o estimador IG (equação 25) vemos que estes estimadores são exatamente iguais se $r = M$. Veja também que a segunda parcela do estimador MQ, i.e., o segundo termo da equação 26

$$\sum_{i=1}^M \frac{\beta_i^{Ruido}}{S_i} \bar{\mathbf{v}}_i$$

pode crescer infinitamente se $S_i \approx 0$. Portanto a solução estimada via MQ com dados com ruído pode estar infinitamente distante da solução estimada com dados livres de ruído (dados exatos) devido a segunda parcela do somatório da equação (26) em que cada termo do somatório pode ser muito grande se $S_i \rightarrow 0$ amplificando o ruído $\bar{\boldsymbol{\varepsilon}}$ contido no vetor $\bar{\boldsymbol{\beta}}^{Ruido} = \bar{\bar{\mathbf{U}}}^T \bar{\boldsymbol{\varepsilon}}$ (projeção do ruído nos autovetores do espaço das observações).

Diferentemente, no caso do estimador IG (equação 25) a segunda parcela é um somatório envolvendo apenas r valores singulares e não os M valores singulares como no estimador MQ. Portanto o estimador IG tem a flexibilidade de não utilizar os M valores singulares do sistema, mas sim os r ($r \leq M$) valores singulares convenientes de modo a tornar o problema estável. Para alcançar esta estabilidade da solução estimada via IG, basta estipular um valor $r < M$ de modo a eliminar aqueles valores singulares próximos a zero. Veja então que eliminando todos os valores singulares próximos a

zero a segunda parcela do estimador IG, i.e., $\sum_{i=1}^r \frac{\beta_i^{Ruido}}{S_i} \bar{\mathbf{v}}_i$, não promoverá a amplificação indesejável do numerador desta parcela e com isto não ocorrerá a amplificação do ruído dos dados observados.

Lembrando que os valores singulares são ordenados em ordem decrescente, i.e., $S_1 \geq S_2 \geq S_3 \geq \dots \geq S_r \geq S_{r+1} \geq \dots \geq S_M$, então quanto MENOR o valor atribuído a r MAIOR a estabilidade introduzida na determinação da solução via IG

TRADE OFF : Estabilidade X Tendenciosidade

Vimos então que há uma relação entre o valor de r e a estabilidade da solução estimada via IG. O preço pago por esta estabilização é a introdução de uma tendenciosidade na estimativa dos parâmetros via IG. Veja que se os dados forem exatos (não contaminados por ruído) a estimativa dos parâmetros via MQ é dada por

$$\hat{\bar{\mathbf{p}}} = \sum_{i=1}^M \frac{\beta_i}{S_i} \bar{\mathbf{v}}_i$$

Porem, sob esta mesma condição o estimador IG é expresso

$$\bar{\mathbf{p}}^+ = \sum_{i=1}^r \frac{\beta_i}{S_i} \bar{\mathbf{v}}_i$$

Note que a diferença entre $\hat{\bar{\mathbf{p}}}$ e $\bar{\mathbf{p}}^+$ será tanto maior quanto menor for o valor de r

$$\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}^+ = \sum_{i=1}^M \frac{\beta_i}{S_i} - \sum_{i=1}^r \frac{\beta_i}{S_i} \bar{\mathbf{v}}_i$$

$$\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}^+ = \sum_{i=r+1}^M \frac{\beta_i}{S_i} \bar{\mathbf{v}}_i$$

Em notação matricial esta diferença é dada por

$$\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}^+ = \bar{\bar{\mathbf{V}}}_M \bar{\bar{\mathbf{S}}}_M^{-1} \bar{\bar{\mathbf{\beta}}}_M - \bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{S}}}_r^{-1} \bar{\bar{\mathbf{\beta}}}_r$$

$$\hat{\bar{\mathbf{p}}} - \bar{\mathbf{p}}^+ = \begin{bmatrix} \bar{\bar{\mathbf{V}}}_r & \bar{\bar{\mathbf{V}}}_{M-r} \end{bmatrix} \begin{bmatrix} \bar{\bar{\mathbf{S}}}_r & \\ & \bar{\bar{\mathbf{S}}}_{M-r} \end{bmatrix}^{-1} \begin{bmatrix} \bar{\bar{\mathbf{\beta}}}_r \\ \bar{\bar{\mathbf{\beta}}}_{N-r} \end{bmatrix} - \begin{bmatrix} \bar{\bar{\mathbf{V}}}_r & \bar{\bar{\mathbf{0}}} \end{bmatrix} \begin{bmatrix} \bar{\bar{\mathbf{S}}}_r & \\ & \bar{\bar{\mathbf{0}}} \end{bmatrix}^{-1} \begin{bmatrix} \bar{\bar{\mathbf{\beta}}}_r \\ \bar{\bar{\mathbf{0}}} \end{bmatrix}$$

$$\hat{\mathbf{p}} - \mathbf{p}^+ = \overline{\overline{\mathbf{V}}}_r \overline{\overline{\mathbf{S}}}_r^{-1} \overline{\mathbf{p}}_r + \overline{\overline{\mathbf{V}}}_{M-r} \overline{\overline{\mathbf{S}}}_{M-r}^{-1} \overline{\mathbf{p}}_{N-r} - \overline{\overline{\mathbf{V}}}_r \overline{\overline{\mathbf{S}}}_r^{-1} \overline{\mathbf{p}}_r.$$

$$\hat{\mathbf{p}} - \mathbf{p}^+ = \overline{\overline{\mathbf{V}}}_{M-r} \overline{\overline{\mathbf{S}}}_{M-r}^{-1} \overline{\mathbf{p}}_{N-r}$$

$(M \times M - r) \quad (M - r \times N - r) \quad (N - r \times 1)$

Note que considerando dados exatos, a diferença entre o vetor de parâmetros exatos via MQ ($\hat{\mathbf{p}}$) e o o vetor de parâmetros exatos via IG (\mathbf{p}^+) envolve apenas a informação contida no espaço M-r i.e., espaço não iluminado.

Analisando o estimador Inversa Generalizada para dados com ruído em comparação ao estimador Ridge Regression (Tikhonov de ordem zero)

Já definimos que o estimador IG (equação 25) é dado por

$$\mathbf{p}^+ = \sum_{i=1}^r \frac{\beta_i^{Exato}}{S_i} \overline{\mathbf{v}}_i + \sum_{i=1}^r \frac{\beta_i^{Ruido}}{S_i} \overline{\mathbf{v}}_i \quad (27)$$

Vimos no tópico 18 que o estimador do Ridge Regression (Regularizador de Tikhonov de ordem zero) é dado por

$$\mathbf{p}^* = \sum_{i=1}^M \frac{S_i}{S_i^2 + k} \beta_i^{Exato} \overline{\mathbf{v}}_i + \sum_{i=1}^M \frac{S_i}{S_i^2 + k} \beta_i^{Ruido} \overline{\mathbf{v}}_i \quad (28)$$

Note que no estimador IG (equação 27) os somatórios envolvem o espaço r dimensional, portanto o espaço M-r dimensional é totalmente eliminado. Já no estimador o Ridge Regression (Regularizador de Tikhonov de ordem zero) [equação (28)] os somatórios envolvem todo o espaço M dimensional.

No IG os valores singulares pertencentes ao espaço M-r são todos eliminados. Portanto, para alcançar a estabilidade da solução estimada há a eliminação de M-r valores singulares próximos de zero. Já no estimador o Ridge Regression (Regularizador de Tikhonov de ordem zero) todos os M valores singulares são utilizados porém há uma distorção de todos os valores singulares (tanto daqueles valores singulares pequenos, pertencentes ao espaço M-r dimensional, quanto dos valores singulares grandes, pertencentes ao espaço r dimensional)

Em resumo, o estimador IG elimina todos os valores singulares pequenos, pertencentes ao espaço M-r dimensional (espaço não iluminado) e preserva todos os valores singulares pertencentes ao espaço r dimensional (espaço iluminado). Ao contrário o estimador Ridge Regression (Regularizador de Tikhonov de ordem zero) distorce (modifica) todos os M valores singulares através do uso de um valor positivo para a variável k [equação (28)]. Esta distorção dos valores singulares é pequena para os valores singulares grandes (pertencentes ao espaço iluminado), por outro lado esta distorção é muito grande para os valores singulares pequenos o que garante a estabilidade da solução.

Significado da informação a priori introduzida pelo estimador IG

A informação a priori introduzida pelo estimador IG é:

$$\overline{\mathbf{a}}_{M-r} = \overline{\mathbf{0}}$$

Portanto o IG introduz a informação que a projeção dos elementos do vetor de parâmetros que pertencem ao espaço nulo (M-r) no novo sistema de referência em que os eixos formados pelos autovetores da matriz $\overline{\overline{\mathbf{V}}}_{M-r}^{(M \times M-r)}$

Em outras palavras o IG introduz a informação que a solução pertencente ao espaço nulo é o vetor nulo

$$\bar{\mathbf{p}}^{null} = \bar{\bar{\mathbf{V}}}_{M-r} \bar{\mathbf{a}}_{M-r}$$

$$\bar{\mathbf{p}}^{null} = \bar{\mathbf{0}}$$

$$\bar{\bar{\mathbf{V}}}_{M-r}^T \bar{\mathbf{p}} = \bar{\mathbf{0}}$$

Então o IG impõe que a solução $\bar{\mathbf{p}}^+$ é ortogonal ao espaço nulo, uma vez que sua projeção no espaço nulo (espaço M-r) é nulo ($\bar{\mathbf{a}}_{M-r} = \bar{\mathbf{0}}$). Lembre-se que $\bar{\mathbf{a}}_{M-r}$ é a projeção da solução nula na base do espaço nulo.

Critério para a determinação do posto efetivo r^* do estimador IG

Vimos que o estimador IG introduz uma tendenciosidade a solução estimada para obtenção de uma solução estável. O posto ótimo r^* deve ser um equilíbrio entre a tendenciosidade e a estabilidade da solução estimada.

Vamos apresentar alguns critérios para determinação do posto ótimo r^* .

(1) Limite Superior para a Variância do k-ésimo parâmetro

Sob as premissas estatísticas estabelecidas na Figura 2, a variância do k-ésimo parâmetro estimado via IG é

$$\text{var} \left\{ \mathbf{p}^+_k \right\} = \sigma^2 \sum_{j=1}^r \frac{v_{kj}^2}{S_j^2} \quad k = 1, \dots, M$$

O posto ótimo r^* será o maior inteiro que satisfaz a seguinte desigualdade

$$\sigma^2 \sum_{j=1}^r \frac{v_{kj}^2}{S_j^2} \leq \sigma_{\text{sup}}^2(k) \quad (33)$$

em que $\sigma_{\text{sup}}^2(k)$ é a máxima variância tolerada para o k-ésimo parâmetro.

Se escolhermos o maior r que satisfaz a desigualdade (33) então isto implicará um menor espaço nulo $(M-r)$ e, conseqüentemente, implicará um menor espaço para ser incorporado informação a priori $\bar{\mathbf{a}}_{M-r} = \bar{\mathbf{0}}$ logo menor será a tendenciosidade.

(1) Limite superior para a razão $\frac{S_r}{S_{r+1}}$

Vamos escolher o r como o maior inteiro satisfazendo

$$\frac{s_r}{s_{r+1}} < c$$

em que c é um limite, usualmente, no entorno de 10. Então verificamos se a razão entre os valores singulares sucessivos é menor que c .

(2) Análise da norma do resíduo

$$Q = \|\bar{\epsilon}\|_2^2 = \left\| \bar{y}^o - \bar{A} \bar{p}^+ \right\|_2^2$$

Substituindo o estimador IG $\bar{p}^+ = \bar{V}_r \bar{S}_r^{-1} \bar{U}_r^T \bar{y}^o$ na equação acima temos que a norma Euclideana do resíduo é

$$Q = \|\bar{\epsilon}\|_2^2 = \left\| \bar{y}^o - \bar{A} \bar{V}_r \bar{S}_r^{-1} \bar{U}_r^T \bar{y}^o \right\|_2^2$$

Usando a decomposição em valores singulares da matriz $\bar{A} = \bar{U}_r \bar{S}_r \bar{V}_r^T$, temos

$$Q = \|\bar{\epsilon}\|_2^2 = \left\| \bar{y}^o - \bar{U}_r \bar{S}_r \bar{V}_r^T \bar{V}_r \bar{S}_r^{-1} \bar{U}_r^T \bar{y}^o \right\|_2^2$$

Como $\bar{V}_r^T \bar{V}_r = \bar{I}_{(r \times r)}$ e $\bar{S}_r^{-1} \bar{S}_r = \bar{I}_{(r \times r)}$ temos que

$$Q = \|\bar{\epsilon}\|_2^2 = \left\| \bar{y}^o - \bar{U}_r \bar{U}_r^T \bar{y}^o \right\|_2^2$$

$$Q = \|\bar{\epsilon}\|_2^2 = \left\| \left(\bar{I}_{(N \times N)} - \bar{U}_r \bar{U}_r^T \right) \bar{y}^o \right\|_2^2$$

Como $\bar{U}_r \bar{U}_r^T + \bar{U}_{N-r} \bar{U}_{N-r}^T = \bar{I}_{(N \times N)}$ então temos que $\bar{U}_{N-r} \bar{U}_{N-r}^T = \bar{I}_{(N \times N)} - \bar{U}_r \bar{U}_r^T$ logo

$$Q = \|\bar{\varepsilon}\|_2^2 = \left\| \overline{\mathbf{U}}_{N-r} \overline{\mathbf{U}}_{N-r}^T \bar{\mathbf{y}}^o \right\|_2^2$$

Como $\overline{\mathbf{U}}_{N-r}^T \bar{\mathbf{y}}^o = \bar{\boldsymbol{\beta}}_{N-r}$ então temos que

$$Q = \|\bar{\varepsilon}\|_2^2 = \left\| \overline{\mathbf{U}}_{N-r} \bar{\boldsymbol{\beta}}_{N-r} \right\|_2^2 \quad (33)$$

Veja então que o vetor de resíduos do estimador IG pode ser escrito como


$$\bar{\varepsilon} = \overline{\mathbf{U}}_{N-r} \overline{\mathbf{U}}_{N-r}^T \bar{\mathbf{y}}^o$$

Logo os resíduos do estimador IG é a projeção dos dados observados no espaço N-r das observações. Matematicamente minimizar a função-objeto (33) significa impor que a projeção dos dados observados no espaço N-r das observações, i.e. $\bar{\boldsymbol{\beta}}_{N-r}$, deve ser aproximadamente zero. Em outras palavras, a minimização de

$$Q = \|\bar{\varepsilon}\|_2^2 = \left\| \overline{\mathbf{U}}_{N-r} \bar{\boldsymbol{\beta}}_{N-r} \right\|_2^2$$

implica $\bar{\boldsymbol{\beta}}_i \approx 0, i = r+1, r+2, \dots, N$, logo estes coeficientes não contribuirão significativamente para o ajuste IG. Então podemos dizer que o ajuste do estimador IG é controlado apenas pela projeção dos dados observados no espaço r das observações, i.e. $\bar{\boldsymbol{\beta}}_r$.

Na prática faremos um gráfico do ajuste Q versus o posto. Assim o posto ótimo r^* será o primeiro inteiro a partir do qual o resíduo Q não cai substancialmente



Dedução e análise do estimador Inversa Generalizada (IG) via Estimador Genérico:

Vimos que o estimador IG é deduzido do problema matemático:

$$\text{Minimize } \bar{\mathbf{p}}^T \bar{\mathbf{W}}_p \bar{\mathbf{p}}$$

$$\text{Sujeito a } \left(\bar{\mathbf{A}}\bar{\mathbf{p}} - \bar{\mathbf{y}}^0 \right)^T \bar{\mathbf{W}}_e \left(\bar{\mathbf{A}}\bar{\mathbf{p}} - \bar{\mathbf{y}}^0 \right) = \delta$$

Façamos

$$\bar{\mathbf{W}}_p = \bar{\mathbf{V}} \begin{bmatrix} \bar{\mathbf{0}} & \bar{\mathbf{0}} \\ \bar{\mathbf{0}} & \bar{\boldsymbol{\eta}} \end{bmatrix} \bar{\mathbf{V}}^T$$

em que $\bar{\boldsymbol{\eta}}$ é uma matriz diagonal, não singular com dimensão $(M - r \times M - r)$ logo

$$\bar{\mathbf{W}}_p = \bar{\mathbf{V}}_{M-r} \bar{\boldsymbol{\eta}} \bar{\mathbf{V}}_{M-r}^T$$

e

$$\bar{\mathbf{W}}_e = \bar{\mathbf{U}} \begin{bmatrix} \bar{\boldsymbol{\gamma}} & \bar{\mathbf{0}} \\ \bar{\mathbf{0}} & \bar{\mathbf{0}} \end{bmatrix} \bar{\mathbf{U}}^T$$

em que $\bar{\boldsymbol{\gamma}}$ é uma matriz diagonal, não singular com dimensão $(r \times r)$ logo

$$\bar{\mathbf{W}}_e = \bar{\mathbf{U}}_r \bar{\boldsymbol{\gamma}} \bar{\mathbf{U}}_r^T$$

Vimos anteriormente que se $r = M$ o estimador Inversa Generalizada é dado pela equação

$$\bar{\mathbf{p}}^+ = \bar{\mathbf{V}}_r \bar{\mathbf{S}}_r^{-1} \bar{\mathbf{U}}_r^T \bar{\mathbf{y}}^0 \quad (3.1)$$

Comparando a equação (3.1) com a equação (3) concluímos que no estimador Inversa Generalizada

$$\bar{\bar{\mathbf{H}}} = \bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{S}}}_r^{-1} \bar{\bar{\mathbf{U}}}_r^T \quad (3.2)$$

$$\bar{\mathbf{p}}^0 = \bar{\mathbf{0}} \quad (3.3)$$

$$\bar{\bar{\mathbf{W}}}_y = \bar{\bar{\mathbf{U}}}_r \bar{\bar{\gamma}} \bar{\bar{\mathbf{U}}}_r^T \quad (3.4)$$

$$\bar{\bar{\mathbf{W}}}_p = \bar{\bar{\mathbf{V}}}_{M-r} \bar{\bar{\eta}} \bar{\bar{\mathbf{V}}}_{M-r}^T \quad (3.5)$$

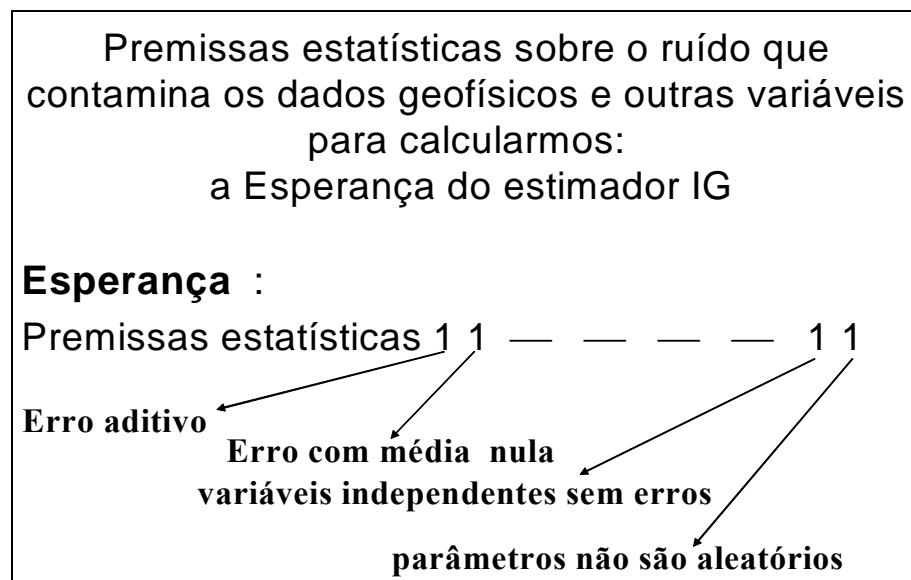
$$\mu = 0 \quad (3.6)$$

Logo no estimador Inversa Generalizada temos que

$$\hat{\bar{\mathbf{p}}} = \bar{\bar{\mathbf{H}}} \bar{\mathbf{y}}^0 \quad (3.7)$$

3.1) Análise Estatística do Estimador Inversa Generalizada Via Estimador Genérico

3.1.1) A esperança de $\bar{\mathbf{p}}^+$ sob as premissas estatísticas 1 1 — — — — 1 1



Vimos na equação (6) que

$$E \left\{ \tilde{\bar{\mathbf{p}}} \right\} = \overline{\overline{\mathbf{H}}} \overline{\overline{\mathbf{A}}} \bar{\mathbf{p}} + \left(\overline{\overline{\mathbf{I}}} - \overline{\overline{\mathbf{H}}} \overline{\overline{\mathbf{A}}} \right) \bar{\mathbf{p}}^0$$

Como no estimador Inversa Generalizada $\bar{\mathbf{p}}^0 = \bar{\mathbf{0}}$ e $\overline{\overline{\mathbf{H}}} = \overline{\overline{\mathbf{V}}}_r \overline{\overline{\mathbf{S}}}_r^{-1} \overline{\overline{\mathbf{U}}}_r^T$ temos que a equação acima é dada por

$$E\{\bar{\mathbf{p}}^+\} = \overline{\overline{\mathbf{V}}}_r \overline{\overline{\mathbf{S}}}_r^{-1} \overline{\overline{\mathbf{U}}}_r^T \overline{\overline{\mathbf{A}}} \bar{\mathbf{p}}$$

Usando a decomposição em valores singulares da matriz de sensibilidade é igual a

$$\overline{\overline{\mathbf{A}}} = \overline{\overline{\mathbf{U}}}_r \overline{\overline{\mathbf{S}}}_r \overline{\overline{\mathbf{V}}}_r^T \text{ temos que}$$

$$E\{\bar{\mathbf{p}}^+\} = \overline{\overline{\mathbf{V}}}_r \overline{\overline{\mathbf{S}}}_r^{-1} \overline{\overline{\mathbf{U}}}_r^T \overline{\overline{\mathbf{U}}}_r \overline{\overline{\mathbf{S}}}_r \overline{\overline{\mathbf{V}}}_r^T \bar{\mathbf{p}}$$

$$E\{\bar{\mathbf{p}}^+\} = \overline{\overline{\mathbf{V}}}_r \overline{\overline{\mathbf{V}}}_r^T \bar{\mathbf{p}} \quad (3.8)$$

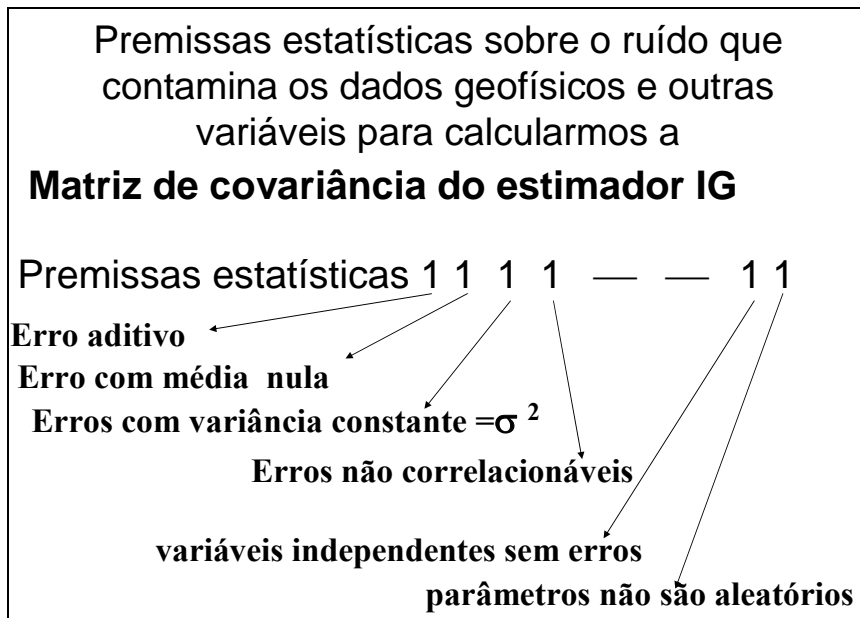
Portanto o estimador Inversa Generalizada é um estimador tendencioso.

Veja que, somente se $r = M$ temos que $\overline{\overline{\mathbf{V}}}_r \overline{\overline{\mathbf{V}}}_r^T = \overline{\overline{\mathbf{I}}}$, este caso temos o estimador MQ

sobredeterminado em que $E\{\hat{\bar{\mathbf{p}}}\} = \bar{\mathbf{p}}$

3.1.2) A Matriz de Covariância de $\bar{\mathbf{p}}^+$

Sob as premissas estatísticas 1 1 1 1 — — 1 1



Vimos na equação (7) que

$$\text{COV} \left\{ \tilde{\mathbf{p}} \right\} = \overline{\mathbf{H}} \text{cov} \left\{ \tilde{\mathbf{\epsilon}} \right\} \overline{\mathbf{H}}^T$$

Como no estimador Inversa Generalizada e $\overline{\mathbf{H}} = \overline{\mathbf{V}}_r \overline{\mathbf{S}}_r^{-1} \overline{\mathbf{U}}_r^T$ temos que a equação acima é

$$\text{COV} \left\{ \overline{\mathbf{p}}^+ \right\} = \overline{\mathbf{V}}_r \overline{\mathbf{S}}_r^{-1} \overline{\mathbf{U}}_r^T \text{cov} \left\{ \tilde{\mathbf{\epsilon}} \right\} \overline{\mathbf{U}}_r \overline{\mathbf{S}}_r^{-1} \overline{\mathbf{V}}_r^T$$

Usando a premissa 3 que os erros tem variância constante e a premissa 4 que os erros não são correlacionáveis temos que

$$\text{COV} \left\{ \tilde{\mathbf{\epsilon}} \right\} = \sigma^2 \overline{\mathbf{I}}$$

$$\text{COV} \left\{ \overline{\mathbf{p}}^+ \right\} = \sigma^2 \overline{\mathbf{V}}_r \overline{\mathbf{S}}_r^{-1} \overline{\mathbf{U}}_r^T \overline{\mathbf{U}}_r \overline{\mathbf{S}}_r^{-1} \overline{\mathbf{V}}_r^T$$

$$\boxed{\text{COV} \left\{ \overline{\mathbf{p}}^+ \right\} = \sigma^2 \overline{\mathbf{V}}_r \overline{\mathbf{S}}_r^{-2} \overline{\mathbf{V}}_r^T} \quad (3.9)$$

Veja que a covariância do kj-ésimo elemento da matriz $\text{cov} \left\{ \hat{\mathbf{p}} \right\}$ é

$$\text{cov} \left\{ \mathbf{p}^+_{kj} \right\} = \sigma^2 \sum_{j=1}^r \frac{v_{kj} v_{kj}}{S_j^2}, \quad k = 1, \dots, M$$

Como a variância de $\overline{\mathbf{p}}^+$ são os elementos da diagonal da matriz de covariância ($\text{cov} \left\{ \overline{\mathbf{p}}^+ \right\}$) então temos que a variância do k-ésimo parâmetro é

$$\text{var} \left\{ \hat{\mathbf{p}}_k \right\} = \sigma^2 \sum_{j=1}^r \frac{v_{kj}^2}{S_j^2} \quad (3.10)$$

Note que no estimador IG temos também variâncias inversamente proporcionais aos valores singulares da matriz de sensibilidade $\overline{\mathbf{A}}$. No entanto, diferentemente do estimadores MQ sobre e MQ sub, vemos que o somatório na equação (3.10) envolve apenas r valores singulares. Então, o estimador Inversa Generalizada permite utilizar apenas os r maiores valores singulares (aqueles r valores singulares que não são próximos a zero).

Esta é a grande vantagem do estimador IG quando comparado aos estimadores:

i) MQ SOBRE cuja matriz de covariância é dada por

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = \sigma^2 \overline{\mathbf{V}}_M \overline{\mathbf{S}}_M^{-2} \overline{\mathbf{V}}_M^T \quad \text{MQ SOBRE}$$

sendo, portanto, a variância do k-ésimo parâmetro dada por

$$\text{var} \left\{ \hat{\mathbf{p}}_k \right\} = \sigma^2 \sum_{j=1}^M \frac{v_{kj}^2}{S_j^2} \quad \text{MQ SOBRE}$$

e

ii) MQ SUB cuja matriz de covariância é dada por

$$\text{COV} \left\{ \hat{\mathbf{p}} \right\} = \sigma^2 \overline{\mathbf{V}}_N \overline{\mathbf{S}}_N^{-2} \overline{\mathbf{V}}_N^T \quad \text{MQ SUB}$$

sendo, portanto, a variância do k-ésimo parâmetro dada por

$$\text{var} \left\{ \hat{\mathbf{p}}_k \right\} = \sigma^2 \sum_{j=1}^N \frac{v_{kj}^2}{S_j^2} \quad \text{MQ SUB}$$

Notamos que no MQ sobre e MQ Sub, obrigatoriamente, as variâncias dos parâmetros envolvem, respectivamente, os M e N valores singulares. Ao contrário, no estimador IG o somatório na equação (3.10) envolve apenas r valores singulares em que r pode ser menor que M (e/ou menor que N). Isto possibilita excluir do somatório da equação (3.10) aqueles M-r valores singulares próximos de zero.

Então quanto menor o valor atribuído a r, maior será a estabilidade introduzida na determinação da solução via IG. O preço pago por isto é a introdução da tendenciosidade na estimativa dos parâmetros que pode ser atestada matematicamente por

$$E\{\bar{\mathbf{p}}^+\} = \overline{\mathbf{V}}_r \overline{\mathbf{V}}_r^T \bar{\mathbf{p}}$$

se $r \neq M$ temos que $\overline{\mathbf{V}}_r \overline{\mathbf{V}}_r^T \neq \overline{\mathbf{I}}$ logo o estimador IG é tendencioso.

2.1.3) A esperança da distância $(\bar{\mathbf{p}}^+ - \bar{\mathbf{p}})^T (\bar{\mathbf{p}}^+ - \bar{\mathbf{p}})$

Vimos na equação (8) que

$$E\left\{\left\|\tilde{\mathbf{p}} - \bar{\mathbf{p}}\right\|_2^2\right\} = \text{tr}\{\text{cov}(\tilde{\mathbf{p}})\} + \left\|E\left\{\tilde{\mathbf{p}}\right\} - \bar{\mathbf{p}}\right\|_2^2$$

Na equação (3.9) deduzimos que no estimador MQ sobre

$$\text{COV}\left\{\bar{\mathbf{p}}^+\right\} = \sigma^2 \bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{S}}}_r^{-2} \bar{\bar{\mathbf{V}}}_r^T$$

e na equação (3.8) deduzimos que

$$E\{\bar{\mathbf{p}}^+\} = \bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{V}}}_r^T \bar{\mathbf{p}}$$

Logo temos que no estimador Inversa Generalizada a esperança da distância

$(\bar{\mathbf{p}}^+ - \bar{\mathbf{p}})^T (\bar{\mathbf{p}}^+ - \bar{\mathbf{p}})$ é dada por

$$E\{[\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]^T [\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]\} = \text{tr}\left\{\sigma^2 \bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{S}}}_r^{-2} \bar{\bar{\mathbf{V}}}_r^T\right\} + \left\|\bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{V}}}_r^T \bar{\mathbf{p}} - \bar{\mathbf{p}}\right\|_2^2$$

$$E\{[\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]^T [\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]\} = \text{tr}\left\{\sigma^2 \bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{S}}}_r^{-2} \bar{\bar{\mathbf{V}}}_r^T\right\} + \left\|\left(\bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{V}}}_r^T - \bar{\bar{\mathbf{I}}}\right)\bar{\mathbf{p}}\right\|_2^2$$

Lembrando da propriedade do traço do produto de matrizes

$$\text{tr}\{\bar{\bar{\mathbf{C}}}\bar{\bar{\mathbf{B}}}\} = \text{tr}\{\bar{\bar{\mathbf{B}}}\bar{\bar{\mathbf{C}}}\}$$

Então podemos escrever que

$$E\{[\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]^T [\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]\} = \text{tr}\left\{\sigma^2 \bar{\bar{\mathbf{S}}}_r^{-2} \bar{\bar{\mathbf{V}}}_r^T \bar{\bar{\mathbf{V}}}_r\right\} + \left\|\left(\bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{V}}}_r^T - \bar{\bar{\mathbf{I}}}\right)\bar{\mathbf{p}}\right\|_2^2$$

$$E\{[\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]^T [\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]\} = \text{tr}\left\{\sigma^2 \bar{\bar{\mathbf{S}}}_r^{-2}\right\} + \left\|\left(\bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{V}}}_r^T - \bar{\bar{\mathbf{I}}}\right)\bar{\mathbf{p}}\right\|_2^2$$

Como no caso Inversa Generalizada $r < M$ então temos que

$$\bar{\bar{\mathbf{V}}}_M \bar{\bar{\mathbf{V}}}_M^T = \bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{V}}}_r^T + \bar{\bar{\mathbf{V}}}_{M-r} \bar{\bar{\mathbf{V}}}_{M-r}^T = \bar{\bar{\mathbf{I}}}_M$$

então temos que $\bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{V}}}_r^T - \bar{\bar{\mathbf{I}}}_M = -\bar{\bar{\mathbf{V}}}_{M-r} \bar{\bar{\mathbf{V}}}_{M-r}^T$

$$E\{[\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]^T [\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]\} = \text{tr}\left\{\sigma^2 \bar{\bar{\mathbf{S}}}_r^{-2}\right\} + \left\| \left(-\bar{\bar{\mathbf{V}}}_{M-r} \bar{\bar{\mathbf{V}}}_{M-r}^T\right) \bar{\mathbf{p}} \right\|_2^2$$

$$E\{[\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]^T [\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]\} = \text{tr}\left\{\sigma^2 \bar{\bar{\mathbf{S}}}_r^{-2}\right\} + \bar{\mathbf{p}}^T \left(-\bar{\bar{\mathbf{V}}}_{M-r} \bar{\bar{\mathbf{V}}}_{M-r}^T\right)^T \left(-\bar{\bar{\mathbf{V}}}_{M-r} \bar{\bar{\mathbf{V}}}_{M-r}^T\right) \bar{\mathbf{p}}$$

$$E\{[\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]^T [\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]\} = \text{tr}\left\{\sigma^2 \bar{\bar{\mathbf{S}}}_r^{-2}\right\} + \bar{\mathbf{p}}^T \left(-\bar{\bar{\mathbf{V}}}_{M-r} \bar{\bar{\mathbf{V}}}_{M-r}^T\right) \left(-\bar{\bar{\mathbf{V}}}_{M-r} \bar{\bar{\mathbf{V}}}_{M-r}^T\right) \bar{\mathbf{p}}$$

$$E\{[\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]^T [\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]\} = \text{tr}\left\{\sigma^2 \bar{\bar{\mathbf{S}}}_r^{-2}\right\} + \bar{\mathbf{p}}^T \bar{\bar{\mathbf{V}}}_{M-r} \bar{\bar{\mathbf{V}}}_{M-r}^T \bar{\bar{\mathbf{V}}}_{M-r} \bar{\bar{\mathbf{V}}}_{M-r}^T \bar{\mathbf{p}}$$

$$E\{[\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]^T [\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]\} = \text{tr}\left\{\sigma^2 \bar{\bar{\mathbf{S}}}_r^{-2}\right\} + \bar{\mathbf{p}}^T \bar{\bar{\mathbf{V}}}_{M-r} \bar{\bar{\mathbf{V}}}_{M-r}^T \bar{\mathbf{p}}$$

Chamando $\bar{\bar{\mathbf{V}}}_{M-r}^T \bar{\mathbf{p}} = \bar{\bar{\mathbf{a}}}_{M-r}$ temos que

$$E\{[\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]^T [\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]\} = \sigma^2 \text{tr}\left\{\bar{\bar{\mathbf{S}}}_r^{-2}\right\} + \bar{\bar{\mathbf{a}}}_{M-r}^T \bar{\bar{\mathbf{a}}}_{M-r}$$

Com a decomposição em valores singulares da matriz de sensibilidade é igual a

$$\bar{\bar{\mathbf{A}}} = \bar{\bar{\mathbf{U}}}_r \bar{\bar{\mathbf{S}}}_r \bar{\bar{\mathbf{V}}}_r^T \text{ em que } r = N, \text{ temos que esperança da distância } (\bar{\mathbf{p}}^+ - \bar{\mathbf{p}})^T (\bar{\mathbf{p}}^+ - \bar{\mathbf{p}})$$

do estimador Inversa Generalizada é dado por

$$E\{[\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]^T [\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}]\} = \sigma^2 \sum_{i=1}^r \frac{1}{S_i^2} + \sum_{i=r+1}^M \alpha_i^2 \quad (3.11)$$

$$E\left\{\left\|\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}\right\|_2^2\right\} = \sigma^2 \frac{1}{S_1^2} + \sigma^2 \frac{1}{S_2^2} + \dots + \sigma^2 \frac{1}{S_r^2} + \alpha_{r+1}^2 + \alpha_{r+2}^2 + \dots + \alpha_M^2$$

em que $S_i, i = 1, 2, \dots, r$ são os r maiores valores singulares da matriz de sensibilidade $\bar{\bar{\mathbf{A}}}$.

Note que quanto menor o valor de r maior é o espaço $M - r$ e conseqüentemente

maior é a dimensão do vetor $\bar{\mathbf{u}}_{M-r}$. Se aumentarmos o valor de r menor será o espaço $M-r$ e menor a dimensão do vetor $\bar{\mathbf{u}}_{M-r}$.

Então veja o primeiro termo da Esperança da distância $\|\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}\|_2^2$, equação (3.11), é formada por duas parcelas:

1) $tr\{\text{cov}(\bar{\mathbf{p}}^+)\} = \sigma^2 \sum_{i=1}^r \frac{1}{S_i^2}$ é a primeira parcela e representa uma medida

de covariância do estimador, ou seja, uma medida da estabilidade da solução estimada. Esta parcela é uma função crescente monotônica de r , i.e., quanto maior r maior será o valor desta primeira parcela e, por outro lado, quanto menor r menor será o valor desta primeira parcela.

2) $\|E\{\bar{\mathbf{p}}^+\} - \bar{\mathbf{p}}\|_2^2 = \sum_{i=r+1}^M \alpha_i^2$ é a segunda parcela representa uma medida da distância

da esperança do estimador ($\bar{\mathbf{p}}^+$) e o vetor de parâmetros ($\bar{\mathbf{p}}$). Veja portanto que esta segunda parcela é uma medida da tendenciosidade do estimador $\bar{\mathbf{p}}^+$. Esta parcela é uma função decrescente monotônica de r , i.e., quanto maior r menor será o valor desta segunda parcela e, por outro lado, quanto menor r maior será o valor desta segunda parcela.

Graficamente a esperança da distância $(\bar{\mathbf{p}}^+ - \bar{\mathbf{p}})^T(\bar{\mathbf{p}}^+ - \bar{\mathbf{p}})$ do estimador Inversa Generalizada pode ser simplificada pela Figura 1 em que r^* é o posto “ótimo”, i.e., um trade-off entre a tendenciosidade e a estabilidade da solução. Note que se $r = M$ temos a $E\{\|\bar{\mathbf{p}}^+ - \bar{\mathbf{p}}\|_2^2\}$ do estimador de MQ SOBRE (i.e., solução se tendeciosidade porém com variância máxima).




Figura 3.1

1.1.4) A matriz de resolução associada a $\bar{\mathbf{p}}^+$

Vimos na equação (9) que

$$\bar{\bar{\mathbf{R}}} = \bar{\bar{\mathbf{H}}} \bar{\bar{\mathbf{A}}}$$

Como no estimador Inversa Generalizada $\bar{\bar{\mathbf{H}}} = \bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{S}}}_r^{-1} \bar{\bar{\mathbf{U}}}_r^T$ temos que a equação acima é dada por

$$\bar{\bar{\mathbf{R}}} = \bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{S}}}_r^{-1} \bar{\bar{\mathbf{U}}}_r^T \bar{\bar{\mathbf{A}}}$$

Usando a decomposição em valores singulares da matriz de sensibilidade é igual a

$$\bar{\bar{\mathbf{A}}} = \bar{\bar{\mathbf{U}}}_r \bar{\bar{\mathbf{S}}}_r \bar{\bar{\mathbf{V}}}_r^T \text{ temos que}$$

$$\bar{\bar{\mathbf{R}}} = \bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{S}}}_r^{-1} \bar{\bar{\mathbf{U}}}_r^T \bar{\bar{\mathbf{U}}}_r \bar{\bar{\mathbf{S}}}_r \bar{\bar{\mathbf{V}}}_r^T$$

$$\bar{\bar{\mathbf{R}}} = \bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{V}}}_r^T \quad (3.12)$$

Veja que a matriz de resolução estimador Inversa Generalizada NÃO é igual a matriz identidade, portanto não é a máxima resolução a menos que $r = M$ porque, neste caso, $\bar{\bar{\mathbf{V}}}_M \bar{\bar{\mathbf{V}}}_M^T = \bar{\bar{\mathbf{I}}}_M$ e $\bar{\bar{\mathbf{R}}} = \bar{\bar{\mathbf{I}}}_M$. Como em geral $r < M$, o produto $\bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{V}}}_r^T \neq \bar{\bar{\mathbf{I}}}_M$.

Isto significa dizer que cada elemento NÃO é estimado de modo ÚNICO (i.e., $p_j^+, j = 1, 2, \dots, M$ NÃO são estimados independentemente). Dizemos que cada elemento de $\bar{\mathbf{p}}^+$ NÃO é perfeitamente resolvido. Em outras palavras, se a matriz de resolução estimador Inversa Generalizada é diferente da a matriz identidade, isto significa dizer que o j-ésimo parâmetro estimado via IG é obtido como uma combinação linear de TODOS os parâmetros. Logo no estimador Inversa Generalizada a resolução não é máxima.

Em resumo no estimador IG em geral $r < M$ então $\bar{\bar{\mathbf{R}}} = \bar{\bar{\mathbf{V}}}_r \bar{\bar{\mathbf{V}}}_r^T \neq \bar{\bar{\mathbf{I}}}_M$ então o aspecto da i-ésima linha da matriz de resolução passa de uma delta de Dirac [caso em que $r = M$ e $\bar{\bar{\mathbf{R}}} = \bar{\bar{\mathbf{V}}}_M \bar{\bar{\mathbf{V}}}_M^T = \bar{\bar{\mathbf{I}}}_M$, Figura 3.2a] para uma função sinc discreta (Figura 3.2b)




Figura 3.2

Assim $p_i^+ = \bar{\mathbf{r}}_i^T \bar{\mathbf{p}}$ mostra que neste caso em que $r < M$ a estimativa IG do i-ésimo parâmetro é obtida pela combinação linear de todos os parâmetros com uma maior contribuição do i-ésimo parâmetro verdadeiro. Quanto menor for o valor de r em

relação a M, mais achatada será a função sinc e maior a contribuição relativa de outros parâmetros em relação ao i-ésimo parâmetro verdadeiro estimado p_i^+

Note que adicionalmente que

$$\bar{\mathbf{p}}^+ = \bar{\mathbf{R}} \bar{\mathbf{p}}$$

$$\bar{\mathbf{p}}^+ = \bar{\mathbf{V}}_r \bar{\mathbf{V}}_r^T \bar{\mathbf{p}}$$

Como temos que $\bar{\mathbf{V}}_M \bar{\mathbf{V}}_M^T = \bar{\mathbf{V}}_r \bar{\mathbf{V}}_r^T + \bar{\mathbf{V}}_{M-r} \bar{\mathbf{V}}_{M-r}^T = \bar{\mathbf{I}}_M$ então temos que

$$\bar{\mathbf{V}}_r \bar{\mathbf{V}}_r^T = \bar{\mathbf{I}}_M - \bar{\mathbf{V}}_{M-r} \bar{\mathbf{V}}_{M-r}^T$$

logo

$$\bar{\mathbf{p}}^+ = \left(\bar{\mathbf{I}}_M - \bar{\mathbf{V}}_{M-r} \bar{\mathbf{V}}_{M-r}^T \right) \bar{\mathbf{p}}$$

$$\bar{\mathbf{p}}^+ = \bar{\mathbf{p}} - \bar{\mathbf{V}}_{M-r} \bar{\mathbf{V}}_{M-r}^T \bar{\mathbf{p}}$$

Chamando $\bar{\mathbf{V}}_{M-r}^T \bar{\mathbf{p}} = \bar{\mathbf{a}}_{M-r}$ temos que

$$\bar{\mathbf{p}}^+ = \bar{\mathbf{p}} - \bar{\mathbf{V}}_{M-r} \bar{\mathbf{a}}_{M-r}$$

Considerando que a solução IG excluiu todos os $M - r$ valores singulares iguais

a zero, então $\bar{\mathbf{V}}_{M-r} \bar{\mathbf{a}}_{M-r} = \bar{\mathbf{p}}^{null}$ expresso como

$$\bar{\mathbf{p}}^+ = \bar{\mathbf{p}} - \bar{\mathbf{p}}^{Null} \quad (3.13)$$

O resultado mostrado pela equação (3.13) diz que o estimador Inversa Generalizada, se forem excluídos os $M-r$ valores singulares iguais a zero, é uma solução que nunca contém qualquer solução nula ($\bar{\mathbf{p}}^{null}$)

3.1.5) A matriz densidade de informação associada a $\bar{\mathbf{p}}^+$

Vimos na equação (10) que

$$\begin{matrix} \overline{\overline{\mathbf{F}}} \\ (N \times N) \end{matrix} = \overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{H}}}$$

Como no estimador Inversa Generalizada $\overline{\overline{\mathbf{H}}} = \overline{\overline{\mathbf{V}}}_r \overline{\overline{\mathbf{S}}}_r^{-1} \overline{\overline{\mathbf{U}}}_r^T$ temos que a equação acima é dada por

$$\overline{\overline{\mathbf{F}}} = \overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{V}}}_r \overline{\overline{\mathbf{S}}}_r^{-1} \overline{\overline{\mathbf{U}}}_r^T$$

Usando a decomposição em valores singulares da matriz de sensibilidade é igual a

$$\overline{\overline{\mathbf{A}}} = \overline{\overline{\mathbf{U}}}_r \overline{\overline{\mathbf{S}}}_r \overline{\overline{\mathbf{V}}}_r^T \text{ temos que}$$

$$\overline{\overline{\mathbf{F}}} = \overline{\overline{\mathbf{U}}}_r \overline{\overline{\mathbf{S}}}_r \overline{\overline{\mathbf{V}}}_r^T \overline{\overline{\mathbf{V}}}_r \overline{\overline{\mathbf{S}}}_r^{-1} \overline{\overline{\mathbf{U}}}_r^T$$

$$\boxed{\overline{\overline{\mathbf{F}}} = \overline{\overline{\mathbf{U}}}_r \overline{\overline{\mathbf{U}}}_r^T}$$

(3.14)

A equação (3.14) mostra que a matriz densidade de informação do estimador Inversa Generalizada só será igual a matriz identidade se $r = N$. Se $r < N$ a matriz

$$\overline{\overline{\mathbf{F}}} = \overline{\overline{\mathbf{U}}}_r \overline{\overline{\mathbf{U}}}_r^T \neq \overline{\overline{\mathbf{I}}}_N. \text{ Isto quer dizer que se } r < N \text{ os dados observados e os dados}$$

ajustados via estimador Inversa Generalizada é diferente de zero ($\bar{\varepsilon} \neq \bar{\mathbf{0}}$). Conclusão, no estimador Inversa Generalizada o ajuste em geral NÃO EXATO (se $r < N$).