

Teoria da Reconstituição Compacta:

O estimador de Inversão Compacta (Last and Kubik, 1983)

O estimador que apresentaremos agora introduz uma informação a priori qualitativa de compacidade da fonte anômala, i.e, fonte com mínimo volume (Last and Kubik, 1983). Matematicamente, esta informação será introduzida através da minimização do funcional estabilizante.

$$H(\bar{\mathbf{p}}) = (\bar{\mathbf{p}} - \bar{\mathbf{p}}^0)^T \overline{\overline{\mathbf{W}}}_p (\bar{\mathbf{p}} - \bar{\mathbf{p}}^0), \quad (1)$$

em que $\bar{\mathbf{p}}^0 = \bar{\mathbf{0}}$ e $\overline{\overline{\mathbf{W}}}_p$ é uma matriz diagonal de dimensão $M \times M$ cujo j -ésimo elemento é dado por

$$W_{pj} = \frac{1}{p_j^2 + \varepsilon} \quad (2)$$

em que ε é um número positivo pequeno.

Interpretação do funcional $H(\bar{\mathbf{p}})$ a ser minimizado

Considerando que $\bar{\mathbf{p}}^0 = \bar{\mathbf{0}}$, veja que temos que minimizar o funcional $H(\bar{\mathbf{p}})$ dado por:

$$\min H(\bar{\mathbf{p}}) = \min \left\{ \bar{\mathbf{p}}^T \overline{\overline{\mathbf{W}}}_p \bar{\mathbf{p}} \right\} \quad (3)$$

Considerando a matriz $\overline{\overline{\mathbf{W}}}_p$ definida na equação (2), a minimização do funcional (3) é equivalente a minimizar

$$H(\mathbf{p}) = \sum_{j=1}^M W_{p_j} p_j^2 \quad (4)$$

$$H(\mathbf{p}) = \sum_{j=1}^M \frac{p_j^2}{p_j^2 + \varepsilon} = \begin{cases} 0, & \text{se } p_j = 0 \\ 1, & \text{se } p_j \neq 0 \end{cases} \quad (5)$$

Veja então que $H(\mathbf{p})$ é o número de parâmetros não nulos. Por exemplo, se tenho 5 parâmetros e o mínimo do funcional $H(\mathbf{p})$ é igual a 3 parâmetros estimados, isto significa dizer que há 3 parâmetros estimados não nulos e 2 parâmetros nulos. Desse modo o mínimo de $H(\mathbf{p})$ ocorrerá quando houver um número mínimo de parâmetros estimados não nulos, sujeito a explicar as observações geofísicas.

Veja que se os parâmetros são propriedades físicas da subsuperfície, por exemplo, a densidade e o nosso problema inverso consiste estimar a variação espacial da densidade a partir dos dados gravimétricos, presumindo-se como simplificação que a nossa subsuperfície foi discretizada em M bloquinhos (Figura 1)

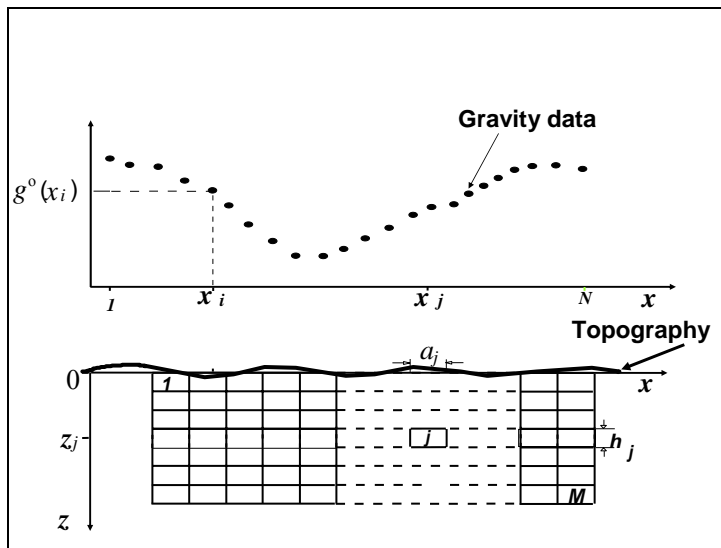


Figura 1

em que p_j é a densidade do j -ésimo bloquinho.

Neste caso o funcional $H(\mathbf{p})$ será o número de bloquinhos com densidades não nulas.

Desse modo o mínimo de $H(\mathbf{p})$ ocorrerá quando for estimada uma fonte anômala com o mínimo número de bloquinhos com densidades estimadas diferentes de zero, ou seja, uma fonte anômala com mínimo volume, sujeito a explicar os dados gravimétricos observados. Alternativamente, dizemos que a fonte tem compacidade máxima.

Formulação Matemática do Problema da Inversão Compacta

Matematicamente a Inversão compacta pode ser formulada como um problema vinculado de

$$\begin{cases} \min & H(\bar{\mathbf{p}}) \\ \text{sujeito a} & \|\boldsymbol{\varepsilon}\|_2^2 = \delta \end{cases} \quad (6)$$

em que δ é o ruído contido nos dados observados. O problema vinculado (6) pode ser reescrito como

$$\begin{cases} \min & H(\bar{\mathbf{p}}) = \min \left\| \overline{\mathbf{W}}_p^{1/2} \bar{\mathbf{p}} \right\|_2^2 \\ \text{sujeito a} & \left\| \bar{\mathbf{y}}^o - \overline{\mathbf{A}} \bar{\mathbf{p}} \right\|_2^2 = \delta \end{cases} \quad (7)$$

ou ainda

$$\begin{cases} \min & H(\bar{\mathbf{p}}) = \min \left\{ \bar{\mathbf{p}}^T \overline{\mathbf{W}}_p \bar{\mathbf{p}} \right\} \\ \text{sujeito a} & \left(\bar{\mathbf{y}}^o - \overline{\mathbf{A}} \bar{\mathbf{p}} \right)^T \left(\bar{\mathbf{y}}^o - \overline{\mathbf{A}} \bar{\mathbf{p}} \right) = \delta \end{cases} \quad (8)$$

em que $\overline{\overline{\mathbf{W}}}_p$ é uma matriz diagonal ($M \times M$) cujo j -ésimo elemento é

$$W_{p_j} = \frac{1}{p_j^2 + \varepsilon}. \quad (9)$$

onde ε é um número positivo da ordem de 10^{-7} . Veja que estamos considerando que a relação funcional entre a i -ésima observação geofísica e os parâmetros a serem estimados (vetor $\overline{\mathbf{p}}$) é uma função linear em relação aos parâmetros, que em notação matricial é

$$\overline{\mathbf{y}} = \overline{\overline{\mathbf{A}}} \overline{\mathbf{p}}. \quad (10)$$

Então a matriz de sensibilidade $\overline{\overline{\mathbf{A}}} (N \times M)$ não depende dos parâmetros. A princípio o nosso problema inverso geofísico é linear. Agora vamos analisar o funcional estabilizante a ser minimizado

$$\min H(\overline{\mathbf{p}}) = \min \left\| \overline{\overline{\mathbf{W}}}_p^{1/2} \overline{\mathbf{p}} \right\|_2^2 \quad (11)$$

Veja que estamos minimizando a norma Euclideana do vetor $\overline{\overline{\mathbf{W}}}_p^{1/2} \overline{\mathbf{p}}$, cujo j -ésimo elemento é

$$W_{p_j}^{1/2} p_j = \frac{1}{\left(p_j^2 + \varepsilon\right)^{1/2}} p_j$$

Derivando este elemento em relação ao j -ésimo termo temos

$$\begin{aligned}\frac{\partial}{\partial p_j} \left\{ W_{p_j}^{1/2} p_j \right\} &= \frac{\partial}{\partial p_j} \left\{ \left(p_j^2 + \varepsilon \right)^{-1/2} p_j \right\} \\ \frac{\partial}{\partial p_j} \left\{ W_{p_j}^{1/2} p_j \right\} &= -\frac{1}{2} \left(p_j^2 + \varepsilon \right)^{-3/2} (2 p_j) p_j + \left(p_j^2 + \varepsilon \right)^{-1/2} \\ \frac{\partial}{\partial p_j} \left\{ W_{p_j}^{1/2} p_j \right\} &= \frac{1}{\left(p_j^2 + \varepsilon \right)^{1/2}} - \frac{p_j^2}{\left(p_j^2 + \varepsilon \right)^{3/2}}\end{aligned}$$

Como podemos verificar a derivada da informação a priori introduzida NÃO é uma constante. É uma função dos parâmetros como mostra a equação acima. Logo nós estamos diante de uma função não linear. Rigorosamente, o nosso problema inverso vinculado (8) é um problema não linear. No entanto, os autores formularam este problema inverso como um problema linear iterativo reponderado (reweighted least-squares minimization). Matematicamente, o problema que resolvemos iterativamente é o problema linear vinculado de

$$\begin{cases} \min H(\bar{\mathbf{p}}) = \min \left\{ \left(\bar{\mathbf{p}} - \bar{\mathbf{p}}^0 \right)^T \overline{\overline{\mathbf{W}}}_p \left(\bar{\mathbf{p}} - \bar{\mathbf{p}}^0 \right) \right\} \\ \text{sujeito a } \left(\bar{\mathbf{y}}^0 - \overline{\overline{\mathbf{A}}} \bar{\mathbf{p}} \right)^T \left(\bar{\mathbf{y}}^0 - \overline{\overline{\mathbf{A}}} \bar{\mathbf{p}} \right) = \delta \end{cases} \quad (12)$$

em que $\overline{\overline{\mathbf{W}}}_p$ e $\bar{\mathbf{p}}^0$ serão considerados constantes em cada iteração (i.e., não dependentes do vetor de parâmetros). Este problema vinculado (12) pode ser resolvido via Multiplicadores de Lagrange. Então a função não vinculada a ser minimizada pode ser escrita como

$$\text{Min } \{\Gamma(\bar{\mathbf{p}})\} = \text{Min} \left\{ \frac{1}{\lambda} (\bar{\mathbf{y}}^0 - \bar{\mathbf{A}} \bar{\mathbf{p}})^T (\bar{\mathbf{y}}^0 - \bar{\mathbf{A}} \bar{\mathbf{p}}) - \delta + (\bar{\mathbf{p}} - \bar{\mathbf{p}}^0)^T \bar{\mathbf{W}}_p (\bar{\mathbf{p}} - \bar{\mathbf{p}}^0) \right\}, \quad (13)$$

Vamos considerar que a matriz $\bar{\mathbf{W}}_p$ é uma matriz constante (i.e. é uma matriz que não depende dos parâmetros) e o vetor $\bar{\mathbf{p}}^0$ também não é função dos parâmetros, sob estas considerações a solução da equação (13) é obtida tomando o gradiente da função $\Gamma(\bar{\mathbf{p}})$ e igualando o resultado ao vetor nulo:

$$\bar{\nabla}_p \{ \Gamma(\bar{\mathbf{p}}) \} = \bar{\nabla}_p \left\{ \left(\bar{\mathbf{y}}^0 - \bar{\mathbf{A}} \bar{\mathbf{p}} \right)^T \left(\bar{\mathbf{y}}^0 - \bar{\mathbf{A}} \bar{\mathbf{p}} \right) - \delta \right\} + \lambda \bar{\nabla}_p \left\{ (\bar{\mathbf{p}} - \bar{\mathbf{p}}^0)^T \bar{\mathbf{W}}_p (\bar{\mathbf{p}} - \bar{\mathbf{p}}^0) \right\}$$

Calculando os gradientes e igualando o resultado ao vetor nulo temos:

$$2 \bar{\mathbf{A}}^T \bar{\mathbf{A}} \tilde{\bar{\mathbf{p}}} - 2 \bar{\mathbf{A}}^T \bar{\mathbf{y}}^0 + 2 \lambda \bar{\mathbf{W}}_p \tilde{\bar{\mathbf{p}}} + 2 \lambda \bar{\mathbf{W}}_p \bar{\mathbf{p}}^0 = \bar{\mathbf{0}}$$

$$\bar{\mathbf{A}}^T \bar{\mathbf{A}} \tilde{\bar{\mathbf{p}}} + \lambda \bar{\mathbf{W}}_p \tilde{\bar{\mathbf{p}}} - \lambda \bar{\mathbf{W}}_p \bar{\mathbf{p}}^0 = \bar{\mathbf{A}}^T \bar{\mathbf{y}}^0$$

Vamos somar nos dois lados da equação o termo $-\bar{\mathbf{A}}^T \bar{\mathbf{A}} \bar{\mathbf{p}}^0$ então teremos:

$$\bar{\mathbf{A}}^T \bar{\mathbf{A}} \tilde{\bar{\mathbf{p}}} - \bar{\mathbf{A}}^T \bar{\mathbf{A}} \bar{\mathbf{p}}^0 + \lambda \bar{\mathbf{W}}_p \tilde{\bar{\mathbf{p}}} - \lambda \bar{\mathbf{W}}_p \bar{\mathbf{p}}^0 = \bar{\mathbf{A}}^T \bar{\mathbf{y}}^0 - \bar{\mathbf{A}}^T \bar{\mathbf{A}} \bar{\mathbf{p}}^0$$

$$\left[\bar{\mathbf{A}}^T \bar{\mathbf{A}} + \lambda \bar{\mathbf{W}}_p \right] (\tilde{\bar{\mathbf{p}}} - \bar{\mathbf{p}}^0) = \bar{\mathbf{A}}^T (\bar{\mathbf{y}}^0 - \bar{\mathbf{A}} \bar{\mathbf{p}}^0)$$

$$(\tilde{\bar{\mathbf{p}}} - \bar{\mathbf{p}}^0) = \left[\bar{\mathbf{A}}^T \bar{\mathbf{A}} + \lambda \bar{\mathbf{W}}_p \right]^{-1} \bar{\mathbf{A}}^T (\bar{\mathbf{y}}^0 - \bar{\mathbf{A}} \bar{\mathbf{p}}^0)$$

$$\tilde{\bar{\mathbf{p}}} = \bar{\mathbf{p}}^0 + \left[\bar{\mathbf{A}}^T \bar{\mathbf{A}} + \lambda \bar{\mathbf{W}}_p \right]^{-1} \bar{\mathbf{A}}^T (\bar{\mathbf{y}}^0 - \bar{\mathbf{A}} \bar{\mathbf{p}}^0) \quad (14)$$

Lembre-se que a matriz de peso $\bar{\mathbf{W}}_p$ foi considerada, por simplificação, uma matriz diagonal com elementos constantes (não dependentes dos parâmetros). No entanto, mostramos anteriormente que a matriz $\bar{\mathbf{W}}_p$ não é constante, logo é função dos

parâmetros ($\bar{\mathbf{p}}$). Desta forma a solução será estimada em um processo iterativo, em que na iteração K+1 estimaremos:

$$\tilde{\bar{\mathbf{p}}}^{(k+1)} = \bar{\mathbf{p}}^{(k)} + \left[\bar{\mathbf{A}}^T \bar{\mathbf{A}} + \lambda \bar{\mathbf{W}}_p^{(k)} \right]^{-1} \bar{\mathbf{A}}^T (\bar{\mathbf{y}}^o - \bar{\mathbf{A}} \bar{\mathbf{p}}^{(k)}) \quad (15)$$

Usando a identidade $\bar{\mathbf{C}}(\bar{\mathbf{D}} \bar{\mathbf{C}} + \bar{\mathbf{I}}_n)^{-1} = (\bar{\mathbf{C}} \bar{\mathbf{D}} + \bar{\mathbf{I}}_m)^{-1} \bar{\mathbf{C}}$ em que sendo $\bar{\mathbf{C}}$ uma matriz com dimensão M x N e $\bar{\mathbf{D}}$ uma matriz com dimensão N x M, ambas não singulares (invertíveis) temos que a equação (15) pode ser reescrita como

$$\tilde{\bar{\mathbf{p}}}^{(k+1)} = \bar{\mathbf{p}}^{(k)} + \left[\left(\bar{\mathbf{A}}^T \bar{\mathbf{A}} \frac{1}{\lambda} \bar{\mathbf{W}}_p^{(k)-1} + \bar{\mathbf{I}}_M \right) \lambda \bar{\mathbf{W}}_p^{(k)} \right]^{-1} \bar{\mathbf{A}}^T (\bar{\mathbf{y}}^o - \bar{\mathbf{A}} \bar{\mathbf{p}}^{(k)})$$

$$\tilde{\bar{\mathbf{p}}}^{(k+1)} = \bar{\mathbf{p}}^{(k)} + \frac{1}{\lambda} \bar{\mathbf{W}}_p^{(k)-1} \left[\bar{\mathbf{A}}^T \bar{\mathbf{A}} \frac{1}{\lambda} \bar{\mathbf{W}}_p^{(k)-1} + \bar{\mathbf{I}}_M \right]^{-1} \bar{\mathbf{A}}^T (\bar{\mathbf{y}}^o - \bar{\mathbf{A}} \bar{\mathbf{p}}^{(k)}) \quad (16)$$

Vamos chamar:

$$\bar{\mathbf{C}} = \bar{\mathbf{A}}^T \quad \text{e}$$

$$\bar{\mathbf{D}} = \bar{\mathbf{A}} \left(\frac{1}{\lambda} \bar{\mathbf{W}}_p^{(k)-1} \right).$$

Agora vamos usar a identidade $\bar{\mathbf{C}}(\bar{\mathbf{D}} \bar{\mathbf{C}} + \bar{\mathbf{I}}_n)^{-1} = (\bar{\mathbf{C}} \bar{\mathbf{D}} + \bar{\mathbf{I}}_m)^{-1} \bar{\mathbf{C}}$ na equação (16)

$$\tilde{\bar{\mathbf{p}}}^{(k+1)} = \bar{\mathbf{p}}^{(k)} + \frac{1}{\lambda} \bar{\mathbf{W}}_p^{(k)-1} \bar{\mathbf{A}}^T \left[\bar{\mathbf{A}} \frac{1}{\lambda} \bar{\mathbf{W}}_p^{(k)-1} \bar{\mathbf{A}}^T + \bar{\mathbf{I}}_N \right]^{-1} (\bar{\mathbf{y}}^o - \bar{\mathbf{A}} \bar{\mathbf{p}}^{(k)})$$

Colocando o termo $\frac{1}{\lambda}$ para dentro do termo a ser invertido temos:

$$\tilde{\bar{\mathbf{p}}}^{(k+1)} = \bar{\mathbf{p}}^{(k)} + \bar{\mathbf{W}}_p^{(k)-1} \bar{\mathbf{A}}^T \left[\left(\bar{\mathbf{A}} \frac{1}{\lambda} \bar{\mathbf{W}}_p^{(k)-1} \bar{\mathbf{A}}^T + \bar{\mathbf{I}}_N \right) \lambda \right]^{-1} (\bar{\mathbf{y}}^o - \bar{\mathbf{A}} \bar{\mathbf{p}}^{(k)})$$

$$\tilde{\mathbf{p}}^{(k+1)} = \bar{\mathbf{p}}^{(k)} + \overline{\overline{\mathbf{W}}}_p^{(k)-1} \overline{\overline{\mathbf{A}}}^T \left[\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{W}}}_p^{(k)-1} \overline{\overline{\mathbf{A}}}^T + \lambda \overline{\overline{\mathbf{I}}}_N \right]^{-1} (\bar{\mathbf{y}}^o - \overline{\overline{\mathbf{A}}} \bar{\mathbf{p}}^{(k)}) \quad (17)$$

O estimador de Inversão compacta [equação (17)] usa na iteração $k = 0$ $\overline{\overline{\mathbf{W}}}_p = \overline{\overline{\mathbf{I}}}_M$ e

$\bar{\mathbf{p}}^o = \mathbf{0}$. Com isto o estimador (17) no primeiro passo (em que $k = 0$) reduz-se a:

$$\tilde{\mathbf{p}}^{(1)} = \overline{\overline{\mathbf{A}}}^T \left[\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{A}}}^T + \lambda \overline{\overline{\mathbf{I}}}_N \right]^{-1} \bar{\mathbf{y}}^o \quad (18)$$

Veja que a inversão compacta, parte do estimador de Ridge Regression (regularizador de Tikhonov de ordem zero), onde λ é um escalar não negativo. Quanto maior o valor de λ , o menor a norma Euclideana de $\tilde{\mathbf{p}}^{(1)}$. Então, o parâmetro estimado é iterativamente atualizado por

$$\tilde{\mathbf{p}}^{(k+1)} = \tilde{\mathbf{p}}^{(k)} + \Delta \tilde{\mathbf{p}}^{(k)} \quad (19)$$

em que

$$\Delta \tilde{\mathbf{p}}^{(k)} = \overline{\overline{\mathbf{W}}}_p^{(k)-1} \overline{\overline{\mathbf{A}}}^T \left[\overline{\overline{\mathbf{A}}} \overline{\overline{\mathbf{W}}}_p^{(k)-1} \overline{\overline{\mathbf{A}}}^T + \lambda \overline{\overline{\mathbf{I}}}_N \right]^{-1} (\bar{\mathbf{y}}^o - \overline{\overline{\mathbf{A}}} \tilde{\mathbf{p}}^{(k)}) \quad (20)$$

Para evitar que o volume colapse em um único bloco com densidade extremamente alta, é necessário impor um limite superior e um limite inferior as estimativas das densidades. Estes limites são impostos da seguinte forma. Na k -ésima iteração, os blocos cujas densidade estimadas foram acima do limite superior (ou inferior) o peso da matriz $\overline{\overline{\mathbf{W}}}_p$, correspondente a tais blocos, i.e. os elementos da matriz $\overline{\overline{\mathbf{W}}}_p$, ao invés de serem calculados via equação (9) serão atribuídos valores muito elevados para garantir que $\tilde{p}_j^{(k+1)} \approx \tilde{p}_j^{(k)}$ para tais blocos (i.e, se atribuirmos um valor extremamente grande para $W_{p_j}^{(k)}$ estamos forçando $\Delta \tilde{p}_j^{(k)} \rightarrow 0$ para garantir a minimização do

funcional $H(\bar{\mathbf{p}})$). Além disso, neste caso, o j -ésimo elemento de $\hat{\mathbf{p}}^{(k)}$ (equação 19) é substituído pelo limite de densidade violado (limite inferior ou superior) .

Desse modo, haverá a tendência do algoritmo buscar uma fonte homogênea com densidade igual ao limite superior introduzido no algoritmo.

Assim além da informação de MENOR VOLUME, o método introduz as informações sobre: HOMOGENEIDADE e VALOR DA PROPRIEDADE FÍSICA.

Reconstituição Compacta (Guillen and Menichetti, 1984)

O estimador que apresentarei agora introduz uma informação a priori qualitativa de CONCENTRAÇÃO DA FONTE ANÔMALA EM TORNO DE UM EIXO (Guillen and Menichetti, 1984). Similarmente estes autores presumiram que os parâmetros são propriedades físicas da subsuperfície, por exemplo, a densidade e o problema inverso consiste estimar a variação espacial da densidade a partir dos dados gravimétricos, presumindo-se como simplificação que a nossa subsuperfície foi discretizada em M bloquinhos (Figura 2) e o conhecimento a priori sobre direção (eixo) de concentração de fonte.

Matematicamente, a informação a priori sobre concentração de fontes em torno de eixo será introduzida através do mesmo problema vinculado acima estabelecido, i.e.,

$$\left\{ \begin{array}{l} \min H(\bar{\mathbf{p}}) = \min \left\{ \left(\bar{\mathbf{p}} - \bar{\mathbf{p}}^o \right)^T \overline{\overline{\mathbf{W}}}_p \left(\bar{\mathbf{p}} - \bar{\mathbf{p}}^o \right) \right\} \\ \text{sujeito a } \left(\bar{\mathbf{y}}^o - \overline{\overline{\mathbf{A}}} \bar{\mathbf{p}} \right)^T \left(\bar{\mathbf{y}}^o - \overline{\overline{\mathbf{A}}} \bar{\mathbf{p}} \right) = \delta \end{array} \right. \quad (21)$$

em que $\overline{\overline{\mathbf{W}}}_p$ é uma matriz diagonal ($M \times M$) cujo j -ésimo elemento é

$$W_{p_j} = \frac{(d_j^2 + k_j^2) v_j}{|p_j| + \varepsilon} \quad (22)$$

onde ε é um número positivo da ordem de 10^{-7} , v_j é o volume da j -ésima célula (ou bloco), d_j é a distância do centro da j -ésima célula ao eixo (informação a priori introduzida) e k_j é uma constante que iremos discutir a seguir.

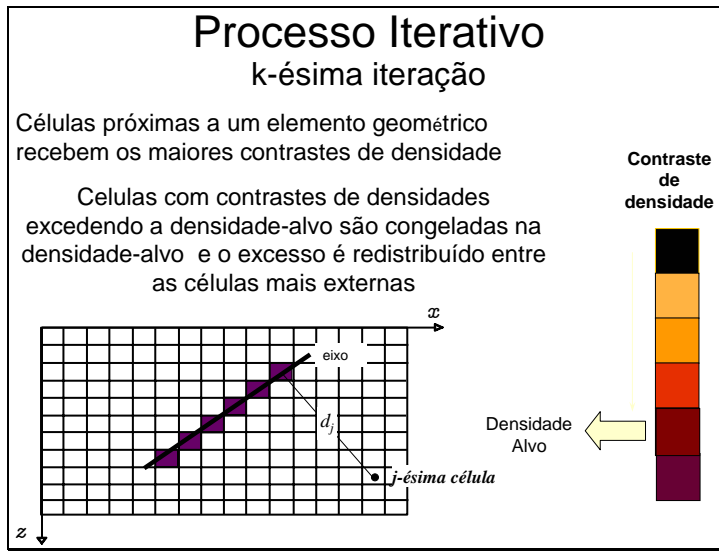


Figura 2

Interpretação do funcional $H(\bar{\mathbf{p}})$ a ser minimizado

Considerando que $\bar{\mathbf{p}}^0 = \bar{\mathbf{0}}$, equação (21), veja que temos que minimizar o funcional $H(\bar{\mathbf{p}})$ dado por:

$$\min H(\bar{\mathbf{p}}) = \min \left\{ \bar{\mathbf{p}}^T \overline{\mathbf{W}}_p \bar{\mathbf{p}} \right\} \quad (23)$$

Considerando a matriz $\overline{\mathbf{W}}_p$ definida na equação (22), a minimização do funcional (23) é equivalente a minimizar

$$H(\bar{\mathbf{p}}) = \sum_{j=1}^M W_{p_j} p_j^2 \quad (24)$$

$$H(\bar{\mathbf{p}}) = \sum_{j=1}^M p_j^2 \frac{(d_j^2 + k_j^2) v_j}{|p_j| + \varepsilon} \begin{cases} 0, & \text{se } p_j = 0 \\ |p_j|(d_j^2 + k_j^2) v_j, & \text{se } p_j \neq 0 \end{cases} \quad (25)$$

A constante k_j é escolhida de modo que seja igual ao momento de inércia em relação ao eixo dado. Minimizar $H(\mathbf{p})$ é equivalente a encontrar um fonte compacta (com o menor número de parâmetros não nulos, i.e, com menor número de blocos com propriedade física diferente de zero) e que também tenha o menor momento de inércia em relação ao eixo dado. Desse modo, a solução tenderão a apresentar uma concentração da propriedade física no entorno do eixo.

As mesmas observações sobre o processo iterativo e a introdução de limites sobre a propriedade física, feitas no caso da inversão compacta, são válidas aqui também. Assim além de introduzir informações sobre compacidade da fonte e de homogeneidade (com o valor da propriedade física igual ao limite superior estabelecido), este método introduz informação a priori sobre direção preferencial de concentração da propriedade física.

Outros estimadores que exploram a reconstituição compacta

Barbosa and Silva (1994) generalizaram a metodologia de Guillen e Menichetti (1983) para admitir a concentração de fontes no entorno de múltiplos eixos e pontos.

A adaptação do método de Last and Kubik (1983) para o caso 3D gravimétrico e magnético foi desenvolvido por Portniaguine and Zhdanov (1999) e (2000), respectivamente. Portniaguine and Zhdanov (1999) usaram o mesmo funcional estabilizante originalmente desenvolvido por Last and Kubik (1983) para inversão gravimétrica compacta 2D e atribuíram um novo nome para este método (focusing inversion method).

Portniaguine and Zhdanov (2000) explicitamente estabeleceram que usaram um funcional estabilizante similar aquele desenvolvido por last and Kubik (1983), referindo-se a este funcional como um “funcional estabilizante de mínimo suporte (MS)”. Enfatizo que a principal diferença entre a abordagem de Portniaguine and Zhdanov (1999) usando o funcional MS e aquele desenvolvido por Last and Kubik (1983) é a implementação computacional do algoritmo. Por outro lado, ressalto que um dos resultados interessantes obtidos por Portniaguine and Zhdanov (1999) foi a prova que o funcional estabilizantes introduzido por Last and Kubik (1983) pode ser considerado como um estabilizador de regularização de Tikhonov (veja Appendix A on Portniaguine and Zhdanov, 1999).

Referências

Barbosa, V. C. F., and Silva, J. B. C, 1994, Generalized compact gravity inversion: Geophysics, **59**, 57-68.

Guillen, A., and Menichetti, V., 1984, Gravity and magnetic inversion with minimization of a specific functional: Geophysics, **49** , 1354-1360.

Last, B. J., and Kubik, K., 1983, Compact gravity inversion: Geophysics, **48** , 713-721

Portniaguine, O. and Zhdanov, M. S., 1999, Focusing geophysical inversion images: Geophysics, **64**, 874-887.

Portniaguine, O. and Zhdanov, M. S., 2000, 3-D magnetic inversion with data compression and image focusing: Geophysics, **67**, 1532-1541.